

最优化理论

陈鸿峥

2019.06*

目录

1	简介	2
1.1	优化概述	2
1.2	分类	3
1.3	历史	3
2	凸集	3
3	凸函数	6
4	凸优化问题	12
4.1	标准型	12
4.2	线性规划	14
4.3	二次规划	15
4.4	半定规划	17
4.5	多目标优化问题	18
5	对偶理论	18
5.1	拉格朗日对偶	18
5.2	强弱对偶	22
5.3	对偶问题的几种解释	24
5.4	一般优化问题的对偶理论	26
6	优化算法	29
6.1	简介	29
6.2	梯度下降法	31
6.3	非光滑优化问题	36
6.4	二阶优化方法	42

*Build 20190615

6.5	有约束优化方法	44
6.6	对偶次梯度法	46
7	大数据中的优化问题与算法	50
7.1	并行优化	50
7.2	无中心分布式优化	52
7.3	有限和优化	54
7.4	方差消减	54
7.5	深度神经网络	55
7.6	在线优化	55
7.7	动态优化	56
7.8	Nesterov加速	56
A	矩阵微积分	57
A.1	基本矩阵知识	57
A.2	实值函数对向量的导数	57
A.3	向量值函数对向量的导数	58
B	参考资料	59

1 简介

1.1 优化概述

优化(optimization): 从一个可行解的集合中寻找出最好的元素

- 最小二乘法 (凸问题)

$$\min \|A\mathbf{x} - \mathbf{b}\|_2^2$$

- 深度神经网络 (非凸, 见下)

$$\mathbf{x}_1^{(i)} = f_1(\mathbf{x}_0^{(i)}, \mathbf{w}_1)$$

... ..

$$\mathbf{x}_n^{(i)} = f_n(\mathbf{x}_{n-1}^{(i)}, \mathbf{w}_n)$$

$$\min \sum_{i=1}^m (\mathbf{y}^{(i)} - \mathbf{x}_n^{(i)})^2$$

- 图像处理, 自然图像通常都是分块光滑的, 原图 Φ_0 , 有噪声的新图 Φ
全变参(TV, Total Variation)范数, 计算图像每个像素点左侧和下侧的差异

$$\|\Phi\|_{TV} = \sum_y \sum_x \sqrt{(\Phi(x, y) - \Phi(x, y - 1))^2 + (\Phi(x, y) - \Phi(x - 1, y))^2}$$

可得优化目标：近似自然图像，而且跟原图不能差太远

$$\min(\|\Phi\|_{TV} + \lambda\|\Phi - \Phi_0\|_F^2)$$

- 推荐系统：Netflix问题→低秩矩阵补全

矩阵横向为用户，纵向为电影，值为评分值(1 ~ 5)，问题是把矩阵补全，这样就可以做推荐了
电影很多，但类型不多，关联关系有限→近似低秩¹

低秩本来需要最小化 \mathbf{z} 的非零奇异值数目 $\|\mathbf{z}\|_0$ ，但是非凸的；转化为最小化和范数² $\|\mathbf{z}\|_*$

$$\min \quad \|\mathbf{z}\|_* := \|\mathbf{z}\|_1$$

$$\text{s.t.} \quad \mathbf{z}_{ij} = M_{ij}, (i, j) \in \Omega$$

1.2 分类

- 线性规划/非线性规划
- 凸规划/非凸规划（更好的分类）

目标函数凸函数，可行解集为凸集则是凸优化，一般容易求解

1.3 历史

- Newton-Raphson算法：求零点，等价于求 $\min f^2(x)$
- Gauss-Seidel算法：求解线性方程组 $A\mathbf{x} = \mathbf{b}$ ，等价于求 $\min \|A\mathbf{x} - \mathbf{b}\|_2^2$
- Lagrange：法国
- Kantorovich：苏联，线性规划，诺贝尔经济学奖
- Dantzig：美国，优化决策，线性规划单纯形
- Von Neumann：线性规划问题对偶理论
- Karmarkar：80年代，线性规划内点法
- Nesterov：后80年代，非线性凸优化内点法
- 现代：并行、随机算法

2 凸集

定义 1. 一些集合概念如下

¹ A 的秩等于非零奇异值 $\sqrt{\text{eig}(A^T A)}$ 数目

²矩阵所有奇异值之和

- 仿射集 (*affine set*)

C 为仿射集 \iff 过 C 内任意两点的直线都在 C 内

$$\iff \forall x_1, x_2 \in C, \theta \in \mathbb{R}, \theta x_1 + (1 - \theta)x_2 \in C$$

例 1. 用定义易证线性方程组的解集 $C = \{\mathbf{x} \mid A\mathbf{x} = \mathbf{b}\}$ 是仿射集；反过来，每一个仿射集都可以用线性方程组的解集表示

- 仿射组合 (多点扩展)

$$\forall x_1, x_2, \dots, x_k \in C, \theta_1, \dots, \theta_k \in \mathbb{R}, \theta_1 + \dots + \theta_k = 1 : \theta_1 x_1 + \dots + \theta_k x_k \in C$$

- 仿射包 (*hull*): 所有仿射组合的集合

$$\text{aff } C := \{\theta_1 x_1 + \dots + \theta_k x_k \mid \forall x_1, \dots, x_k \in C, \theta_1 + \dots + \theta_k = 1\}$$

- 凸集 (*convex set*)

C 为凸集 \iff 过 C 内任意两点的线段都在 C 内

$$\iff \forall x_1, x_2 \in C, \theta \in [0, 1], \theta x_1 + (1 - \theta)x_2 \in C$$

- 凸组合

$$\forall x_1, x_2, \dots, x_k \in C, \theta_1, \dots, \theta_k \in [0, 1], \theta_1 + \dots + \theta_k = 1 : \theta_1 x_1 + \dots + \theta_k x_k \in C$$

- 凸包: 最小的凸集

$$\text{conv } C := \{\theta_1 x_1 + \dots + \theta_k x_k \mid \forall x_1, \dots, x_k \in C, \theta_1, \dots, \theta_k \in [0, 1], \theta_1 + \dots + \theta_k = 1\}$$

- 凸锥 (*convex cone*)

$$C \text{ 为凸锥 } \iff \forall x_1, x_2 \in C, \theta_1, \theta_2 \geq 0, \theta_1 x_1 + \theta_2 x_2 \in C$$

除了空集的凸锥都得包含原点 (取 $\theta_1 = \theta_2 = 0$)

- 凸锥组合/非负线性组合:

$$\forall x_1, x_2, \dots, x_k \in C, \theta_1, \dots, \theta_k \geq 0 : \theta_1 x_1 + \dots + \theta_k x_k \in C$$

- 凸锥包: 类似前面定义

由上面的定义易知，仿射组合/凸锥组合 (强条件) 一定是凸组合。

定义 2 (超平面(hyperplane)与半空间(halfspace)). 超平面都是比原空间低一维

$$\{\mathbf{x} \mid \mathbf{a}^T \mathbf{x} = b, \mathbf{x}, \mathbf{a} \in \mathbb{R}^n, b \in \mathbb{R}, \mathbf{a} \neq 0\}$$

超平面将空间划分为两个部分, 即半空间

$$\{\mathbf{x} \mid \mathbf{a}^T \mathbf{x} \leq b, \mathbf{a} \neq 0\}$$

若方程特解为 \mathbf{x}_0 , 则 $\mathbf{a} \perp (\mathbf{x} - \mathbf{x}_0)$

定义 3 (欧式球(Euclidean ball)).

$$B(\mathbf{x}_c, r) = \{\mathbf{x} \mid \|\mathbf{x} - \mathbf{x}_c\|_2 \leq r\}$$

范数(norm)球可类似定义

定义 4 (椭球(ellipsoid)).

$$\varepsilon(\mathbf{x}_c, P) = \{\mathbf{x} \mid (\mathbf{x} - \mathbf{x}_c)^T P^{-1} (\mathbf{x} - \mathbf{x}_c) \leq 1\}, P \succ 0$$

其中 $P \succ 0$ 表示 P 对称($P = P^T$)且正定, 或记为 $P \in \mathbb{S}_{++}$

分析. 定义内积 $\langle \mathbf{x}^T, P^{-1} \mathbf{y} \rangle$ (需证满足内积条件), 进而 $\|\mathbf{x}\|_p := \sqrt{\mathbf{x}^T P \mathbf{x}}$ 是范数, 而椭球不过是 p -范数意义下的球, 由定理得椭球是凸的

定义 5 (多面体(polyhedron)).

$$P = \{\mathbf{x} \mid \mathbf{a}_i^T \mathbf{x} \leq b_i, \mathbf{c}_j^T \mathbf{x} = d_j, i = 1, \dots, m, j = 1, \dots, p\}$$

例 2. • 空集、点、 \mathbb{R}^n 空间均为仿射

- 任意直线为仿射; 若过原点则为凸锥
- \mathbb{R}^n 空间的子空间³为仿射和凸锥
- 超平面为仿射
- 半空间、欧式球、椭球、多面体为凸集

定义 6 (仿射函数).

$$f: \mathbb{R}^n \mapsto \mathbb{R}^m \quad f(\mathbf{x}) = A\mathbf{x} + \mathbf{b}, A \in \mathbb{R}^{m \times n}, \mathbf{b} \in \mathbb{R}^m$$

性质如下:

- $S \subset \mathbb{R}^n$ 为凸 $\implies f(S) = \{f(\mathbf{x}) \mid \mathbf{x} \in S\}$ 为凸
- $C \subset \mathbb{R}^m$ 为凸 $\implies f^{-1}(C) = \{\mathbf{x} \in \mathbb{R}^n \mid f(\mathbf{x}) \in C\}$ 为凸

³零元、加法封闭、数乘封闭

例 3. 两个集合的和 $S_1 + S_2 = \{\mathbf{x} + \mathbf{y} \mid \mathbf{x} \in S_1, \mathbf{y} \in S_2\}$ 保凸

分析. 直积 $S_1 \times S_2 = \{(\mathbf{x}, \mathbf{y}) \mid \mathbf{x} \in S_1, \mathbf{y} \in S_2\}$ 显然可以保凸 (相当于在两个集合同时画线)

令 $A \leftarrow \begin{bmatrix} I & I \end{bmatrix}, \mathbf{x} \leftarrow \begin{bmatrix} \mathbf{x} & \mathbf{y} \end{bmatrix}^T, \mathbf{b} \leftarrow \mathbf{0}$, 由仿射函数性质得证

定义 7 (透视(perspective)函数⁴). 透视函数 $P: \mathbb{R}^{n+1} \mapsto \mathbb{R}^n, \text{dom } P = \mathbb{R}^n \times \mathbb{R}_{++}$ 定义如下

$$P(\mathbf{z}, t) = \frac{\mathbf{z}}{t}, \mathbf{z} \in \mathbb{R}^n, t \in \mathbb{R}_{++}$$

反透视函数

$$P^{-1}(c) := \left\{ (\mathbf{x}, t) \in \mathbb{R}^{n+1} \mid \frac{\mathbf{x}}{t} \in c, t > 0 \right\}$$

凸集经过透视函数和反透视函数依然是凸集

分析. 考虑 \mathbb{R}^{n+1} 内的线段, $\mathbf{x} = (\tilde{\mathbf{x}} \in \mathbb{R}^n, \mathbf{x}_{n+1} \in \mathbb{R}_{++}), \mathbf{y} = (\tilde{\mathbf{y}}, \mathbf{y}_{n+1})$ 则经过透视函数仍是线段

$$P(\theta \mathbf{x} + (1 - \theta) \mathbf{y}) = \frac{\theta \tilde{\mathbf{x}} + (1 - \theta) \tilde{\mathbf{y}}}{\theta \mathbf{x}_{n+1} + (1 - \theta) \mathbf{y}_{n+1}} = \frac{\theta \mathbf{x}_{n+1}}{\theta \mathbf{x}_{n+1} + (1 - \theta) \mathbf{y}_{n+1}} \frac{\tilde{\mathbf{x}}}{\mathbf{x}_{n+1}} + \frac{(1 - \theta) \mathbf{y}_{n+1}}{\theta \mathbf{x}_{n+1} + (1 - \theta) \mathbf{y}_{n+1}} \frac{\tilde{\mathbf{y}}}{\mathbf{y}_{n+1}}$$

定义 8 (线性分数函数). 仿射函数

$$g(\mathbf{x}) = \begin{bmatrix} A \\ \mathbf{c}^T \end{bmatrix} \mathbf{x} + \begin{bmatrix} \mathbf{b} \\ \mathbf{d} \end{bmatrix}, A \in \mathbb{R}^{m \times n}, \mathbf{b} \in \mathbb{R}^m, \mathbf{c} \in \mathbb{R}^n, \mathbf{d} \in \mathbb{R}$$

线性分数函数 $f: \mathbb{R}^n \mapsto \mathbb{R}^m = p \circ g$

$$f(\mathbf{x}) = \frac{A\mathbf{x} + \mathbf{b}}{\mathbf{c}^T \mathbf{x} + \mathbf{d}}, \text{dom } f = \{\mathbf{x} \mid \mathbf{c}^T \mathbf{x} + \mathbf{d} > 0\}$$

保凸性

- 凸集之交
- 仿射、逆仿射
- 透视函数
- 线性分数函数

3 凸函数

定义 9 (凸函数). 凸函数的几种基本定义如下

1. $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 为凸 $\iff \text{dom } f$ 为凸, 且

$$\forall \mathbf{x}, \mathbf{y} \in \text{dom } f, \theta \in [0, 1]: f(\theta \mathbf{x} + (1 - \theta) \mathbf{y}) \leq \theta f(\mathbf{x}) + (1 - \theta) f(\mathbf{y})$$

- 严格凸: $\theta \in (0, 1)$, 不等式不能取等

⁴+代表 ≥ 0 , ++代表 > 0

- 凹函数：若 $-f$ 为凸

2. 高维定义： $f: \mathbb{R}^n \mapsto \mathbb{R}$ 为凸 $\iff \text{dom } f$ 为凸， 且

$$\forall \mathbf{x} \in \text{dom } f, \mathbf{v} \in \mathbb{R}^n : g(t) := f(\mathbf{x} + t\mathbf{v}) \text{ 为凸, } \text{dom } g = \{t \mid \mathbf{x} + t\mathbf{v} \in \text{dom } f\}$$

相当于每一个剖面上的低维函数都是凸的（固定 \mathbf{x} 和 \mathbf{v} 变化 t 看凸性，则 $\mathbf{x} + t\mathbf{v}$ 在一条直线上/超平面上移动）

3. 一阶条件(*first-order condition*)⁵

$$f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla^T f(\mathbf{x})(\mathbf{y} - \mathbf{x})$$

即 *Taylor* 公式一阶展开

4. 二阶条件： $f: \mathbb{R}^n \mapsto \mathbb{R}$ 为凸 $\iff \text{dom } f$ 为凸， 且

$$\forall \mathbf{x} \in \text{dom } f : \nabla^2 f(\mathbf{x}) \succeq 0$$

- 凹函数： $\nabla^2 f(\mathbf{x}) \preceq 0$
- 严格凸： $\iff \nabla^2 f(\mathbf{x}) \succ 0$ ，反例 $f(x) = x^4$ （在一个点斜率不变并不要紧）

例 4. $f(\mathbf{x}) = \mathbf{a}^T \mathbf{x} + \mathbf{b}$

分析. 有 $\nabla f(\mathbf{x}) = \mathbf{a}$ ，进而

$$f(\mathbf{y}) = \mathbf{a}^T \mathbf{y} + \mathbf{b} \geq \mathbf{a}^T \mathbf{x} + \mathbf{b} + \mathbf{a}^T (\mathbf{y} - \mathbf{x}) = \mathbf{a}^T \mathbf{y} + \mathbf{b}$$

定义 10 (凸函数的扩展(*extended-value*)). 尽管凸函数的定义域为凸，但往往不好处理，那就将其扩展到全空间。 $\mathbf{x} \in \text{dom } f \subset \mathbb{R}^n, \text{dom } \tilde{f} = \mathbb{R}^n$ ，会有

$$\tilde{f}(\mathbf{x}) = \begin{cases} f(\mathbf{x}) & \mathbf{x} \in \text{dom } f \\ +\infty & \mathbf{x} \notin \text{dom } f \end{cases}$$

注意指示/示性(*indicator*)函数不一定是凸的

$$f(\mathbf{x}) = \begin{cases} 0 & \mathbf{x} \in \mathcal{C} \\ +\infty & \mathbf{x} \notin \mathcal{C} \end{cases}$$

定理 1. 若 f 为凸，可微，则 $\exists \mathbf{x} \in \text{dom } f, \nabla f(\mathbf{x}) = 0$

例 5. 二次函数 $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T P \mathbf{x} + \mathbf{q}^T \mathbf{x} + r$, $P \in \mathbb{S}^n$ (对称矩阵), $\mathbf{q} \in \mathbb{R}^n$, $r \in \mathbb{R}$

⁵ $\nabla^T f(\mathbf{x}) = [\nabla f(\mathbf{x})]^T$, $\nabla^2 f(\mathbf{x})$ 为 $f(\mathbf{x})$ 的 Hessian 矩阵，其他关于矩阵微积分的知识请见附录 A 节

分析. $\nabla f(\mathbf{x}) = \frac{1}{2}(P + P^T)\mathbf{x} + \mathbf{q} \implies \nabla^2 f(\mathbf{x}) = P$

故 $P \in \mathbb{S}_+^n$, $f(\mathbf{x})$ 为凸; $P \in \mathbb{S}_{++}^n$, $f(\mathbf{x})$ 严格凸

例 6. $f(x) = \frac{1}{x^2}$, $\text{dom } f = \{x \in \mathbb{R}, x \neq 0\}$

分析. 注意 $\text{dom } f$ 不是凸集

常见的凸函数例子如下

- 仿射函数 $f(x) = ax + b$
- 指数函数 $f(x) = e^{ax}$
- 幂函数 $f(x) = x^a$
- 绝对值的幂函数 $f(x) = |x|^p, x \in \mathbb{R}, p > 0$: $p \in [1, +\infty)$ 凸, $p \in (0, 1)$ 既不凸又不凹

分析.

$$f''(x) = \begin{cases} p(p-1)x^{p-2} & x > 0 \\ p(p-1)(-x)^{p-2} & x < 0 \end{cases}$$

- 对数函数 $f(x) = \log x$
- 熵 $f(x) = -x \log x$
- 极大值函数 $f(x) = \max\{x_1, \dots, x_n\}, x \in \mathbb{R}^n$

例 7. 极大值函数的解析近似⁶是 $f(x) = \log(e^{x_1} + \dots + e^{x_n})$

$$\max\{x_1, \dots, x_n\} \leq f(\mathbf{x}) \leq \max\{x_1, \dots, x_n\} + \log n$$

分析.

$$\begin{aligned} \frac{\partial f}{\partial x_i} &= \frac{e^{x_i}}{e^{x_1} + \dots + e^{x_n}} \\ \frac{\partial^2 f}{\partial x_i \partial x_j} &= \begin{cases} \frac{-e^{x_i} e^{x_j}}{(e^{x_1} + \dots + e^{x_n})^2} & i \neq j \\ \frac{e^{x_i}(e^{x_1} + \dots + e^{x_{i-1}} + e^{x_{i+1}} + \dots + e^{x_n})}{(e^{x_1} + \dots + e^{x_n})^2} & i = j \end{cases} \\ \mathbf{z} &:= \begin{bmatrix} e^{x_1} & \dots & e^{x_n} \end{bmatrix}^T \end{aligned}$$

求 Hessian 矩阵

$$H = \frac{1}{(\mathbf{1}^T \mathbf{z})^2} ((\mathbf{1}^T \mathbf{z}) \text{diag}(\mathbf{z}) - \mathbf{z} \mathbf{z}^T)$$

⁶即无穷阶可微

将前面常量丢弃

$$\begin{aligned}
\mathbf{v}^T H \mathbf{v} &= (\mathbb{1}^T \mathbf{z}) \mathbf{v}^T \text{diag}(\mathbf{z}) \mathbf{v} - \mathbf{v}^T \mathbf{z} \mathbf{z}^T \mathbf{v} \\
&= \left(\sum_i z_i \right) \left(\sum_i v_i^2 z_i \right) - \left(\sum_i v_i z_i \right)^2 \\
&\quad \text{令 } \mathbf{a}_i := \mathbf{v}_i \sqrt{\mathbf{z}_i} = \begin{bmatrix} a_1 & \cdots & a_n \end{bmatrix}^T, b_i := \sqrt{\mathbf{z}_i} \\
&= (\mathbf{b}^T \mathbf{b})(\mathbf{a}^T \mathbf{a}) - (\mathbf{a}^T \mathbf{b})^2 \quad \text{Cauchy} \\
&\geq 0
\end{aligned}$$

由二阶条件知 $f(\mathbf{x})$ 为凸函数

定理 2. \mathbb{R}^n 中的范数都是凸函数 (因而常常用来正则化!)

分析. 由三角不等式

$$\forall \mathbf{x}, \mathbf{y}, \theta \in [0, 1]: \|\theta \mathbf{x} + (1 - \theta) \mathbf{y}\| \leq \|\theta \mathbf{x}\| + \|(1 - \theta) \mathbf{y}\| \leq \theta \|\mathbf{x}\| + (1 - \theta) \|\mathbf{y}\|$$

例 8. 行列式的对数 $f(\mathbf{x}) = \log \det(\mathbf{x})$, $\text{dom } f = \mathbb{S}_{++}^n$, $n = 1$ 凹函数, 证明 $n > 1$ 也为凹

分析. 用高维定义

$$\begin{aligned}
g(t) &:= f(\mathbf{z} + t\mathbf{v}) \\
&= \log \det(\mathbf{z} + t\mathbf{v}) \\
&= \log \det(\mathbf{z}^{1/2} (I + t\mathbf{z}^{-1/2} \mathbf{v} \mathbf{z}^{-1/2}) \mathbf{z}^{1/2}), \quad \mathbf{z}^{1/2} \in \mathbb{S}_{++}^n, \mathbf{z}^{1/2} \mathbf{z}^{1/2} = \mathbf{z} \\
&= \log \det(\mathbf{z}) + \log \det(I + t\mathbf{z}^{-1/2} \mathbf{v} \mathbf{z}^{-1/2}) \\
&= \log \det(\mathbf{z}) + \sum_{i=1}^n \log(1 + t\lambda_i), \quad \lambda_i \text{ 为 } \mathbf{z}^{-1/2} \mathbf{v} \mathbf{z}^{-1/2} \text{ 的特征值}
\end{aligned}$$

$$\begin{aligned}
g'(t) &= \sum_{i=1}^n \frac{\lambda_i}{1 + t\lambda_i} \\
g''(t) &= \sum_{i=1}^n -\frac{\lambda_i^2}{(1 + t\lambda_i)^2}
\end{aligned}$$

补充证明: 对对称阵进行特征值分解 $t\mathbf{z}^{-1/2} \mathbf{v} \mathbf{z}^{-1/2} = tQ\Lambda Q^T$, 对角阵 Λ 即为 $QQ^T = I$, Q 为酉矩阵

$$\begin{aligned}
I + t\mathbf{z}^{-1/2} \mathbf{v} \mathbf{z}^{-1/2} &= QQ^T + tQ\Lambda Q^T = Q(I + t\Lambda)Q^T \\
\log \det(I + t\mathbf{z}^{-1/2} \mathbf{v} \mathbf{z}^{-1/2}) &= \log \det(Q) + \log \det(I + t\Lambda) + \log \det(Q^T)
\end{aligned}$$

保持函数凸性

- 非负加权和 f_1, \dots, f_m 为凸, 定义域 \mathbb{R}^n

$$f := \sum_{i=1}^m w_i f_i, w_i \geq 0$$

- 非负积分 $f(x, y)$ 对 $y \in A$ 均为凸 (A 不一定为凸), $w(y) \geq 0$

$$g(x) := \int_{y \in A} w(y) f(x, y) dy$$

- 仿射映射 $f: \mathbb{R}^n \mapsto \mathbb{R}$ 为凸, $A \in \mathbb{R}^{m \times n}, \mathbf{b} \in \mathbb{R}^m, \text{dom } g = \{\mathbf{x} \mid A\mathbf{x} + \mathbf{b} \in \text{dom } f\}$

$$g(\mathbf{x}) := f(A\mathbf{x} + \mathbf{b})$$

分析. — $\text{dom } f$ 为凸, 则 $\text{dom } g$ 为凸

$$- \forall \mathbf{x}, \mathbf{y} \in \text{dom } g, \forall \theta \in [0, 1]$$

$$\begin{aligned} g(\theta \mathbf{x} + (1 - \theta) \mathbf{y}) &= f(A(\theta \mathbf{x} + (1 - \theta) \mathbf{y}) + \mathbf{b}) \\ &= f(\theta(A\mathbf{x} + \mathbf{b}) + (1 - \theta)(A\mathbf{y} + \mathbf{b})) \\ &\leq \theta f(A\mathbf{x} + \mathbf{b}) + (1 - \theta) f(A\mathbf{y} + \mathbf{b}) \\ &= \theta g(\mathbf{x}) + (1 - \theta) g(\mathbf{y}) \end{aligned}$$

— 其实只是在定义域上改变, 而不是改变值域, 因而函数凸性不会改变

- 两个函数的极大值函数, f_1, f_2 为凸

$$f(x) := \max\{f_1(x), f_2(x)\}, \text{dom } f = \text{dom } f_1 \cap \text{dom } f_2$$

- 任意个凸函数极大值函数为凸

$$f(x) = \max\{\mathbf{a}_1^T \mathbf{x} + \mathbf{b}_1, \dots, \mathbf{a}_m^T \mathbf{x} + \mathbf{b}_m\}$$

- 无限个凸函数, $y \in A, f(x, y)$ 对于 x 为凸, 则 $g(x) = \sup_{y \in A} f(x, y)$ 为凸

例 9. 点 x 到集合 C 的最远距离

$$f(x) = \sup_{y \in A} \|x - y\|$$

位移对于范数凸性不会有影响

例 10. $\mathbf{x} \in \mathbb{R}^n, x[i]$ 为第 i 大元素, $x[1] \geq x[2] \geq \dots \geq x[r] \geq \dots \geq x[n]$

$$f(\mathbf{x}) := \sum_{i=1}^r x[i]$$

— $r = 1$: $f(\mathbf{x}) = x[1] = \max\{x_1, \dots, x_n\}$, 每一项都是 $\mathbf{e}_i^T \mathbf{x}$

— $r > 1$: $f(\mathbf{x}) = \max\{x_{i_1} + \dots + x_{i_r} \mid 1 \leq i_1 < i_2 < \dots < i_r \leq n\}$

- 函数的组合: $h: \mathbb{R}^k \mapsto \mathbb{R}, g: \mathbb{R}^n \mapsto \mathbb{R}^k$

$$f := h \circ g: \mathbb{R}^n \mapsto \mathbb{R}$$

先考虑 $n = k = 1, \text{dom } g = \mathbb{R}^n, \text{dom } h = \mathbb{R}^k, \text{dom } f = \mathbb{R}, h, g$ 二阶可微

$$f'(x) = h'(g(x)) \cdot g'(x)$$

$$f''(x) = h''(g(x))(g'(x))^2 + h'(g(x))g''(x) > 0$$

即当 g 为凸, h 为凸且不降; g 为凹, h 为凸且不增时, $f(x)$ 为凸

(若定义域非全空间) 当 g 为凸, h 为凸, 扩展值函数 \tilde{h} 不降; g 为凹, h 为凸, \tilde{h} 不增时, $f(x)$ 为凸

例 11. g 为凸, $\exp g(x)$ 为凸; g 为凹, $g > 0$, $\log g(x)$ 为凹; g 为凸, $g > 0$, $1/g(x)$ 为凸

例 12. $g(x) = x^2, \text{dom } g = \mathbb{R}, h(y) = 0, \text{dom } h = [1, 2], f = h \circ g$, 注意 \tilde{h} 并非不降!

- 函数透视: $P: \mathbb{R}^{n+1} \mapsto \mathbb{R}^n, \text{dom } P \in \mathbb{R}^n \times \mathbb{R}_{++}, P(z, t) = \frac{z}{t}$

$$f: \mathbb{R}^n \mapsto \mathbb{R}, g(x, t) = tf\left(\frac{x}{t}\right), \text{dom } g = \{(x, t) \mid \frac{x}{t} \in \text{dom } f\}, g: \mathbb{R}^n \times \mathbb{R}_{++} \mapsto \mathbb{R}$$

若 $f(x)$ 为凸, 则 $g(x, t)$ 相对于 (x, t) 联合凸

例 13. — $f(x) = x^T x, g(x, t) = x^T x/t$

— $f(x) = -\log x, g(x, t) = t \log(t/x)$

— $u, v \in \mathbb{R}_{++}^n, g(u, v) = \sum_{i=1}^n u_i \log(u_i/v_i)$, 信息论常用, 衡量相似性, KL 散度

$$D_{KL} := \sum_{i=1}^n \left(u_i \log \frac{u_i}{v_i} - u_i + v_i \right)$$

定义 11 (α 次水平集(α -sub level set)). $f: \mathbb{R}^n \mapsto \mathbb{R}, C_\alpha = \{\mathbf{x} \in \text{dom } f \mid f(\mathbf{x}) \leq \alpha\}$

定义 12 (拟凸函数(quasi-convex)). α 次水平集为凸集 $\iff f$ 为拟凸函数

拟凸函数有很好的性质 \rightarrow 单模态/单峰函数

凸函数与凸集联系

- 凸函数定义域为凸集
- 凸函数的 α 次水平集为凸集

4 凸优化问题

4.1 标准型

广义定义：极小化凸函数，约束为凸集

$$\begin{aligned} & \text{minimize} && f_0(\mathbf{x}) \\ & \text{subject to} && f_i(\mathbf{x}) \leq 0 \quad i = 1, \dots, m \\ & && h_j(\mathbf{x}) = 0 \quad j = 1, \dots, p \end{aligned}$$

- 优化变量 $\mathbf{x} \in \mathbb{R}^n$
- 目标/损失函数 $f_0 : \mathbb{R}^n \mapsto \mathbb{R}$
- 不等式约束函数 $f_i : \mathbb{R}^n \mapsto \mathbb{R}$
- 等式约束函数 $h_j : \mathbb{R}^n \mapsto \mathbb{R}$
- 域 $\mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{j=1}^p \text{dom } h_j$
- 可行解 $\mathcal{X} = \{\mathbf{z} \mid f_i(\mathbf{z}) \leq 0, h_j(\mathbf{z}) = 0, i = 1, \dots, m, j = 1, \dots, p\}$
- 最优值 $P^* = \inf\{f_0(\mathbf{x}) \mid \mathbf{x} \in \mathcal{X}\}$
- 最优解 $\mathbf{x}^* \iff \forall \mathbf{z} \in \mathbb{R}^n, \mathbf{z} \in \mathcal{X} : f_0(\mathbf{z}) \geq f_0(\mathbf{x}^*)$
- 最优解集 $X^* = \{\mathbf{x}^* \mid f_0(\mathbf{x}^*) = P^*, \mathbf{x}^* \in \mathcal{S}\}$
- ε -次优解集 $X_\varepsilon = \{\mathbf{x} \mid f_0(\mathbf{x}) \leq P^* + \varepsilon, \mathbf{x} \in \mathcal{X}\}$
- 局部最优 $\exists R > 0, f_0(\mathbf{x}) = \inf\{f_0(\mathbf{z}) \mid \mathbf{x} \in \mathcal{X}, \mathbf{z} \in \mathcal{X}, \|\mathbf{x} - \mathbf{z}\| \leq R\}$ ，即邻域内下确界
- 局部最优解集 $x_{local} = \{\mathbf{x} \mid \mathbf{x} \text{ 为局部最优}\}$

狭义定义： $f_i(\mathbf{x}), i = 0, 1, \dots$ 为凸函数， $h_i(\mathbf{x})$ 为仿射函数

例 14.

$$\begin{aligned} \min & f_0(x) = x_1^2 + x_2^2 \\ \text{s.t.} & f_1(x) = \frac{x_1}{1+x_2^2} \leq 0 \implies x_1 \leq 0 \\ & h_1(x) = (x_1 + x_2)^2 = 0 \implies x_1 + x_2 = 0 \end{aligned}$$

定理 3. 凸问题局部最优等价于全局最优

分析. 若 \mathbf{x} 为局部最优

$$\exists R > 0 : f_0(\mathbf{x}) = \inf\{f_0(\mathbf{z}) \mid \mathbf{z} \in \mathcal{X}, \mathbf{x} \in \mathcal{X}, \|\mathbf{x} - \mathbf{z}\|_2 \leq R\}$$

反证法，设 \mathbf{x} 不是全局最优， \mathbf{y} 为全局最优，即 $f_0(\mathbf{x}) > f_0(\mathbf{y})$

取 $\mathbf{z} = \theta \mathbf{x} + (1 - \theta) \mathbf{y}$ 为 \mathbf{x}, \mathbf{y} 连线上一点, 令 $\theta = \frac{R}{2\|\mathbf{y} - \mathbf{x}\|_2}$, 使 \mathbf{z} 能够落在 \mathbf{x} 的邻域内

$$\|\mathbf{z} - \mathbf{x}\|_2 = \frac{R\|\mathbf{y} - \mathbf{x}\|_2}{2\|\mathbf{y} - \mathbf{x}\|_2} = \frac{R}{2}$$

由 $\|\mathbf{z} - \mathbf{x}\|_2 \leq R \implies f_0(\mathbf{x}) \leq f_0(\mathbf{z})$, 又结合 $f_0(\mathbf{x}) > f_0(\mathbf{y})$, 有

$$f_0(\mathbf{z}) \leq \theta f_0(\mathbf{x}) + (1 - \theta) f_0(\mathbf{y}) < \theta f_0(\mathbf{z}) + (1 - \theta) f_0(\mathbf{z}) = f_0(\mathbf{z})$$

左边第一个不等号由凸函数定义, 第二个不等号由推导出的条件, 故矛盾

对于可微凸目标函数 $f_0(\mathbf{x})$, 最优解满足以下条件

- 无约束 $\min f_0(\mathbf{x})$, 只需 $\nabla f_0(\mathbf{x}^*) = 0$

分析. 由凸函数的性质


$$\forall \mathbf{x}, \mathbf{y} : f_0(\mathbf{y}) \geq f_0(\mathbf{x}) + \langle \nabla f_0(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle$$

进而

$$f_0(\mathbf{y}) \geq f_0(\mathbf{x}^*) + \langle \nabla f_0(\mathbf{x}^*), \mathbf{y} - \mathbf{x}^* \rangle = f_0(\mathbf{x}^*)$$

- 有约束 $\min f_0(\mathbf{x}), s.t. \mathbf{x} \in \mathcal{X}$

$$\forall \mathbf{y} \in \mathcal{X} : \langle \nabla f_0(\mathbf{x}^*), \mathbf{y} - \mathbf{x}^* \rangle \geq 0$$



例 15. 等式约束 $\min f_0(\mathbf{x}), \text{dom } f_0 \subset \mathbb{R}^n$, f_0 可微, 使得 $A\mathbf{x} = \mathbf{b}$

分析. \mathbf{x}^* 最优, $A\mathbf{x}^* = \mathbf{b}$, 最优解需满足

$$\forall \mathbf{y}, A\mathbf{y} = \mathbf{b} : \langle \nabla f_0(\mathbf{x}^*), \mathbf{y} - \mathbf{x}^* \rangle \geq 0$$

从而

$$\begin{cases} \mathbf{y} = \mathbf{x}^* + \mathbf{v} \\ A\mathbf{v} = \mathbf{0} \end{cases}, \mathbf{v} \in \text{Nul } A$$

即

$$\forall \mathbf{v} \in \text{Nul } A : \langle \nabla f_0(\mathbf{x}^*), \mathbf{v} \rangle \geq 0$$

那么

1. $\text{Nul } A = \{\mathbf{0}\}$
2. A 不可逆, $\nabla f_0(\mathbf{x}^*) \perp \text{Nul } A$

例 16. 正约束 $\min f_0(\mathbf{x}), s.t. \mathbf{x} \geq \mathbf{0}$

分析. 若 \mathbf{x}^* 最优 $\iff \mathbf{x}^* \geq \mathbf{0}, \forall \mathbf{y} \geq \mathbf{0}, \langle \nabla f_0(\mathbf{x}^*), \mathbf{y} - \mathbf{x}^* \rangle \geq 0 \iff \langle \nabla f_0(\mathbf{x}^*), \mathbf{y} \rangle \geq \langle \nabla f_0(\mathbf{x}^*), \mathbf{x}^* \rangle$

1. 若 $\nabla f_0(\mathbf{x}^*) \not\geq \mathbf{0}$, 则存在矛盾 (负数行乘上正无穷), 故 $\nabla f_0(\mathbf{x}^*) \geq \mathbf{0}$
2. 令 $\mathbf{y} = \mathbf{0}$, 有 $0 \geq \langle \nabla f_0(\mathbf{x}^*), \mathbf{x}^* \rangle \implies \sum_{i=1}^n (\nabla f_0(\mathbf{x}^*))_i x_i^* \leq 0$
前面 ≥ 0 , 进而互补松弛条件
3. $\mathbf{x}^* \geq \mathbf{0}$

4.2 线性规划

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} + \mathbf{d} \\ \text{s.t.} \quad & G\mathbf{x} \leq \mathbf{h} \\ & A\mathbf{x} = \mathbf{b} \end{aligned}$$

例 17 (食谱问题). m 种营养元素不小于 b_1, \dots, b_m , n 种食物, 单位含量 a_{1j}, \dots, a_{mj} , 食物量 x_1, \dots, x_n , 价格 c_1, \dots, c_n

$$\begin{aligned} \min \quad & \sum_{j=1}^n c_j x_j \\ \text{s.t.} \quad & \sum_{j=1}^n a_{ij} x_j \geq b_i \\ & x_j \geq 0 \end{aligned}$$

其中 $i = 1, \dots, m, j = 1, \dots, n$

例 18 (线性分数规划).

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) = \frac{\mathbf{c}^T \mathbf{x} + d}{\mathbf{e}^T \mathbf{x} + f}, \text{dom } \mathbf{f} = \{\mathbf{x} \mid \mathbf{e}^T \mathbf{x} + f > 0\} \\ \text{s.t.} \quad & G\mathbf{x} \leq \mathbf{h} \\ & A\mathbf{x} = \mathbf{b} \end{aligned}$$

等价于

$$\begin{aligned}
 \min \quad & \mathbf{c}^T \mathbf{y} + dz \\
 \text{s.t.} \quad & G\mathbf{y} - hz \leq 0 \\
 & A\mathbf{y} - bz = 0 \\
 & \mathbf{e}^T \mathbf{y} + fz = 1 \\
 & z \geq 0
 \end{aligned}$$

分析. 证明两个问题等价, P_0 与 P_1

若 \mathbf{x} 在 P_0 内可行

$$\mathbf{y} = \frac{\mathbf{x}}{\mathbf{e}^T \mathbf{x} + f}, z = \frac{1}{\mathbf{e}^T \mathbf{x} + f}$$

若 (\mathbf{y}, z) 在 P_1 中可行

$$\mathbf{x} = \frac{\mathbf{y}}{z} (z \neq 0)$$

若 $z = 0$, \mathbf{x}_0 为 P_0 的可行解

$$\begin{aligned}
 \mathbf{x} &= \mathbf{x}_0 + t\mathbf{y}, t \geq 0 \\
 \lim_{t \rightarrow \infty} \frac{\mathbf{c}^T(\mathbf{x}_0 + t\mathbf{y}) + d}{\mathbf{e}^T(\mathbf{x}_0 + t\mathbf{y}) + f} &= \mathbf{c}^T \mathbf{y}
 \end{aligned}$$

代入看所有条件结论都相同

4.3 二次规划

二次规划(Quadratic Programming)

$$\begin{aligned}
 \min \quad & \frac{1}{2} \mathbf{x}^T P \mathbf{x} + \mathbf{q}^T \mathbf{x} + r, P \succ 0 \\
 \text{s.t.} \quad & G\mathbf{x} \leq h \\
 & A\mathbf{x} = \mathbf{b}
 \end{aligned}$$

二次约束二次规划(QCQP)

$$\begin{aligned}
 \min \quad & \frac{1}{2} \mathbf{x}^T P_0 \mathbf{x} + \mathbf{q}_0^T \mathbf{x} + r_0, P_0 \succ 0 \\
 \text{s.t.} \quad & \frac{1}{2} \mathbf{x}^T P_i \mathbf{x} + \mathbf{q}_i^T \mathbf{x} + r_i \leq 0, i = 1, \dots, m, P_i \succ 0 \\
 & A\mathbf{x} = \mathbf{b}
 \end{aligned}$$

例 19 (最小二乘问题).

$$\begin{aligned} \min_{\mathbf{x}} \quad & \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 \\ \text{s.t.} \quad & \mathbf{Ax} + \mathbf{e} = \mathbf{b} \end{aligned}$$

分析. 一范数规范化最小二乘

$$\min \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

本来用零范数, 但用一范数拟合, 改写

$$\|\mathbf{x}\|_1 = \mathbb{1}^T \mathbf{x}^+ + \mathbb{1}^T \mathbf{x}^-$$

Basic Pursuit

$$\begin{aligned} \min \quad & \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 \\ \text{s.t.} \quad & \|\mathbf{x}\|_1 \leq \varepsilon_1 \end{aligned}$$

原式很难平衡两者, 下式只需考虑 $\|\mathbf{x}\|_1$ 的影响

采用岭回归 (*Ridge*): 所有 \mathbf{x} 差距不要太大

$$\min \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + \frac{1}{2} \lambda_2 \|\mathbf{x}\|_2^2$$

$$\begin{aligned} \min \quad & \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 \\ \text{s.t.} \quad & \|\mathbf{x}\|_2^2 \leq \varepsilon_2 \end{aligned}$$

例 20 (投资组合问题(portfolio optimization)). 初始价格 x_1, \dots, x_n , 最终价格 $P_1 x_1, \dots, P_n x_n$

$$\begin{aligned} \max \quad & P_1 x_1 + \dots + P_n x_n \\ \text{s.t.} \quad & x_1 + \dots + x_n = B \\ & x_1, \dots, x_n \geq 0 \end{aligned}$$

分析. $\bar{P} = \mathbb{E}(P)$ 已知, $\Sigma = \mathbb{D}(P)$

$$\begin{aligned} \min \quad & \mathbf{x}^T \Sigma \mathbf{x} \\ \text{s.t.} \quad & \mathbf{p}^T \mathbf{x} \geq r_{\min} \\ & x_1 + \dots + x_n = B \\ & x_1, \dots, x_n \geq 0 \end{aligned}$$

4.4 半定规划

半定规划(semi-definite programming, SDP)为矩阵意义下的线性规划问题: $X \in \mathbb{R}^{n \times n}, C \in \mathbb{R}^{n \times n}, A_i \in \mathbb{R}^{n \times n}, b_i \in \mathbb{R}$

$$\begin{aligned} \min \quad & \text{tr}(CX) \\ \text{s.t.} \quad & \text{tr}(A_i X) = b_i, i = 1, \dots, p \\ & X \succeq 0 \end{aligned}$$

例 21 (谱范数极小化问题). 矩阵多项式 $A(\mathbf{x}) = A_0 + x_1 A_1 + \dots + x_n A_n, A_i \in \mathbb{R}^{p \times q}$

$$\min_{\mathbf{x}} \|A(\mathbf{x})\|_2$$

谱范数代表 $A(\mathbf{x})$ 的最大奇异值⁷

$$\begin{aligned} \min_{x, s} \quad & S \\ \text{s.t.} \quad & A^T(\mathbf{x})A(\mathbf{x}) \preceq SI \end{aligned}$$

例 22 (最快分布式线性平均).

$$\begin{aligned} \mathbf{x}(t) &= P\mathbf{x}(t-1) \\ P &= \begin{bmatrix} P_{11} & \cdots & P_{1n} \\ \vdots & \ddots & \vdots \\ P_{n1} & \cdots & P_{nn} \end{bmatrix}, P\mathbf{1} = \mathbf{1} \end{aligned}$$

其中 $(i, j) \in E$ 或 $i = j, P_{ij} \neq 0$; 否则 $P_{ij} = 0$

$P = P^T, P_{ij} = P_{ji}, P_{ij} > 0, P \succeq 0, P_{ij} \geq 0$

只要图是连通图, 则一定会收敛

收敛速度与第二大/特征值绝对值/有关

$$1 = \lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq -1$$

即收敛速度由 $\max\{|\lambda_2|, |\lambda_n|\}$ 决定

$$\begin{aligned} \min \max\{|\lambda_2|, |\lambda_n|\} \\ \max\{|\lambda_2|, |\lambda_n|\} = \left\| P - \frac{1}{n} \mathbf{1} \mathbf{1}^T \right\| \end{aligned}$$

⁷谱范数是诱导范数, F-范数(Frobenias) $\|A(\mathbf{x})\|_F$ 才算是矩阵意义下的2范数

$$\begin{aligned}
\min \quad & t := \left\| P - \frac{1}{n} \mathbb{1} \mathbb{1}^T \right\|_2 \\
\text{s.t.} \quad & P \mathbb{1} = \mathbb{1} \\
& P = P^T \\
& P \succeq 0 \\
& P_{ij} = 0, \quad (i, j) \neq E \wedge i \neq j \\
& -tI \preceq P - \frac{1}{n} \mathbb{1} \mathbb{1}^T \preceq tI
\end{aligned}$$

4.5 多目标优化问题

帕累托最优解：若有另一解在某个指标上更好，则必有指标更差

帕累托最优值/帕累托最优面

$\min f_{01}$ 与 $\min f_{02}$ 的交点为理想点(oracle)

若 $f_{01}(x), \dots, f_{0q}(x)$ 为凸， \mathcal{X} 为凸

$$\begin{aligned}
\min \quad & \lambda_1 f_{01}(x) + \dots + \lambda_q f_{0q}(x), \quad \lambda_1, \dots, \lambda_q \geq 0 \\
\text{s.t.} \quad & x \in \mathcal{X}
\end{aligned}$$

1. 能找到一个Pareto最优解
2. 遍历 $\lambda_1, \dots, \lambda_q$ ，可找到全部

岭回归的多目标优化表示

$$\begin{cases} \min \frac{1}{2} \|Ax - b\|_2^2 \\ \min \frac{1}{2} \|x\|_2^2 \end{cases}$$

5 对偶理论

5.1 拉格朗日对偶

定义 13 (拉格朗日函数(Lagrangian function)). $f_i(\mathbf{x})$ 和 $h_j(\mathbf{x})$ 含义同 4.1 节，前者不等式约束，后者等式约束。

$$\begin{aligned}
L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) &= f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p v_i h_i(\mathbf{x}) \\
&= f_0(\mathbf{x}) + \boldsymbol{\lambda}^T \mathbf{f}(\mathbf{x}) + \mathbf{v}^T \mathbf{h}(\mathbf{x}), \quad \text{dom } L = \mathcal{D} \times \mathbb{R}^m \times \mathbb{R}^p
\end{aligned}$$

定义 14 (拉格朗日乘子(multiplier)). 包括原变量和对偶变量

- 原变量(*primal variable*): $\boldsymbol{\lambda} = \begin{bmatrix} \lambda_1 & \dots & \lambda_m \end{bmatrix}^T$
- 对偶变量(*dual variable*): $\mathbf{v} = \begin{bmatrix} v_1 & \dots & v_p \end{bmatrix}^T$

定义 15 (拉格朗日对偶函数).

$$\begin{aligned} g(\boldsymbol{\lambda}, \mathbf{v}) &= \inf_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) \\ &= \inf_{\mathbf{x} \in \mathcal{D}} \left(f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) + \sum_{i=1}^p v_i h_i(\mathbf{x}) \right) \end{aligned}$$

注意遍历域是 $\mathcal{D} = \bigcap_{i=0}^m \text{dom } f_i \cap \bigcap_{i=1}^p \text{dom } h_i$, 而不是可行解集 \mathcal{X} 。

有以下两点性质:

- $g(\boldsymbol{\lambda}, \mathbf{v})$ 一定是关于 $\boldsymbol{\lambda}$ 和 \mathbf{v} 的凹函数 (关于 $\boldsymbol{\lambda}$ 和 \mathbf{v} 的仿射函数, 注意 \mathbf{x} 为常数)
- $\forall \boldsymbol{\lambda} \geq 0, \forall \mathbf{v} : g(\boldsymbol{\lambda}, \mathbf{v}) \leq p^*$

定义 16 (对偶(dual)问题).

$$\begin{aligned} \max \quad & g(\boldsymbol{\lambda}, \mathbf{v}) \\ \text{s.t.} \quad & \boldsymbol{\lambda} \geq 0 \end{aligned}$$

其最优解记为 \mathbf{d}^* , 则 $\mathbf{d}^* \leq \mathbf{p}^*$, 即给出了原问题(*primal*)的一个最优下界

分析. 记 \mathbf{x}^* 为原问题最优解, 由优化问题定义有

$$\sum_{i=1}^m \lambda_i f_0(\mathbf{x}^*) + \sum_{i=1}^p v_i h_i(\mathbf{x}^*) \leq 0$$

又 $P^* = f_0(\mathbf{x}^*)$ 为原问题最优解

$$L(\mathbf{x}^*, \boldsymbol{\lambda}, \mathbf{v}) = f_0(\mathbf{x}^*) + \left(\sum_{i=1}^m \lambda_i f_0(\mathbf{x}^*) + \sum_{i=1}^p v_i h_i(\mathbf{x}^*) \right) \leq \mathbf{p}^*$$

进而推出

$$g(\boldsymbol{\lambda}, \mathbf{v}) = \inf_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) \leq L(\mathbf{x}^*, \boldsymbol{\lambda}, \mathbf{v}) \leq \mathbf{p}^*$$

例 23 (最小二乘).

$$\begin{aligned} \min \quad & \|\mathbf{x}\|_2 = \mathbf{x}^T \mathbf{x} \\ \text{s.t.} \quad & A\mathbf{x} = \mathbf{b} \end{aligned}$$

分析.

$$L(\mathbf{x}, \mathbf{v}) = \mathbf{x}^T \mathbf{x} + \mathbf{v}^T (A\mathbf{x} - \mathbf{b})$$

$$\begin{aligned} g(\mathbf{v}) &= \inf_{\mathbf{x} \in \mathcal{D}} L(\mathbf{x}, \mathbf{v}) \\ &= \inf_{\mathbf{x} \in \mathcal{D}} (\mathbf{x}^T \mathbf{x} + \mathbf{v}^T A\mathbf{x} - \mathbf{v}^T \mathbf{b}) \quad \text{求最小值相当于求导/求梯度代入} \\ &= \left(-\frac{A^T \mathbf{v}}{2} \right)^T \left(-\frac{A^T \mathbf{v}}{2} \right) + \mathbf{v}^T A \left(-\frac{A^T \mathbf{v}}{2} \right) - \mathbf{v}^T \mathbf{b} \\ &= -\frac{1}{4} \mathbf{v}^T A A^T \mathbf{v} - \mathbf{b}^T \mathbf{v} \end{aligned}$$

$$\text{补充求梯度: } \nabla_{\mathbf{x}} L(\mathbf{x}, \mathbf{v}) = 2\mathbf{x} + (\mathbf{v}^T A)^T = 0 \implies \mathbf{x} = -\frac{A^T \mathbf{v}}{2}$$

因而得到对偶问题

$$\max_{\mathbf{v}} \left(-\frac{1}{4} \mathbf{v}^T A A^T \mathbf{v} - \mathbf{b}^T \mathbf{v} \right)$$

例 24 (标准线性规划).

$$\begin{aligned} \min \quad & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} \quad & A\mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq 0 \end{aligned}$$

分析. 1° 注意 λ 前面符号, 要化为一般形式

$$L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) = \mathbf{c}^T \mathbf{x} - \boldsymbol{\lambda}^T \mathbf{x} + \mathbf{v}^T (A\mathbf{x} - \mathbf{b})$$

$$\begin{aligned} g(\boldsymbol{\lambda}, \mathbf{v}) &= \inf_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) \\ &= \inf_{\mathbf{x}} (\mathbf{c} - \boldsymbol{\lambda} + A^T \mathbf{v})^T \mathbf{x} - \mathbf{v}^T \mathbf{b} \\ &= \begin{cases} -\infty & \mathbf{c} - \boldsymbol{\lambda} + A^T \mathbf{v} \neq 0 \\ -\mathbf{v}^T \mathbf{b} & \mathbf{c} - \boldsymbol{\lambda} + A^T \mathbf{v} = 0 \end{cases} \end{aligned}$$

由于要极大, 故不考虑负无穷部分, 得到对偶问题如下

$$\begin{aligned} \max_{\boldsymbol{\lambda}, \mathbf{v}} \quad & -\mathbf{v}^T \mathbf{b} \\ \text{s.t.} \quad & \mathbf{c} - \boldsymbol{\lambda} + A^T \mathbf{v} = 0 \\ & \boldsymbol{\lambda} \geq 0 \end{aligned}$$

2° 考虑对偶问题的对偶, 先将对偶问题变为极小化问题

$$\begin{aligned} \min \quad & \mathbf{b}^T \mathbf{v} \\ \text{s.t.} \quad & A^T \mathbf{v} + \mathbf{c} \geq 0 \end{aligned}$$

$$L(\mathbf{v}, \boldsymbol{\lambda}) = \mathbf{b}^T \mathbf{v} - \boldsymbol{\lambda}^T (A^T \mathbf{v} + \mathbf{c})$$

$$\begin{aligned} g(\boldsymbol{\lambda}) &= \inf_{\mathbf{v}} L(\mathbf{v}, \boldsymbol{\lambda}) \\ &= \inf (\mathbf{b} - A\boldsymbol{\lambda})^T \mathbf{v} - \boldsymbol{\lambda}^T \mathbf{c} \\ &= \begin{cases} -\boldsymbol{\lambda}^T \mathbf{c} & \mathbf{b} - A\boldsymbol{\lambda} = 0 \\ -\infty & \mathbf{b} - A\boldsymbol{\lambda} \neq 0 \end{cases} \end{aligned}$$

得到新的对偶问题

$$\begin{aligned} \max \quad & -\boldsymbol{\lambda}^T \mathbf{c} \\ \text{s.t.} \quad & \mathbf{b} - A\boldsymbol{\lambda} = 0 \\ & \boldsymbol{\lambda} \geq 0 \end{aligned}$$

对偶的对偶不一定回去，线性规划才满足

例 25 (二路分划(two-way partitioning)). 非凸问题，考虑可行解集有 2^n 个离散点，将 $\{1, \dots, n\}$ 分划到两个集合中， W_{ij} 是将 i, j 指派到同一个集合的开销， $-W_{ij}$ 是将 i, j 指派到不同集合的开销

$$\begin{aligned} \min \quad & \mathbf{x}^T W \mathbf{x} \\ \text{s.t.} \quad & x_i = \pm 1, \quad i = 1, \dots, n \end{aligned}$$

分析. 变为平方等式约束

$$\begin{aligned} L(\mathbf{x}, \mathbf{v}) &= \mathbf{x}^T W \mathbf{x} + \sum_{i=1}^n v_i (x_i^2 - 1) \\ g(\mathbf{v}) &= \inf_{\mathbf{x}} L(\mathbf{x}, \mathbf{v}) \\ &= \inf_{\mathbf{x}} \left(\mathbf{x}^T W \mathbf{x} + \sum_{i=1}^n v_i x_i^2 - \sum_{i=1}^n v_i \right) \\ &= \inf_{\mathbf{x}} \left(\mathbf{x}^T (W + \text{diag } \mathbf{v}) \mathbf{x} - \mathbb{1}^T \mathbf{v} \right) \\ &= \begin{cases} -\mathbb{1}^T \mathbf{v} & W + \text{diag}(\mathbf{v}) \succeq 0 \\ -\infty & \text{otherwise} \end{cases} \end{aligned}$$

其中

$$\text{diag } \mathbf{v} = \begin{bmatrix} v_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & v_n \end{bmatrix}$$

得到对偶问题如下

$$\begin{aligned} \max_{\mathbf{v}} \quad & -\mathbb{1}^T \mathbf{v} \\ \text{s.t.} \quad & W + \text{diag}(\mathbf{v}) \succeq 0 \end{aligned}$$

定义 17 (函数的共轭(conjugate)). $f : \mathbb{R}^n \mapsto \mathbb{R}, f^*(\mathbf{y}) = \sup_{\mathbf{x} \in \text{dom } f} (\mathbf{y}^T \mathbf{x} - f(\mathbf{x}))$, 几何意义即到不同斜率直线的距离最大值, 例子如最大熵

$$f_0(\mathbf{x}) = \sum_{i=1}^n x_i \log x_i, \quad f_0^*(\mathbf{y}) = \sum_{i=1}^n e^{y_i - 1}$$

例 26 (共轭函数).

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & A\mathbf{x} \leq \mathbf{b} \\ & C\mathbf{x} = \mathbf{d} \end{aligned}$$

分析.

$$\begin{aligned} L(\mathbf{x}, \boldsymbol{\lambda}, \mathbf{v}) &= f_0(\mathbf{x}) + \boldsymbol{\lambda}^T (A\mathbf{x} - \mathbf{b}) + \mathbf{v}^T (C\mathbf{x} - \mathbf{d}) \\ &= f_0(\mathbf{x}) + (A^T \boldsymbol{\lambda} + C^T \mathbf{v})^T \mathbf{x} - \boldsymbol{\lambda}^T \mathbf{b} - \mathbf{v}^T \mathbf{d} \\ g(\boldsymbol{\lambda}, \mathbf{v}) &= \inf_{\mathbf{x}} (f_0(\mathbf{x}) + (A^T \boldsymbol{\lambda} + C^T \mathbf{v})^T \mathbf{x} - \boldsymbol{\lambda}^T \mathbf{b} - \mathbf{v}^T \mathbf{d}) \\ &= -\sup_{\mathbf{x}} ((A^T \boldsymbol{\lambda} + C^T \mathbf{v})^T \mathbf{x} - f_0(\mathbf{x})) - \boldsymbol{\lambda}^T \mathbf{b} - \mathbf{v}^T \mathbf{d} \\ &= -f_0^*(-(A^T \boldsymbol{\lambda} + C^T \mathbf{v})) - \boldsymbol{\lambda}^T \mathbf{b} - \mathbf{v}^T \mathbf{d} \end{aligned}$$

5.2 强弱对偶

定义 18 (对偶间隙(duality gap)). $\mathbf{p}^* - \mathbf{d}^* \geq 0$

- 弱对偶: 严格大于 0
- 强对偶: 对偶间隙为 0

1. 对于非凸问题, 通常 $\mathbf{p}^* \neq \mathbf{d}^*$
2. 对于凸问题, 若 Slater 条件满足, $\mathbf{p}^* = \mathbf{d}^*$

定义 19 (相对内点(relative interior)).

$$\text{relint } \mathcal{D} = \{\mathbf{x} \in \mathcal{D} \mid B(\mathbf{x}, r) \cap \text{aff } \mathcal{D} \subset \mathcal{D}, \exists r > 0\}$$

定理 4 (Slater 条件). 强对偶对于下列凸问题成立

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & A\mathbf{x} = \mathbf{b} \end{aligned}$$

若它严格可行, 即

$$\exists \mathbf{x} \in \text{relint } \mathcal{D}, \text{ s.t. } f_i(\mathbf{x}) < 0, \quad i = 1, \dots, m, \quad A\mathbf{x} = \mathbf{b}$$

例 27. 二次规划(QP)

$$\begin{aligned} \min \quad & \mathbf{x}^T \mathbf{x} \\ \text{s.t.} \quad & A\mathbf{x} = \mathbf{b} \end{aligned}$$

Slater条件 $\{\mathbf{x} \mid A\mathbf{x} = \mathbf{b}\}$ 非空

例 28 (二次约束二次规划(QCQP)).

$$\begin{aligned} \min \quad & \frac{1}{2} \mathbf{x}^T P_0 \mathbf{x} + \mathbf{q}_0^T \mathbf{x} + r_0 \\ \text{s.t.} \quad & \frac{1}{2} \mathbf{x}^T P_i \mathbf{x} + \mathbf{q}_i^T \mathbf{x} + r_i \leq 0, \quad i = 1, \dots, m \end{aligned}$$

P_0, \dots, P_m 半正定

凸问题+Slater条件 $\implies \mathbf{p}^* = \mathbf{d}^*$, 但有可能不满足Slater条件也依然强对偶

例 29.

$$\begin{aligned} \min \quad & x, \quad x \in \mathbb{R} \\ \text{s.t.} \quad & x \leq 0 \\ & -x \leq 0 \end{aligned}$$

分析.

$$\begin{aligned} L(x, \lambda_1, \lambda_2) &= x + \lambda_1 x - \lambda_2 x = (1 + \lambda_1 - \lambda_2)x \\ g(\lambda_1, \lambda_2) &= \inf_{x \in \mathbb{R}} (1 + \lambda_1 - \lambda_2)x = \begin{cases} 0 & 1 + \lambda_1 - \lambda_2 = 0 \\ -\infty & \text{otherwise} \end{cases} \end{aligned}$$

得到对偶问题

$$\begin{aligned} \max_{\lambda_1, \lambda_2} \quad & 0 \\ \text{s.t.} \quad & 1 + \lambda_1 - \lambda_2 = 0 \end{aligned}$$

可以推出 $\mathbf{p}^* = \mathbf{d}^* = 0$

例 30 (置信域问题).

$$\begin{aligned} \min \quad & \mathbf{x}^T A \mathbf{x} + \mathbf{b}^T \mathbf{x} \\ \text{s.t.} \quad & \mathbf{x}^T \mathbf{x} \leq 1 \\ & A \not\preceq 0 \end{aligned}$$

依然可以得到 $\mathbf{p}^* = \mathbf{d}^*$

5.3 对偶问题的几种解释


5.3.1 几何解释

考虑问题只有一个约束 $f_1(\mathbf{x}) \leq 0$ ，记 $\mathcal{G} = \{(f_1(\mathbf{x}), f_0(\mathbf{x})) \mid \mathbf{x} \in \mathcal{D}\}$ ，则对偶函数

$$g(\boldsymbol{\lambda}) = \inf\{t + \boldsymbol{\lambda}u \mid (u, t) \in G\}$$

$$\mathbf{p}^* = \inf\{t \mid (u, t) \in G, u \leq 0\}$$

$$\max g(\boldsymbol{\lambda}), \boldsymbol{\lambda} \geq 0$$



注意问题必须要有可行解

5.3.2 经济学解释

满足原材料约束下，利润最多价格 $\lambda_i \geq 0$

$$g(\boldsymbol{\lambda}) = \inf_{\mathbf{x}} (f_0(\mathbf{x}) + \lambda_1 f_1(\mathbf{x}) + \cdots + \lambda_m f_m(\mathbf{x})) = \inf_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda})$$

则 $g(\boldsymbol{\lambda})$ 为对偶函数，市场 \mathbf{p}^* 损失最小 ($g(\boldsymbol{\lambda}) \leq \mathbf{p}^*$)

$$\mathbf{d}^* = \sup_{\boldsymbol{\lambda} \geq 0} g(\boldsymbol{\lambda})$$

市场平衡点，均衡市场 $\mathbf{p}^* = \mathbf{d}^*$ ，最优/影子价格 $\boldsymbol{\lambda}^*$

5.3.3 多目标优化解释

$$\begin{cases} \min f_0(\mathbf{x}) & 1 \\ \min f_1(\mathbf{x}) & \lambda_1 \\ \vdots & \vdots \\ \min f_m(\mathbf{x}) & \lambda_m \end{cases}$$

$$\min_{\mathbf{x}} f_0(\mathbf{x}) + \lambda_1 f_1(\mathbf{x}) + \cdots + \lambda_m f_m(\mathbf{x})$$

5.3.4 鞍点(saddle point)解释

$$f(\mathbf{w}, \mathbf{z}), \mathbf{w} \in S_w, \mathbf{z} \in S_z$$

极小极大不等式

$$\sup_{\mathbf{z} \in S_z} \inf_{\mathbf{w} \in S_w} f(\mathbf{w}, \mathbf{z}) \leq \inf_{\mathbf{w} \in S_w} \sup_{\mathbf{z} \in S_z} f(\mathbf{w}, \mathbf{z})$$

若有 $(\tilde{\mathbf{w}}, \tilde{\mathbf{z}})$ 使得

$$(\tilde{\mathbf{w}}, \tilde{\mathbf{z}}) = \arg \max_{\mathbf{z} \in S_z} \min_{\mathbf{w} \in S_w} f(\mathbf{w}, \mathbf{z})$$

$$(\tilde{\mathbf{w}}, \tilde{\mathbf{z}}) = \arg \min_{\mathbf{w} \in S_w} \max_{\mathbf{z} \in S_z} f(\mathbf{w}, \mathbf{z})$$

则 $(\tilde{\mathbf{w}}, \tilde{\mathbf{z}})$ 为鞍点

有下面不等式成立

$$f(\tilde{\mathbf{w}}, \mathbf{z}) \leq f(\tilde{\mathbf{w}}, \tilde{\mathbf{z}}) \leq f(\mathbf{w}, \tilde{\mathbf{z}}), \forall \mathbf{z} \in S_z, \mathbf{w} \in S_w$$

即从一个方向望过去是最小，从另一个方向望过去是最大

$$L(\mathbf{x}, \boldsymbol{\lambda}) = f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x})$$

$$\implies \sup_{\boldsymbol{\lambda} \geq 0} L(\mathbf{x}, \boldsymbol{\lambda}) = \sup_{\boldsymbol{\lambda} \geq 0} \left\{ f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i f_i(\mathbf{x}) \right\} = \begin{cases} f_0(\mathbf{x}) & f_i(\mathbf{x}) \leq 0, i = 1, \dots, m \\ +\infty & \text{otherwise} \end{cases}$$

$$\implies p^* = \inf_x \{f_0(\mathbf{x}) \mid f_i(\mathbf{x}) \leq 0, i = 1, \dots, m\} = \inf_x \sup_{\boldsymbol{\lambda} \geq 0} L(\mathbf{x}, \boldsymbol{\lambda})$$

$$\mathbf{d}^* = \sup_{\boldsymbol{\lambda} \geq 0} g(\boldsymbol{\lambda}) = \sup_{\boldsymbol{\lambda} \geq 0} \inf_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}) \implies \mathbf{p}^* \geq \mathbf{d}^*$$

如果 $L(\mathbf{x}, \boldsymbol{\lambda})$ 有鞍点，则必有 $\mathbf{p}^* = \mathbf{d}^*$

鞍点在无约束优化问题中是很糟糕的点（所有方向上梯度为0），但是有约束优化问题中则是非常好的点。

若 $(\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}})$ 为 $L(\mathbf{x}, \boldsymbol{\lambda})$ 鞍点 $\iff \mathbf{p}^* = \mathbf{d}^*$ 且 $\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}}$ 为原对偶问题最优解 \implies 若为鞍点， $\mathbf{p}^* = \mathbf{d}^*$

$$\sup_{\boldsymbol{\lambda} \geq 0} \inf_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}) = \inf_{\mathbf{x}} \sup_{\boldsymbol{\lambda} \geq 0} L(\mathbf{x}, \boldsymbol{\lambda})$$

已知 $(\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}})$ 为左边最优

$$\tilde{\boldsymbol{\lambda}} = \arg \max_{\boldsymbol{\lambda} \geq 0} \inf_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda})$$

$$\tilde{\mathbf{x}} = \arg \inf_{\mathbf{x}} \sup_{\boldsymbol{\lambda} \geq 0} L(\mathbf{x}, \boldsymbol{\lambda})$$

则 $\tilde{\boldsymbol{\lambda}}$ 对偶最优， $\tilde{\mathbf{x}}$ 为原问题最优

定理 5. $(\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}})$ 为拉格朗日函数鞍点 $\iff \mathbf{p}^* = \mathbf{d}^*$ ，且 $(\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}})$ 为原对偶的最优解

分析. 右推左, $(\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}})$ 为原对偶问题可行解

$$f_i(\tilde{\mathbf{x}}) \leq 0, i = 1, \dots, m, \tilde{\boldsymbol{\lambda}} \geq 0$$

因 $\mathbf{p}^* = \mathbf{d}^*$, 有

$$\begin{aligned} f_0(\tilde{\mathbf{x}}) &= g(\tilde{\boldsymbol{\lambda}}) \\ &= \inf_x \left\{ f_0(\mathbf{x}) + \sum_{i=1}^m \tilde{\lambda}_i f_i(\mathbf{x}) \right\} \\ &\leq f_0(\tilde{\mathbf{x}}) + \sum_{i=1}^m \tilde{\lambda}_i f_i(\tilde{\mathbf{x}}) \\ &\leq f_0(\tilde{\mathbf{x}}) \end{aligned}$$

进而不等号都得为等号, 还可得到

$$\begin{aligned} 1. \quad &\inf_x L(\mathbf{x}, \tilde{\boldsymbol{\lambda}}) = L(\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}}) \\ 2. \quad &f_0(\tilde{\mathbf{x}}) = \sup_{\boldsymbol{\lambda} \geq 0} \left\{ f_0(\tilde{\mathbf{x}}) + \sum_{i=1}^m \lambda_i f_i(\tilde{\mathbf{x}}) \right\} = \sup_{\boldsymbol{\lambda} \geq 0} L(\tilde{\mathbf{x}}, \boldsymbol{\lambda}) \end{aligned}$$

进而

$$L(\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}}) = \sup_{\boldsymbol{\lambda} \geq 0} L(\tilde{\mathbf{x}}, \boldsymbol{\lambda})$$

故右推左成立

5.4 一般优化问题的对偶理论

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & f_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, m \\ & h_i(\mathbf{x}) = 0, \quad i = 1, \dots, p \end{aligned}$$

不一定是凸问题, 但 $p^* = d^*$, 最优解满足什么条件?

设其对偶问题为下式

$$\begin{aligned} \max \quad & g(\boldsymbol{\lambda}, \mathbf{v}) \\ \text{s.t.} \quad & \boldsymbol{\lambda} \geq 0 \end{aligned}$$

分析. 设 $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \mathbf{v}^*)$ 为原对偶最优解, 则 $(\mathbf{x}^*, \boldsymbol{\lambda}^*, \mathbf{v}^*)$ 为原对偶可行解

$$f_i(\mathbf{x}^*) \leq 0, i = 1, \dots, m, \quad h_i(\mathbf{x}^*) = 0, i = 1, \dots, p, \quad \boldsymbol{\lambda}^* \geq 0$$

$$\begin{aligned}
\mathbf{p}^* = \mathbf{d}^* &\implies f_0(\mathbf{x}^*) = g(\boldsymbol{\lambda}^*, \mathbf{v}^*) \\
&= \inf_{\mathbf{x}} \left\{ f_0(\mathbf{x}) + \sum_{i=1}^m \lambda_i^* f_i(\mathbf{x}) + \sum_{i=1}^p v_i^* h_i(\mathbf{x}) \right\} \quad \text{将inf拆掉} \\
&\leq f_0(\mathbf{x}^*) + \sum_{i=1}^m \lambda_i^* f_i(\mathbf{x}^*) + \sum_{i=1}^p v_i^* h_i(\mathbf{x}^*) \quad \text{原问题约束} \\
&\leq f_0(\mathbf{x}^*)
\end{aligned}$$

同上理，不等号全取等，有

$$1. \lambda_i^* f_i(\mathbf{x}^*) = 0, \forall i = 1, \dots, m$$

$$2. \mathbf{x}^* = \arg \min_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}^*, \mathbf{v}^*)$$

若 f_0, f_i, h_i 均可微，则必要条件为

$$\left. \frac{\partial L(\mathbf{x}, \boldsymbol{\lambda}^*, \mathbf{v}^*)}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}^*} = 0$$

定理 6 (KKT条件). 可微优化问题的 *KKT* (*Karush-Kuhn-Tucker*) 条件如下

- 原始可行性 (*primal feasibility*): $f_i(\mathbf{x}^*) \leq 0, i = 1, \dots, m$
- 原始可行性 (*primal feasibility*): $h_i(\mathbf{x}^*) = 0, i = 1, \dots, p$
- 对偶可行性 (*dual feasibility*): $\boldsymbol{\lambda}^* \geq \mathbf{0}$
- 对偶互斥条件 (*complementarity slackness*): $\lambda_i^* f_i(\mathbf{x}^*) = 0, i = 1, \dots, m$
- 稳定性 (*stability*): $\left. \frac{\partial L(\mathbf{x}, \boldsymbol{\lambda}^*, \mathbf{v}^*)}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}^*} = 0$

若原问题为凸，则 *KKT* 条件为最优解的充要条件

分析. 必要性已证，证明充分性

若 $(\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}}, \tilde{\mathbf{v}})$ 满足 *KKT* 条件 $\implies (\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}}, \tilde{\mathbf{v}})$ 最优，其中， $\tilde{\mathbf{x}}$ 为原问题可行解， $(\tilde{\boldsymbol{\lambda}}, \tilde{\mathbf{v}})$ 为对偶问题可行解

证明思路： $g(\tilde{\boldsymbol{\lambda}}, \tilde{\mathbf{v}}) = f_0(\tilde{\mathbf{x}})$

$L(\mathbf{x}, \tilde{\boldsymbol{\lambda}}, \tilde{\mathbf{v}})$ 为 \mathbf{x} 的凸函数，则 $\tilde{\mathbf{x}}$ 使 $L(\mathbf{x}, \tilde{\boldsymbol{\lambda}}, \tilde{\mathbf{v}})$ 最小

$$\begin{aligned}
g(\tilde{\boldsymbol{\lambda}}, \tilde{\mathbf{v}}) &= \inf_{\mathbf{x}} L(\mathbf{x}, \tilde{\boldsymbol{\lambda}}, \tilde{\mathbf{v}}) \\
&= L(\tilde{\mathbf{x}}, \tilde{\boldsymbol{\lambda}}, \tilde{\mathbf{v}}) \\
&= f_0(\tilde{\mathbf{x}}) + \sum_{i=1}^m \tilde{\lambda}_i f_i(\tilde{\mathbf{x}}) + \sum_{i=1}^p \tilde{v}_i h_i(\tilde{\mathbf{x}}) \\
&= f_0(\tilde{\mathbf{x}})
\end{aligned}$$

例 31 (Water-filling). 共 n 个信道 (*channel*)

$$\text{source} \longleftrightarrow \text{destination}$$

$$\begin{aligned}
\min \quad & -\sum_{i=1}^n \log(\alpha_i + x_i), \alpha_i > 0 \\
\text{s.t.} \quad & \mathbf{x} \geq \mathbf{0} \\
& \mathbb{1}^T \mathbf{x} = 1
\end{aligned}$$

分析. 拉格朗日函数, 注意 $\boldsymbol{\lambda}^T \mathbf{x}$ 项符号

$$L(x, \lambda, v) = -\sum_{i=1}^n \log(\alpha_i + x_i) - \boldsymbol{\lambda}^T \mathbf{x} + v(\mathbb{1}^T \mathbf{x} - 1)$$

KKT条件如下

- 原始可行性: $\mathbf{x}^* \geq 0$
- 原始可行性: $\mathbb{1}^T \mathbf{x}^* = 1$
- 对偶可行性: $\boldsymbol{\lambda}^* \geq \mathbf{0}$
- 对偶互斥条件: $\lambda_i^* x_i^* = 0, \forall i$
- 稳定性条件:

$$\begin{aligned}
\left(\frac{\partial L(\mathbf{x}, \boldsymbol{\lambda}, v)}{\partial \mathbf{x}} \right)_i &= -\frac{1}{\alpha_i + x_i} - \lambda_i + v \\
&= -\frac{1}{\alpha_i + x_i^*} - \lambda_i^* + v^* = 0, \forall i \\
\implies v^* &= \frac{1}{\alpha_i + x_i^*} + \lambda_i^*, i = 1, \dots, n
\end{aligned}$$

若 $v^* \geq \frac{1}{\alpha_i}$, 则

$$x_i^* = 0, \lambda_i = v - \frac{1}{\alpha_i}$$


若 $v^* < \frac{1}{\alpha_i}$, 则

$$\frac{1}{\alpha_i} > v^* \geq \frac{1}{\alpha_i + x_i^*}$$

进而

$$\begin{aligned}
x_i^* &> 0 \\
v^* &= \frac{1}{\alpha_i + x_i^*} \\
x_i^* &= \frac{1}{v^*} - \alpha_i \\
\implies x_i^* &= \max \left\{ 0, \frac{1}{v^*} - \alpha_i \right\}
\end{aligned}$$

结合 $\sum_i x_i^* = 1$, 即注水算法



n 个块，每块高度为 α_i ，用单位水量填充面积，最终的高度为 $1/\nu^*$

定义 20 (扰动(perturbed)问题).

$$\begin{aligned} \min \quad & f_0(x) \\ \text{s.t.} \quad & f(x) \leq u_i, \quad i = 1, \dots, m \\ & h_i(x) = w_i, \quad i = 1, \dots, p \end{aligned}$$

新问题的最优解记为 $\mathbf{p}^*(\mathbf{u}, \mathbf{w})$

定理 7. 若原始问题为凸，则 $\mathbf{p}^*(\mathbf{u}, \mathbf{w})$ 是 (u, w) 的凸函数

6 优化算法

6.1 简介

例 32.

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & A\mathbf{x} = \mathbf{b} \end{aligned}$$

分析. 1° 罚函数法(*penalty function*)

$$\min F(\mathbf{x}) := f_0(\mathbf{x}) + \frac{\lambda}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2$$

$$\tilde{\mathbf{x}} = \arg \min_{\mathbf{x}} F \implies \nabla f_0(\tilde{\mathbf{x}}) + \lambda A^T(A\tilde{\mathbf{x}} - \mathbf{b}) = 0$$

2° 拉格朗日函数方法

$$\begin{aligned} L(\mathbf{x}, \mathbf{v}) &= f_0(\mathbf{x}) + \mathbf{v}^T(A\mathbf{x} - \mathbf{b}) \\ \implies g(\mathbf{v}) &= \inf_{\mathbf{x}} (f_0(\mathbf{x}) + \mathbf{v}^T(A\mathbf{x} - \mathbf{b})) \\ \mathbf{v} &= \lambda(A\tilde{\mathbf{x}} - \mathbf{b}) \\ \implies g(\lambda(A\tilde{\mathbf{x}} - \mathbf{b})) &= \inf_{\mathbf{x}} (f_0(\mathbf{x}) + \lambda(A\tilde{\mathbf{x}} - \mathbf{b})^T(A\mathbf{x} - \mathbf{b})) \end{aligned}$$

例 33.

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & \mathbf{Ax} \geq \mathbf{b} \end{aligned}$$

分析. *log-barrier*函数

$$\min f_0(\mathbf{x}) + \sum_{i=1}^m u_i \log(a_i^T \mathbf{x} - b_i)$$

考虑这样的问题, $f_0(\mathbf{x})$ 可微, 凸, 无约束, 即

$$\min f_0(\mathbf{x})$$

1. 所有算法都是迭代的

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha^{(k)} \mathbf{d}^{(k)}$$

$\alpha \geq 0$ 为步长, \mathbf{d} 为方向, 所有算法本质上都是选择方向与步长的问题

2. 如何选择步长 $\alpha^{(k)}$

$$\left\{ \begin{array}{l} \text{确定步长} \\ \text{搜索步长} \end{array} \right\} \left\{ \begin{array}{l} \text{固定步长} \\ \text{变化步长 (递减步长)} \end{array} \right.$$

最优步长: 线搜索问题, 给定当前点及方向

$$\alpha^{(k)} = \arg \min_{\alpha \geq 0} f_0(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$$

(a) 黄金分割法(0.618法)/优选法求解线搜索问题: 这样做的采样复杂度很低, 之前算过的点很容易被再用!

(b) 不精确线搜索(Armijo Rule): 一阶泰勒展开

Algorithm 1 不精确线搜索

```

1:  $\alpha^{(k)} = \alpha_{\max}$ 
2: if  $f_0(\mathbf{x}^{(k)} + \alpha^{(k)} \mathbf{d}^{(k)}) > f_0(\mathbf{x}^{(k)}) + \mu \alpha^{(k)} \langle \nabla f_0(\mathbf{x}^{(k)}), \mathbf{d}^{(k)} \rangle$  then
3:    $\alpha^{(k)} \leftarrow \alpha^{(k)} \beta, \beta \in (0, 1)$ 
4: else
5:   Stop

```

而实际上没有要求最优步长, 在该方向上的差异并没有太大

3. 关键问题是选方向

6.2 梯度下降法

取 $\mathbf{d}^{(k)} = -\nabla f_0(\mathbf{x}^{(k)})$, 则迭代格式为

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha^{(k)} \nabla f(\mathbf{x}^{(k)})$$

关注下面几个问题

- 能否收敛
- 收敛到哪里
- 收敛速度

6.2.1 前提假设

0. 基本假设: f 为可微的凸函数,

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} f_0(\mathbf{x})$$

存在且有限, $f_0(\mathbf{x}^*)$ 有限

1. Lipschitz 连续梯度

$$\exists L \geq 0, \forall \mathbf{x}, \mathbf{y} : \|\nabla f_0(\mathbf{x}) - \nabla f_0(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\|$$

等价定义:

a. 若 $f_0(\mathbf{x})$ 二阶可微

$$\nabla^2 f_0(\mathbf{x}) \preceq LI, \forall \mathbf{x}$$

b. 下界

$$\langle \nabla f_0(\mathbf{x}) - \nabla f_0(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \geq \frac{1}{L} \|\nabla f_0(\mathbf{x}) - \nabla f_0(\mathbf{y})\|^2$$

c. 上界

$$\langle \nabla f_0(\mathbf{x}) - \nabla f_0(\mathbf{y}), \mathbf{x} - \mathbf{y} \rangle \leq L \|\mathbf{x} - \mathbf{y}\|^2$$

d. 当函数为凸时

$$0 \leq f_0(\mathbf{y}) - f_0(\mathbf{x}) - \langle \nabla f_0(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle \leq \frac{L}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$

2. 强凸性(strong convexity): 即加了正则化项

$$\exists \mu > 0, \forall \mathbf{x}, \mathbf{y} : f_0(\mathbf{y}) \geq f_0(\mathbf{x}) + \langle \nabla f_0(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle + \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$

二阶可微情况下的等价定义

$$\nabla^2 f(\mathbf{x}) \succeq \mu I$$

例 34. 判断下列函数是否符合 *Lipschitz* 连续梯度及强凸性条件

$$\begin{array}{lll} f_0(\mathbf{x}) = \mathbb{1}^\top \mathbf{x} & L = 0 & \mathbf{x} \\ f_0(\mathbf{x}) = \frac{1}{2} \|\mathbf{x}\|_2^2 & L = 1 & \mu = 1 \\ f_0(\mathbf{x}) = \frac{1}{4} \|\mathbf{x}\|_2^4 & \mathbf{x} & \mathbf{x} \end{array}$$

区别于严格凸(strictly convex), 强凸一定是严格凸

定理 8. 严格凸函数只有一个最小值点

分析. 反证法, 假设 x, y 均为最小值点, 且 $x \neq y$

$$f_0(\mathbf{y}) > f_0(\mathbf{x}) + \langle \nabla f_0(\mathbf{x}), \mathbf{x} - \mathbf{y} \rangle = f_0(\mathbf{x})$$

定理 9. 若 $f_0(\mathbf{x})$ 有 Lipschitz 连续梯度, 常数 L , 若 $\alpha \in (0, \frac{2}{L})$, 则有

$$f_0(\mathbf{x}^{(k)}) - f_0(\mathbf{x}^*) \leq \frac{2(f_0(\mathbf{x}^0) - f_0(\mathbf{x}^*)) \|\mathbf{x}^0 - \mathbf{x}^*\|^2}{2 \|\mathbf{x}^0 - \mathbf{x}^*\|^2 + k\alpha(2 - L\alpha)(f_0(\mathbf{x}^0) - f_0(\mathbf{x}^*))}, \forall \mathbf{x}^*$$

即以 $O(\frac{1}{k})$ 速度收斂

分析. 1° 点的单调性: 与任意 x^* 的距离在缩小

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\|^2 \leq \|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2, \forall \mathbf{x}^*$$

$$\begin{aligned} LHS &= \left\| \mathbf{x}^{(k)} - \mathbf{x}^* - \alpha \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 \\ &= \left\| \mathbf{x}^{(k)} - \mathbf{x}^* \right\|^2 - 2\alpha \langle \mathbf{x}^{(k)} - \mathbf{x}^*, \nabla f_0(\mathbf{x}^{(k)}) \rangle + \alpha^2 \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 \\ &\leq \left\| \mathbf{x}^{(k)} - \mathbf{x}^* \right\|^2 + \alpha \left(\alpha - \frac{2}{L} \right) \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 \quad \text{注意到 } \nabla f_0(\mathbf{x}^*) = 0, \text{ 利用 Lipschitz 连续梯度} \\ &\leq \left\| \mathbf{x}^{(k)} - \mathbf{x}^* \right\|^2 \end{aligned}$$

2° 函数值的单调性: $f_0(\mathbf{x}^{(k+1)}) \leq f_0(\mathbf{x}^{(k)})$ (注意下降可能非常缓慢, 并不一定收敛)

$$\begin{aligned} f_0(\mathbf{x}^{(k+1)}) &\leq f_0(\mathbf{x}^{(k)}) + \langle \nabla f_0(\mathbf{x}^{(k)}), \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} \rangle + \frac{L}{2} \|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|^2 \\ &= f_0(\mathbf{x}^{(k)}) - \alpha(1 - \frac{L\alpha}{2}) \|\nabla f_0(\mathbf{x}^{(k)})\|^2 \\ &\leq f_0(\mathbf{x}^{(k)}) \end{aligned}$$

3° 函数值的充分下降 (即证明收敛性)

$$f_0(\mathbf{x}^{(k+1)}) - f_0(\mathbf{x}^*) \leq f_0(\mathbf{x}^{(k)}) - f_0(\mathbf{x}^*) - \omega \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2$$

$$\begin{aligned}
f_0(\mathbf{x}^{(k)}) - f_0(\mathbf{x}^*) &\leq \langle f_0(\mathbf{x}^{(k)}), \mathbf{x}^{(k)} - \mathbf{x}^* \rangle \\
&= \langle \nabla f_0(\mathbf{x}^{(k)}) - \nabla f_0(\mathbf{x}^*), \mathbf{x}^{(k)} - \mathbf{x}^* \rangle \\
&\leq \|\nabla f_0(\mathbf{x}^{(k)}) - \nabla f_0(\mathbf{x}^*)\| \|\mathbf{x}^{(k)} - \mathbf{x}^*\| \\
&\leq \|\nabla f_0(\mathbf{x}^{(k)})\| \|\mathbf{x}^{(k)} - \mathbf{x}^*\| \\
\Delta^{(k+1)} &\leq \Delta^{(k)} - \frac{\omega}{\|\mathbf{x}^0 - \mathbf{x}^*\|^2} (\Delta^{(k)})^2 \\
\frac{1}{\Delta^{(k+1)}} &\leq \frac{1}{\Delta^{(k)}} - \frac{\omega}{\|\mathbf{x}^0 - \mathbf{x}^*\|^2} \frac{\Delta^{(k)}}{\Delta^{(k+1)}}
\end{aligned}$$

错位相消可得结论 $O(\frac{1}{k})$ 收敛速度

定理 10. 若 f_0 有Lipschitz连续梯度, 常数 L , 强凸函数 n , 步长 $\alpha \in (0, \frac{2}{\mu+L}]$, 则


$$\|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2 \leq \left(1 - \frac{2\alpha\mu L}{\mu + L}\right)^k \|\mathbf{x}^{(0)} - \mathbf{x}^*\|^2$$

分析.

$$\begin{aligned}
\|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2 &= \|\mathbf{x}^{(k)} - \alpha \nabla f_0(\mathbf{x}^{(k)}) - \mathbf{x}^*\|^2 \\
&= \|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2 - 2\alpha \langle \mathbf{x}^{(k)} - \mathbf{x}^*, \nabla f_0(\mathbf{x}^{(k)}) \rangle + \alpha^2 \|\nabla f_0(\mathbf{x}^{(k)})\|^2 \\
&\leq \|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2 - \frac{2\alpha}{\mu + L} \|\nabla f_0(\mathbf{x})\|^2 + \alpha^2 \|\nabla f_0(\mathbf{x}^{(k)})\|^2 \quad \text{内积不等式} \\
&\leq RHS
\end{aligned}$$

$$1 - \frac{4\mu L}{(\mu + L)^2} = \frac{(L - \mu)^2}{(L + \mu)^2} = \frac{\left(\frac{L}{\mu} - 1\right)^2}{\left(\frac{L}{\mu} + 1\right)^2}$$

L 为Hessian矩阵的最大特征值, μ 为Hessian矩阵的最小特征值, 则 $\frac{L}{\mu}$ 为该矩阵的条件数



例 35.

$$f_0(\mathbf{x}) = \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2$$

分析.

$$\mathbf{x}^{(0)} \rightarrow \mathbf{x}^{(1)}$$

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} - \alpha(\mathbf{x}^{(0)} - \mathbf{b}) = \mathbf{b}$$

条件数糟糕的病态矩阵收敛速度是非常糟糕的，会出现zig-zag的情况，如下面的矩阵

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 10^{-4} \end{bmatrix}$$

可以通过预处理(precondition)来解决条件数糟糕的问题

$f_0(\mathbf{x})$, Lipschitz连续梯度(L), 强凸(μ), 考虑函数值收敛性

$$\begin{aligned} \tilde{f}_0(\alpha^{(k)}) &= f_0(\mathbf{x}^{(k+1)}) = f_0(\mathbf{x}^{(k)} - \alpha^{(k)} \nabla f_0(\mathbf{x}^{(k)})) \\ &\leq f_0(\mathbf{x}^{(k)}) + \langle \nabla f_0(\mathbf{x}^{(k)}), -\alpha^{(k)} \nabla f_0(\mathbf{x}^{(k)}) \rangle + \frac{L}{2} \left\| -\alpha^{(k)} \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 \\ &= f_0(\mathbf{x}^{(k)}) + \frac{L(\alpha^{(k)})^2 - 2\alpha^{(k)}}{2} \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 \end{aligned}$$

- $\alpha^{(k)} = \alpha_{exact}^{(k)}$ 精确线搜索

$$\begin{aligned} \tilde{f}_0\left(\frac{1}{L}\right) &= f_0(\mathbf{x}^{(k)}) - \frac{1}{2L} \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 \\ \tilde{f}_0(\alpha_{exact}^{(k)}) &\leq \tilde{f}_0\left(\frac{1}{L}\right) \\ \Rightarrow \tilde{f}_0(\alpha_{exact}^{(k)}) - f_0(\mathbf{x}^{(k)}) - f_0(\mathbf{x}^*) - \frac{1}{2L} \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 &\leq \left(1 - \frac{\mu}{L}\right)(f_0(\mathbf{x}^{(k)}) + f_0(\mathbf{x}^*)) \end{aligned}$$

$$\begin{aligned} f_0(\mathbf{x}^*) &\geq f_0(\mathbf{x}^{(k)}) + \langle \nabla f_0(\mathbf{x}^{(k)}), \mathbf{x}^* - \mathbf{x}^{(k)} \rangle + \frac{\mu}{2} \left\| \mathbf{x}^{(k)} - \mathbf{x}^* \right\|^2 \\ &\geq f_0(\mathbf{x}^{(k)}) - \frac{\mu}{2} \left\| \mathbf{x}^{(k)} - \mathbf{x}^* \right\|^2 - \frac{1}{2\mu} \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 + \frac{\mu}{2} \left\| \mathbf{x}^{(k)} - \mathbf{x}^* \right\|^2 \quad ab \geq -\frac{\mu}{2}a^2 - \frac{1}{2\mu}b^2 \\ &= f_0(\mathbf{x}^{(k)}) - \frac{1}{2\mu} \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 \end{aligned}$$

$$f_0(\mathbf{x}^{(k)}) - f_0(\mathbf{x}^*) \leq \frac{1}{2\mu} \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2$$

- Armijo Rule

$$\begin{aligned} \tilde{f}_0(\alpha^{(k)}) &= f_0(\mathbf{x}^{(k+1)}) \leq f_0(\mathbf{x}^{(k)}) + \frac{L(\alpha^{(k)})^2 - 2\alpha^{(k)}}{2} \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 \\ \tilde{f}_0(\alpha^{(k)}) &= f_0(\mathbf{x}^{(k+1)}) \leq f_0(\mathbf{x}^{(k)}) - \nabla \alpha^{(k)} \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2 \end{aligned}$$

首先说明，若 $0 \leq \alpha^{(k)} \leq \frac{1}{L}$ 时，

$$\tilde{f}_0(\alpha^{(k)}) \leq f_0(\mathbf{x}^{(k)}) - \gamma \alpha^{(k)} \left\| \nabla f_0(\mathbf{x}^{(k)}) \right\|^2$$

当 $\alpha^{(k)} \in [0, \frac{1}{2}]$ 时,

$$-\alpha^{(k)} + \frac{L}{2}(\alpha^{(k)})^2 \leq -\frac{\alpha^{(k)}}{2} \iff \frac{L}{2}(\alpha^{(k)})^2 \leq \frac{\alpha^{(k)}}{2} \iff L \cdot \alpha^{(k)} \leq 1$$

$$\begin{aligned} f_0(\mathbf{x}^{(k+1)}) &\leq f_0(\mathbf{x}^{(k)}) + \frac{L(\alpha^{(k)})^2 - 2\alpha^{(k)}}{2} \|\nabla f_0(\mathbf{x}^{(k)})\|^2 \\ &\leq f_0(\mathbf{x}^{(k)}) - \frac{\alpha^{(k)}}{2} \|\nabla f_0(\mathbf{x}^{(k)})\|^2 \\ &\leq f_0(\mathbf{x}^{(k)}) - \gamma\alpha^{(k)} \|\nabla f_0(\mathbf{x}^{(k)})\|^2 \end{aligned}$$

$$\begin{aligned} f_0(\mathbf{x}^{(k+1)}) &\leq f_0(\mathbf{x}^{(k)}) - \min\left\{\gamma\alpha_{\max}, \frac{\gamma\beta}{L}\right\} \|\nabla f_0(\mathbf{x}^{(k)})\|^2 \\ \implies f_0(\mathbf{x}^{(k+1)}) - f_0(\mathbf{x}^*) &\leq \left(1 - \min\left\{2\mu\gamma\alpha_{\max}, \frac{2\mu\gamma\beta}{L}\right\}\right) (f_0(\mathbf{x}^{(k)}) - f_0(\mathbf{x}^*)) \end{aligned}$$

6.2.2 梯度下降法的解释

- 解释一

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha^{(k)} \nabla f_0(\mathbf{x}^{(k)})$$

将 f_0 在 $\mathbf{x}^{(k)}$ 处进行一阶Taylor展开

$$f_0(\mathbf{x}) \approx f_0(\mathbf{x}^{(k)}) + \langle \nabla f_0(\mathbf{x}^{(k)}), \mathbf{x} - \mathbf{x}^{(k)} \rangle + \frac{1}{2\alpha^{(k)}} \|\mathbf{x} - \mathbf{x}^{(k)}\|^2$$

求梯度

$$\begin{aligned} \nabla f_0(\mathbf{x}^{(k)}) + \frac{1}{\alpha^{(k)}}(\mathbf{x} - \mathbf{x}^{(k)}) &= 0 \\ \alpha^{(k)} \nabla f_0(\mathbf{x}^{(k)}) + \mathbf{x} - \mathbf{x}^{(k)} &= 0 \\ \mathbf{x} &= \mathbf{x}^{(k)} - \alpha^{(k)} \nabla f_0(\mathbf{x}^{(k)}) \end{aligned}$$

- 解释二

$$f_0(\mathbf{x}^{(k)} + v) \approx f_0(\mathbf{x}^{(k)}) + \langle \nabla f_0(\mathbf{x}^{(k)}), v \rangle$$

$$\mathbf{d}^{(k)} = \arg \min_v \{ \langle \nabla f_0(\mathbf{x}^{(k)}), v \rangle \mid \|v\| = 1 \}$$

若采用2-范数, 可得标准化的负梯度方向(normalized negative gradient)

$$\mathbf{d}^{(k)} = \frac{-\nabla f_0(\mathbf{x}^{(k)})}{\|\nabla f_0(\mathbf{x}^{(k)})\|_2}$$

通过改变不同的范数, 有不同的特性

进而有坐标下降法/交替极小化(coordinate descent/alternating direction)

$$\mathbf{d}^{(k)} = \mathbf{e}_{k \bmod n}$$

注意，这里 $\mathbf{x} \in \mathbb{R}^n$, $n \bmod n = n$

$$\alpha^{(k)} = \arg \min f_0(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)}), \alpha_{\max} \geq \alpha \geq \alpha_{\min}$$

6.3 非光滑优化问题

6.3.1 次梯度法

同样考虑 f_0 连续, 凸, 不可微

$$\min f_0(\mathbf{x})$$

梯度下降法 \rightarrow 次梯度(subgradient)法

定义 21 (次梯度). 若 $g_0(\mathbf{x}) \in \partial f_0(\mathbf{x})$ (注意凹函数则对应的是 *supgradient*) 为 $f_0(\mathbf{x})$ 的一个次梯度, 则

$$\forall \mathbf{y}: f_0(\mathbf{y}) \geq f_0(\mathbf{x}) + \langle g_0(\mathbf{x}), \mathbf{y} - \mathbf{x} \rangle$$

即过该点的直线都要在整条曲线的下方, 则该直线的斜率范围为次梯度取值

如 $f(\mathbf{x}) = |\mathbf{x}|$ 在零点处次梯度为 $[-1, 1]$ 。

次梯度法⁸迭代格式如下

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha^{(k)} g_0(\mathbf{x}^{(k)})$$

只要有 $0 \in \partial f_0(\mathbf{x}_0)$ 就有最优解 $\mathbf{x} = \mathbf{x}_0$

对于梯度法来说, 关键在于选择步长

- 固定步长 $\alpha^{(k)} = \alpha$
- 不可加但平方可加, 如 $\frac{1}{k}$

$$\sum_{k=0}^{\infty} \alpha^{(k)} = \infty \quad \sum_{k=0}^{\infty} (\alpha^{(k)})^2 < \infty$$

- 不可加递减, 如 $\frac{1}{\sqrt{k}}$

$$\sum_{k=0}^{\infty} \alpha^{(k)} = 0 \quad \lim_{k \rightarrow \infty} \alpha^{(k)} \rightarrow 0$$

考虑收敛速度

$$\inf_{i=0, \dots, k} (f_0(\mathbf{x}^{(i)}) - f_0(\mathbf{x}^*))$$

假设函数 Lipschitz 连续

$$\exists G > 0, \forall \mathbf{x}, \mathbf{y}: \|f_0(\mathbf{x}) - f_0(\mathbf{y})\| \leq G \|\mathbf{x} - \mathbf{y}\|$$

⁸如果激活函数为非光滑的 (如 ReLU), 那么出来的函数也是非光滑的, 就要用次梯度

$\forall \mathbf{x}^*$ 最优

$$\begin{aligned}
& \left\| \mathbf{x}^{(k+1)} - \mathbf{x}^* \right\|^2 = \left\| \mathbf{x}^{(k)} - \alpha^{(k)} g_0(\mathbf{x}^{(k)}) - \mathbf{x}^* \right\|^2 \\
& = \left\| \mathbf{x}^{(k)} - \mathbf{x}^* \right\|^2 - 2 \langle \alpha^{(k)} g_0(\mathbf{x}^{(k)}), \mathbf{x}^{(k)} - \mathbf{x}^* \rangle + (\alpha^{(k)})^2 \left\| g_0(\mathbf{x}^{(k)}) \right\|^2 \quad \text{拆平方} \\
& \leq \left\| \mathbf{x}^{(k)} - \mathbf{x}^* \right\|^2 - 2(\alpha^{(k)})^2 (f_0(\mathbf{x}^{(k)}) - f_0(\mathbf{x}^*)) + (\alpha^{(k)})^2 G^2 \\
& \Rightarrow \left\| \mathbf{x}^{(k+1)} - \mathbf{x}^* \right\|^2 \leq \left\| \mathbf{x}^{(0)} - \mathbf{x}^* \right\|^2 - 2 \sum_{i=0}^k \alpha^{(i)} (f_0(\mathbf{x}^{(i)}) - f_0(\mathbf{x}^*)) + \sum_{i=0}^k (\alpha^{(i)})^2 G^2 \\
& \Rightarrow 2 \sum_{i=0}^k \alpha^{(i)} (f_0(\mathbf{x}^{(i)}) - f_0(\mathbf{x}^*)) \leq \left\| \mathbf{x}^{(0)} - \mathbf{x}^* \right\|^2 + \sum_{i=0}^k (\alpha^{(i)})^2 G^2 \\
& \sum_{i=0}^k \alpha^{(i)} (f_0(\mathbf{x}^{(i)}) - f_0(\mathbf{x}^*)) \geq \left(\sum_{i=0}^k \alpha^{(i)} \right) \inf_{i=0, \dots, k} (f_0(\mathbf{x}^{(i)}) - f_0(\mathbf{x}^*)) \\
& \Rightarrow \inf_{i=0, \dots, k} (f_0(\mathbf{x}^{(i)}) - f_0(\mathbf{x}^*)) \leq \frac{\left\| \mathbf{x}^{(0)} - \mathbf{x}^* \right\|^2 + G^2 \sum_{i=0}^k (\alpha^{(i)})^2}{2 \sum_{i=0}^k \alpha^{(i)}}
\end{aligned}$$

这是一个紧的界

- 固定步长得到上界 $\frac{G^2 \alpha}{2}$ ，以 $f(\mathbf{x}) = |\mathbf{x}|$ 为例
- 不可加平方可加一定收敛，若步长为 $\frac{1}{k}$ ，收敛速度为 $\frac{1}{\log k}$ （幂级数积分取上下界 $\sum_{i=0}^k \frac{1}{i} = O(\log k)$ ）
- 不可加平方不可加同样收敛，若步长为 $\frac{1}{\sqrt{k}}$ ，收敛速度为 $O(\frac{\log k}{\sqrt{k}})$ ，可以证明在该假设下该收敛速度最优

$$\lim_{k \rightarrow \infty} \inf_{i=0, \dots, k} (f_0(\mathbf{x}^{(i)}) - f_0(\mathbf{x}^*)) = 0$$

$$\forall \varepsilon > 0, \exists N_1 \in \mathbb{Z}, \alpha^{(i)} \leq \frac{\varepsilon}{G^2}, \forall i > N_1$$

$$\exists N_2 \in \mathbb{Z} : \sum_{i=0}^k \alpha^{(i)} \geq \frac{1}{\varepsilon} \left(\left\| \mathbf{x}^{(0)} - \mathbf{x}^* \right\|^2 + G^2 \sum_{i=0}^{N_1} (\alpha^{(i)})^2 \right), \forall k > N_2$$

令 $N = \max\{N_1, N_2\}$, $\forall k > N$

$$\frac{\left\| \mathbf{x}^{(0)} - \mathbf{x}^* \right\|^2 + G^2 \sum_{i=0}^{N_1} (\alpha^{(i)})^2}{2 \sum_{i=0}^k \alpha^{(i)}} + \frac{\left\| \mathbf{x}^{(0)} - \mathbf{x}^* \right\|^2 + G^2 \sum_{i=N_1+1}^k (\alpha^{(i)})^2}{2 \sum_{i=0}^{N_1} \alpha^{(i)} + 2 \sum_{i=N_1+1}^k \alpha^{(i)}} \leq \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon$$

$$\text{第二项} \leq \frac{G^2 \sum_{i=N_1+1}^k \alpha^{(i)} \frac{\varepsilon}{G^2}}{2 \sum_{i=0}^{N_1} \alpha^{(i)} + 2 \sum_{i=N_1+1}^k \alpha^{(i)}} \leq \frac{\varepsilon}{2}$$

实际上这个假设一般情况下不成立，但是我们只需保证在优化路径上成立即可，也有设置 \mathbf{x} 有界的

6.3.2 邻近点梯度法(proximal gradient method)


考虑有结构，不可微的函数

$$\min f_0(\mathbf{x}) = s(\mathbf{x}) + r(\mathbf{x})$$

- s : smooth, 可微, 易求导
- r : regularization, 不可微, 易求邻近点投影

定义 22 (邻近点投影(proximal mapping)). 函数 r 和平衡参数 λ 的近端算子

$$\text{prox}_r \hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \left(r(\mathbf{x}) + \frac{1}{2\alpha} \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2 \right)$$



注：邻近点/近端投影字面上理解即对点 \hat{x} 关于 r 下降方向的邻近点。如上图，黑细线为 r 的水平集，黑粗线为定义域边界，蓝色点为 \hat{x} ，红色为作用该算子后的点，这些点都统一朝着函数最小的方法前进⁹。

邻近点梯度法迭代格式如下

$$\begin{cases} \mathbf{x}^{(k+\frac{1}{2})} = \mathbf{x}^{(k)} - \alpha^{(k)} \nabla s(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} = \text{prox}_r \mathbf{x}^{(k+\frac{1}{2})} = \arg \min_{\mathbf{x}} \left(r(\mathbf{x}) + \frac{1}{2\alpha} \|\mathbf{x} - \mathbf{x}^{(k+\frac{1}{2})}\|_2^2 \right) \end{cases}$$

例 36 (LASSO).

$$f(\mathbf{x}) = \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 + p \|\mathbf{x}\|_1$$

分析. 设

$$\begin{cases} s(\mathbf{x}) := \frac{1}{2} \|\mathbf{Ax} - \mathbf{b}\|_2^2 \\ r(\mathbf{x}) := p \|\mathbf{x}\|_1 \end{cases}$$

其中, $A \in \mathbb{R}^{m \times n}$, $\mathbf{x} \in \mathbb{R}^n$, $\mathbf{b}, \mathbf{e} \in \mathbb{R}^m$ (在本题中 $m = 50, n = 100$), $s(\mathbf{x})$ 为光滑函数, $r(\mathbf{x})$ 为非光滑函数, 则原式

$$f(\mathbf{x}) = s(\mathbf{x}) + r(\mathbf{x})$$

⁹详细见<https://zhuanlan.zhihu.com/p/37444622>

先求 $r(\mathbf{x})$ 的邻近点投影

$$\text{prox } \hat{\mathbf{x}} = \arg \min_{\mathbf{x}} \left(p \|\mathbf{x}\|_1 + \frac{1}{2\alpha} \|\mathbf{x} - \hat{\mathbf{x}}\|_2^2 \right)$$

对上式右侧展开有

$$\arg \min_{\mathbf{x}} \left(p \sum_{i=1}^n |x_i| + \frac{1}{2\alpha} \sum_{i=1}^n (x_i - \hat{x}_i)^2 \right)$$

注意到上式对于下标 i 相互独立，故要求上式的最小值，等价于对每一个下标 i 求最小值后求和，即

$$\arg \min_{x_i} \left(p|x_i| + \frac{1}{2\alpha} (x_i - \hat{x}_i)^2 \right), \forall i$$

由不可微函数的极值判断条件有

$$0 \in \left(\partial_{x_i} p|x_i| + \frac{1}{\alpha} (x_i - \hat{x}_i) \right), \forall i$$

对每一个 x_i 进行分类讨论

- 若 $x_i > 0$ ，则 $|x_i|$ 对于 $|x_i|$ 可微，即 $\partial_{x_i} |x_i| = 1$ ，有

$$p + \frac{1}{\alpha} (x_i - \hat{x}_i) = 0$$

整理得

$$x_i = \hat{x}_i - \alpha p$$

由于 $x_i > 0$ ，故 $\hat{x}_i - \alpha p > 0$ ，即 $\hat{x}_i > \alpha p$

- 若 $x_i < 0$ ，则 $|x_i|$ 对于 $|x_i|$ 可微，即 $\partial_{x_i} |x_i| = -1$ ，有

$$-p + \frac{1}{\alpha} (x_i - \hat{x}_i) = 0$$

整理得

$$x_i = \hat{x}_i + \alpha p$$

由于 $x_i < 0$ ，故 $\hat{x}_i + \alpha p < 0$ ，即 $\hat{x}_i < -\alpha p$

- 若 $x_i = 0$ ，则 $|x_i|$ 对于 $|x_i|$ 不可微，需要求次梯度， $\partial_{x_i} |x_i| = [-1, 1]$ ，即

$$0 \in \left[-p - \frac{\hat{x}_i}{\alpha}, p - \frac{\hat{x}_i}{\alpha} \right]$$

那么，需要满足

$$\begin{cases} p - \frac{\hat{x}_i}{\alpha} \geq 0 \\ -p - \frac{\hat{x}_i}{\alpha} \leq 0 \end{cases}$$


推得

$$\hat{x}_i \in [-\alpha p, \alpha p]$$

综上，有

$$x_i = \begin{cases} \hat{x}_i + \alpha p & \hat{x}_i < -\alpha p \\ 0 & \hat{x}_i \in [-\alpha p, \alpha p] \\ \hat{x}_i - \alpha p & \hat{x}_i > \alpha p \end{cases}$$

可以得到下图的软门限(*soft-thresholding*)曲线



进一步，得到邻近点梯度下降法的迭代式如下

$$\begin{cases} \mathbf{x}^{(k+\frac{1}{2})} = \mathbf{x}^{(k)} - \alpha \nabla s(\mathbf{x}^{(k)}) = \mathbf{x}^{(k)} - \alpha A^T(A\mathbf{x}^{(k)} - \mathbf{b}) \\ \mathbf{x}^{(k+1)} = \text{prox } \mathbf{x}^{(k+\frac{1}{2})} = \arg \min_{\mathbf{x}} \left(p \|\mathbf{x}\|_1 + \frac{1}{2\alpha} \left\| \mathbf{x} - \mathbf{x}^{(k+\frac{1}{2})} \right\|_2^2 \right) \end{cases}$$

其中， $x^{(k+\frac{1}{2})}$ 可直接计算， $x^{(k+1)}$ 的显式解可由软门限求得。

此算法即迭代阈值收缩 (*Iterative shrinkage-thresholding algorithm, ISTA*) 算法

例 37 (盒限制(box constrained)优化问题).

$$f_0(\mathbf{x}) = s(\mathbf{x}) + \sum_{i=1}^n I(x_i \in [l_i, u_i])$$

分析. 构造邻近点投影

$$\begin{aligned} \arg \min \quad & \frac{1}{2\alpha} \|\mathbf{x} - \hat{\mathbf{x}}\|^2 \\ \text{subject to} \quad & x_i \in [l_i, u_i], \forall i \end{aligned}$$

如果有约束 $\mathbf{x} \in \mathcal{C}$

$$\begin{cases} \mathbf{x}^{(k+\frac{1}{2})} = \mathbf{x}^{(k)} - \alpha \nabla S(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} = \arg \min_{\mathbf{x}} \left(I_{\mathcal{C}}(\mathbf{x}^{(k+\frac{1}{2})}) + \frac{1}{2\alpha} \left\| \mathbf{x} - \mathbf{x}^{(k+\frac{1}{2})} \right\|^2 \right) = \arg \min_{\mathbf{x}} \frac{1}{2\alpha} \left\| \mathbf{x} - \mathbf{x}^{(k+\frac{1}{2})} \right\|^2, \mathbf{x} \in \mathcal{C} \end{cases}$$

相当于做投影，故称投影梯度法

$$\begin{aligned} 0 &\in \partial r(\mathbf{x}^{(k+1)}) + \frac{1}{\alpha}(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k+\frac{1}{2})}) \\ 0 &= \partial r(\mathbf{x}^{(k+1)}) + \frac{1}{\alpha}(\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} + \alpha \nabla S(\mathbf{x}^{(k)})) \\ \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} - \alpha \nabla S(\mathbf{x}^{(k)}) - \alpha \partial r(\mathbf{x}^{(k+1)}) \end{aligned}$$

数值计算：显式方法（次梯度法）→隐式方法（邻近点梯度法—需要先知道下一步信息，但是这是可以做的，因为有邻近点）

* 邻近点投影法的收敛性能与梯度下降法类似

例 38 (矩阵补全). $Y \in \mathbb{R}^{m \times n}, \{Y_{ij}, (i, j) \in \Omega\}$

$$\min_B \left(\frac{1}{2} \sum_{(i,j) \in \Omega} (Y_{ij} - B_{ij})^2 + \lambda \text{rank}(B) \right)$$

分析. 同LASSO, 由于矩阵的秩（奇异值向量 ℓ_1 -范数）不好求，改为矩阵的和范数 $\|\cdot\|_*$ （奇异值向量 ℓ_1 -范数），即

$$\min_B \left(\frac{1}{2} \sum_{(i,j) \in \Omega} (Y_{ij} - B_{ij})^2 + \lambda \|B\|_* \right)$$

其中，

$$\|B\|_* := \sum_{i=1}^n \sigma_i(B)$$

$$\min \left(\frac{1}{2} \|P_\Omega(B - Y)\|_F^2 + \lambda \|B\|_* \right)$$

若原矩阵中该项不存在， P_Ω 为0；存在的话则保持不变

$$\nabla B \left(\frac{1}{2} \|P_\Omega(B - Y)\|_F^2 \right) = P_\Omega(B - Y)$$

对 B 做奇异值分解， U 为酉矩阵

$$\partial \|B\|_* = \{UDV^T, B = U\Sigma V^T, d = \partial \|\sigma\|_1\}$$

邻近点梯度迭代格式为

$$\begin{cases} B^{(k+\frac{1}{2})} = B^k - \alpha P_\Omega(B^k - Y) \\ B^{(k+1)} = \arg \min_B \lambda \|B\|_* + \frac{1}{2\alpha} \|B - B^{(k+\frac{1}{2})}\|_F^2 \end{cases}$$

求次梯度

$$\begin{aligned} 0 &\in \lambda \partial \|B\|_* + \frac{1}{\alpha}(B - B^{(k+\frac{1}{2})}) \\ 0 &\in \left[\lambda UDV^T + \frac{1}{\alpha}(B - B^{(k+\frac{1}{2})}) \right] \end{aligned}$$

$$\begin{aligned}
B &= U\Sigma V^T, \quad d = \partial \|\sigma\|_1 \\
0 &\in \left\{ \lambda U D V^T + \frac{1}{\alpha} (V\Sigma V^T - B^{(k+\frac{1}{2})}) \right\} \\
\exists V : 0 &= \alpha \lambda U D V^T + V\Sigma V^T - B^{(k+\frac{1}{2})} \\
B^{(k+\frac{1}{2})} &= U(\alpha \lambda D + \Sigma) V^T
\end{aligned}$$

对 $B^{(k+\frac{1}{2})}$ 进行奇异值分解

$$B^{(k+\frac{1}{2})} = U\Sigma^{(k+\frac{1}{2})}V$$

$$T_i = \alpha \lambda d_i + \sigma_i$$

若 $\sigma_i \neq 0 \implies \tau_i = \alpha \lambda + \sigma_i$

若 $\sigma_i = 0 \implies \tau_i \in [-\alpha \lambda + \sigma_i, \alpha \lambda + \sigma_i]$

$$\begin{cases} \sigma_i = \tau_i - \alpha \lambda & \tau_i > \alpha \lambda \\ \sigma_i = 0 & \tau_i \leq \alpha \lambda \end{cases}$$

该算法称为矩阵软门限算法

一阶方法总结：

- 梯度下降法
- 次梯度法：在随机/不确定性优化问题中很有效
- 邻近点梯度法

6.4 二阶优化方法

6.4.1 牛顿法

牛顿法(Newton's method)：要求 $f_0(\mathbf{x})$ 二阶可微，强凸，考虑不同方向，用Taylor展开有

$$\begin{aligned}
\min_{\|\mathbf{v}\|=1} f_0(\mathbf{x}^{(k)} + \mathbf{v}) &\approx \min_{\|\mathbf{v}\|=1} f_0(\mathbf{x}^{(k)}) + \langle \nabla f_0(\mathbf{x}^{(k)}), \mathbf{v} \rangle \\
&\approx \min_{\mathbf{v}} f_0(\mathbf{x}^{(k)}) + \nabla f_0(\mathbf{x}^{(k)})^T \mathbf{v} + \frac{1}{2} \mathbf{v}^T \nabla^2 f_0(\mathbf{x}^{(k)}) \mathbf{v}
\end{aligned}$$

求梯度有

$$\begin{aligned}
&\nabla f_0(\mathbf{x}^{(k)}) + \nabla^2 f_0(\mathbf{x}^{(k)}) \mathbf{v} = 0 \\
\implies \mathbf{v} &= -(\nabla^2 f_0(\mathbf{x}^{(k)}))^{-1} \nabla f_0(\mathbf{x}^{(k)}) \rightarrow \text{牛顿方向} \\
&\begin{cases} \mathbf{d}^{(k)} = -(\nabla^2 f_0(\mathbf{x}^{(k)}))^{-1} \nabla f_0(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha^{(k)} (\nabla^2 f_0(\mathbf{x}^{(k)}))^{-1} \nabla f_0(\mathbf{x}^{(k)}) \end{cases}
\end{aligned}$$

其中 $\alpha^{(k)}$ 为搜索步长。

看下降方向只要看其与负梯度方向是否小于90度

$$\begin{aligned} & \langle -\nabla f_0(\mathbf{x}^{(k)}), -(\nabla^2 f_0(\mathbf{x}^{(k)}))^{-1} \nabla f_0(\mathbf{x}^{(k)}) \rangle \\ &= \nabla^T f_0(\mathbf{x}^{(k)}) (\nabla^2 f_0(\mathbf{x}^{(k)}))^{-1} \nabla f_0(\mathbf{x}^{(k)}) \end{aligned}$$

假设 $\nabla^2 f_0(\mathbf{x})$ Lipschitz 连续

- 若 $\|\nabla f_0(\mathbf{x}^{(k)})\|_2 > \eta$, 阻尼(damped)牛顿段
用 Armijo Rule 算步长, $\exists \gamma > 0, f_0(\mathbf{x}^{(k+1)}) - f_0(\mathbf{x}^{(k)}) \leq -\gamma$
- 若 $\|\nabla f_0(\mathbf{x}^{(k)})\|_2 \leq \eta$, 纯牛顿段
 $\alpha = 1, f_0(\mathbf{x}^{(k+1)}) - f_0(\mathbf{x}^*) \leq \Delta(\frac{1}{2})^{2^k}, \exists \Delta > 0$, 超线性收敛

多了二阶信息, 往最优解跑的速度会越来越快

例 39.

$$\begin{aligned} \min \quad & \frac{1}{2} \mathbf{x}^T P \mathbf{x} + \mathbf{q}^T \mathbf{r} + c \\ \text{s.t.} \quad & P \succ 0 \end{aligned}$$

分析. 对于二阶强凸问题, 只需1步到达最优解; 但用梯度下降法, 与条件数相关

与 Newton-Raphson 算法的联系, 将其扩展至高维的凸问题

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \frac{g(\mathbf{x}^{(k)})}{g'(\mathbf{x}^{(k)})}$$

6.4.2 拟牛顿法

拟牛顿法(quasi-Newton): 希望像一阶算法一样好算, 又像二阶算法一样收敛快

1. 构造 $(\nabla^2 f_0(\mathbf{x}^{(k)}))^{-1}$ 的近似矩阵 $G^{(k)}$ (直接的想法)
2. 构造 $\nabla^2 f_0(\mathbf{x}^{(k)})$ 的近似矩阵 $B^{(k)}$, 且容易求逆

在 $\mathbf{x} = \mathbf{x}^{(k+1)}$ 点处做 Taylor 展开

$$\begin{aligned} f_0(\mathbf{x}) &\approx f_0(\mathbf{x}^{(k+1)}) + \langle \nabla f_0(\mathbf{x}^{(k+1)}), \mathbf{x} - \mathbf{x}^{(k+1)} \rangle + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k+1)})^T \nabla^2 f_0(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)}) \\ \implies \nabla f_0(\mathbf{x}) &\approx \nabla f_0(\mathbf{x}^{(k+1)}) + \nabla^2 f_0(\mathbf{x}^{(k+1)}) (\mathbf{x} - \mathbf{x}^{(k+1)}) \\ \implies \nabla f_0(\mathbf{x}^{(k)}) &\approx \nabla f_0(\mathbf{x}^{(k+1)}) + \nabla^2 f_0(\mathbf{x}^{(k+1)}) (\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)}) \\ \implies \nabla f_0(\mathbf{x}^{(k)}) - \nabla f_0(\mathbf{x}^{(k+1)}) &\approx \nabla^2 f_0(\mathbf{x}^{(k+1)}) (\mathbf{x}^{(k)} - \mathbf{x}^{(k+1)}) \end{aligned}$$

$$\begin{cases} \mathbf{q}^{(k)} = \nabla f_0(\mathbf{x}^{(k+1)}) - \nabla f_0(\mathbf{x}^{(k)}) \\ \mathbf{p}^{(k)} = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)} \end{cases} \implies \begin{cases} \mathbf{q}^{(k)} = B^{(k+1)} \mathbf{p}^{(k)} \\ \mathbf{p}^{(k)} = G^{(k+1)} \mathbf{q}^{(k)} \end{cases}$$

1. 近似 $G^{(k)}$

$$G^{(k+1)} = G^{(k)} + \Delta G^{(k)}$$

- a. 秩1校正（希望 G 中不要有太多元素，故用低秩矩阵做近似）

$$\Delta G^{(k)} = \alpha^{(k)} \mathbf{z}^{(k)} (\mathbf{z}^{(k)})^T$$

$$\begin{aligned} \mathbf{p}^{(k)} &= G^{(k+1)} \mathbf{q}^{(k)} = G^{(k)} \mathbf{q}^{(k)} + \alpha^{(k)} \mathbf{z}^{(k)} (\mathbf{z}^{(k)})^T \mathbf{q}^{(k)} \\ \Rightarrow \Delta G^{(k)} &= \frac{(\mathbf{p}^{(k)} - G^{(k)} \mathbf{q}^{(k)}) (\mathbf{p}^{(k)} - G^{(k)} \mathbf{q}^{(k)})^T}{(\mathbf{q}^{(k)})^T (\mathbf{p}^{(k)} - G^{(k)} \mathbf{q}^{(k)})} \end{aligned}$$

稳定性很有问题，分母接近0的时候，越接近最优解越不稳定

- b. 秩2校正(Dandon-Fletcher-Power, DFP)

$$\Delta G^{(k)} = \frac{\mathbf{p}^{(k)} (\mathbf{p}^{(k)})^T}{(\mathbf{p}^{(k)})^T \mathbf{q}^{(k)}} - \frac{G^{(k)} \mathbf{q}^{(k)} (\mathbf{q}^{(k)})^T G^{(k)}}{(\mathbf{q}^{(k)})^T G^{(k)} \mathbf{q}^{(k)}}$$

前后项都为秩1矩阵，数值稳定性强

2. 近似 $B^{(k)}$ (Broyden-Fletcher-Goldfarb-Shermo, BFGS)

$$B^{(k+1)} = B^{(k)} + \frac{\mathbf{q}^{(k)} (\mathbf{q}^{(k)})^T}{(\mathbf{q}^{(k)})^T \mathbf{p}^{(k)}} - \frac{B^{(k)} \mathbf{p}^{(k)} (\mathbf{p}^{(k)})^T B^{(k)}}{(\mathbf{p}^{(k)})^T B^{(k)} \mathbf{p}^{(k)}}$$

- 拟牛顿法以后可能很有用，因为结合一二阶优化优点
- 找核心问题（Hessian矩阵难算），然后就去解决
- 用**结构信息**，都对结构进行限制（一股脑就用Adam优化器，这是不对的，要分析问题结构）

有限内存(limited memory)—LM-BFGS

6.5 有约束优化方法

$$\min \quad f_0(\mathbf{x})$$

$$\text{s.t.} \quad \mathbf{x} \in \mathcal{C}$$

可改写为

$$\min \quad f_0(\mathbf{x})$$

$$\text{s.t.} \quad A\mathbf{x} = \mathbf{b}$$

本质上都是在考虑它的KKT条件

$$\begin{cases} A\mathbf{x}^* = \mathbf{b} \\ \nabla f_0(\mathbf{x}^*) + A^T \mathbf{v}^* = 0 \end{cases}$$

例 40.

$$\begin{aligned} \min \quad & \frac{1}{2} \mathbf{x}^T P \mathbf{x} + \mathbf{q}^T \mathbf{x} + r, P \succeq 0 \\ \text{s.t.} \quad & A \mathbf{x} = \mathbf{b} \end{aligned}$$

分析. 等价于KKT条件

$$\begin{cases} A \mathbf{x}^* = \mathbf{b} \\ P \mathbf{x}^* + \mathbf{q} + A^T \mathbf{v}^* = 0 \end{cases}$$

等价于

$$\begin{bmatrix} P & A^T \\ A & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{x}^* \\ \mathbf{v}^* \end{bmatrix} = \begin{bmatrix} -\mathbf{q} \\ \mathbf{b} \end{bmatrix}$$

6.5.1 约束满足的牛顿法

若方程组非线性, 那就做一个线性化

$$\begin{aligned} \arg \min_{\mathbf{d}} \quad & f_0(\mathbf{x}^{(k)} + \mathbf{d}) = \mathbf{d}^{(k)} \\ \text{subject to} \quad & A(\mathbf{x}^{(k)} + \mathbf{d}) = \mathbf{b} \end{aligned}$$

近似等价于(二阶近似Taylor展开)

$$\begin{aligned} \arg \min_{\mathbf{d}} \quad & f_0(\mathbf{x}^{(k)}) + \langle \nabla f_0(\mathbf{x}^{(k)}), \mathbf{d} \rangle + \frac{1}{2} \mathbf{d}^T \nabla^T f_0(\mathbf{x}^{(k)}) \mathbf{d} = \mathbf{d}^{(k)} \\ \text{subject to} \quad & A(\mathbf{x}^{(k)} + \mathbf{d}) = \mathbf{b} \end{aligned}$$

写出问题关于 \mathbf{d} 的KKT条件, 可得等价条件

$$\begin{bmatrix} \nabla f_0(\mathbf{x}^{(k)}) & A^T \\ A & \mathbf{0} \end{bmatrix} \begin{bmatrix} \mathbf{d}^{(k)} \\ \mathbf{v}^{(k)} \end{bmatrix} = \begin{bmatrix} -\nabla f_0(\mathbf{x}^{(k)}) \\ \mathbf{b} - A \mathbf{x}^{(k)} \end{bmatrix}$$

若 $\mathbf{x}^{(0)}$ 可行, $A \mathbf{x}^{(0)} = \mathbf{b}$, 之后的 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha^{(k)} \mathbf{d}^{(k)}$ 也可行。

6.5.2 拉格朗日乘子法/对偶分解法

$$L(\mathbf{x}, \mathbf{v}) = f_0(\mathbf{x}) + \langle A \mathbf{x} - \mathbf{b}, \mathbf{v} \rangle$$

更新原变量和对偶变量

$$\begin{cases} \mathbf{x}^{(k+1)} = \arg \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{v}^{(k)}) \\ \mathbf{v}^{(k+1)} = \mathbf{v}^{(k)} + \alpha^{(k)} (A \mathbf{x}^{(k+1)} - \mathbf{b}) \end{cases}$$

$\alpha^{(k)}$ 可以是固定步长, 也可以是递减步长

即为找鞍点， x 方向上找最小值，本来 \mathbf{v} 方向上要找最大值，但容易到正无穷。因此换种方法 $\mathbf{v}^{(k)}$ 做一个保守的计算，每一步都走一个很小的步长。

例 41.

$$\begin{aligned} \min \quad & \frac{1}{2}x^2 \\ \text{s.t.} \quad & x = 1 \end{aligned}$$

分析.

$$\begin{aligned} L(x, v) &= \frac{1}{2}x^2 + v(x - 1) \\ &= \frac{1}{2}x^2 + vx - v \end{aligned}$$

6.6 对偶次梯度法

\mathbf{v} 才是最关键的，只是在寻找最优 \mathbf{v} 的时候顺带找到了 \mathbf{x} （收敛到 \mathbf{v}^* 的同时也找到了 \mathbf{x}^* ）

$$D(\mathbf{v}) = \inf_{\mathbf{x}} L(\mathbf{x}, \mathbf{v})$$

$D(\mathbf{v})$ 为凹函数，关注 $-D(\mathbf{v})$

$$\begin{cases} \mathbf{x}^{(k+1)} = \arg \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{v}^{(k)}) \\ \mathbf{v}^{(k+1)} = \mathbf{v}^{(k)} - \alpha^{(k)}(-(A\mathbf{x}^{(k+1)}) - \mathbf{b}) \end{cases}$$

若 $f_0(\mathbf{x})$ 为凸，若 $\hat{\mathbf{x}} = \arg \min_{\mathbf{x}} L(\mathbf{x}, \hat{\boldsymbol{\lambda}})$ ，则 $-(A\hat{\mathbf{x}} - \mathbf{b})$ 为 $-D(\boldsymbol{\lambda})$ 在 $\hat{\boldsymbol{\lambda}}$ 的次梯度

$$\forall \mathbf{v} : -D(\boldsymbol{\lambda}) \geq -D(\hat{\boldsymbol{\lambda}}) + \langle \mathbf{v} - \hat{\boldsymbol{\lambda}}, g(\hat{\boldsymbol{\lambda}}) \rangle$$

$$\begin{aligned} D(\mathbf{v}) &= \inf_{\mathbf{x}} L(\mathbf{x}, \mathbf{v}) \\ &= \inf_{\mathbf{x}} f_0(\mathbf{x}) + \langle \mathbf{v}, A\mathbf{x} + \mathbf{b} \rangle \\ &\leq f_0(\hat{\mathbf{x}}) + \langle \mathbf{v}, A\hat{\mathbf{x}} - \mathbf{b} \rangle \\ &= f_0(\hat{\mathbf{x}}) + \langle \hat{\boldsymbol{\lambda}}, A\hat{\mathbf{x}} - \mathbf{b} \rangle + \langle \mathbf{v} - \hat{\boldsymbol{\lambda}}, A\hat{\mathbf{x}} - \mathbf{b} \rangle \\ &= D(\hat{\boldsymbol{\lambda}}) + \langle \mathbf{v} - \hat{\boldsymbol{\lambda}}, A\hat{\mathbf{x}} - \mathbf{b} \rangle \\ -D(\mathbf{v}) &\geq -D(\hat{\boldsymbol{\lambda}}) + \langle \mathbf{v} - \hat{\boldsymbol{\lambda}}, -(A\hat{\mathbf{x}} - \mathbf{b}) \rangle \end{aligned}$$

进而得到 $-(A\hat{\mathbf{x}} - \mathbf{b})$ 就是一个次梯度

这个算法一般来说性能不好，在机器学习里面很多时候都被乱用，有时候可以，有时候不行。

- 在什么情况下它是好用的？对偶函数是可微的，采用固定步长。
- 对偶函数 $D(\mathbf{v})$ 何时可微？任何 $-D(\boldsymbol{\lambda})$ 都具有 $-(A\hat{\mathbf{x}} - \mathbf{b})$ 的形式，得到当 $f_0(\mathbf{x})$ 严格凸时， $f_0(\mathbf{x}) + \langle \hat{\boldsymbol{\lambda}}, A\mathbf{x} - \mathbf{b} \rangle$ 严格凸，进而 $D(\mathbf{v})$ 可微

6.6.1 原对偶次梯度法

计算量出在 $\mathbf{x}^{(k+1)}$ ，那么想办法近似

$$\begin{cases} \mathbf{x}^{(k+1)} &= \mathbf{x}^{(k)} - \alpha^{(k)} \partial_x L(\mathbf{x}, \mathbf{v}^{(k)}) \\ \mathbf{v}^{(k+1)} &= \mathbf{v}^{(k)} + \alpha^{(k)} \partial_v L(\mathbf{x}^{(k+1)}, \mathbf{v}) \\ &= \mathbf{v}^{(k)} + \alpha^{(k)} (A\mathbf{x}^{(k+1)} - \mathbf{b}) \end{cases}$$

$\mathbf{v}^{(k+1)}$ 需要等待 $\mathbf{x}^{(k+1)}$ ，将其换成下式可以不用等待

$$\mathbf{v}^{(k)} + \alpha^{(k)} (A\mathbf{x}^{(k)} - \mathbf{b})$$

由于两个方向都不精确，故收敛性质糟糕。

6.6.2 增广(augmented)拉格朗日法

当函数不是严格凸时，依然能得到很好的效果

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) \\ \text{s.t.} \quad & A\mathbf{x} = \mathbf{b} \end{aligned}$$

$$L(\mathbf{x}, \mathbf{v}) = f_0(\mathbf{x}) + \langle \mathbf{v}, A\mathbf{x} - \mathbf{b} \rangle = f_0(\mathbf{x}) + \mathbf{v}^T (A\mathbf{x} - \mathbf{b})$$

增广拉格朗日函数

$$L_c(\mathbf{x}, \mathbf{v}) = f_0(\mathbf{x}) + \langle \mathbf{v}, A\mathbf{x} - \mathbf{b} \rangle + \frac{c}{2} \|A\mathbf{x} - \mathbf{b}\|^2, c > 0$$

增广拉格朗日函数是下面问题的拉格朗日函数

$$\begin{aligned} \min \quad & f_0(\mathbf{x}) + \frac{c}{2} \|A\mathbf{x} - \mathbf{b}\|^2 \\ \text{s.t.} \quad & A\mathbf{x} = \mathbf{b} \end{aligned}$$

两个问题的原对偶最优解相同

设 $(\mathbf{x}^*, \mathbf{v}^*)$ 为原问题最优解，分别有以下两个KTT条件

$$\begin{cases} A\mathbf{x}^* = \mathbf{b} \\ \left. \frac{\partial L(\mathbf{x}, \mathbf{v}^*)}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}^*} = 0 \end{cases} \quad \begin{cases} A\mathbf{x}^* = \mathbf{b} \\ \left. \frac{\partial L_c(\mathbf{x}, \mathbf{v}^*)}{\partial \mathbf{x}} \right|_{\mathbf{x}=\mathbf{x}^*} = 0 \end{cases}$$

对于原问题有

$$\left. \nabla_x (f_0(\mathbf{x}) + \langle \mathbf{v}^*, A\mathbf{x} - \mathbf{b} \rangle) \right|_{\mathbf{x}=\mathbf{x}^*} = 0$$

对于对偶问题有

$$\begin{aligned} & \nabla_x \left(f_0(\mathbf{x}) + \langle \mathbf{v}^*, A\mathbf{x} - \mathbf{b} \rangle + \frac{c}{2} \|A\mathbf{x} - \mathbf{b}\|^2 \right) \Big|_{\mathbf{x}=\mathbf{x}^*} \\ &= \nabla_x \left(\frac{c}{2} \|A\mathbf{x} - \mathbf{b}\|^2 \right) \Big|_{\mathbf{x}=\mathbf{x}^*} \quad \text{原问题最优解代入} \\ &= cA^T(A\mathbf{x}^* - \mathbf{b}) = 0 \end{aligned}$$

得到增广拉格朗日法的迭代格式

$$\begin{cases} \mathbf{x}^{(k+1)} = \arg \min_{\mathbf{x}} L_c(\mathbf{x}, \mathbf{v}^{(k)}) \\ \mathbf{v}^{(k+1)} = \mathbf{v}^{(k)} + c(A\mathbf{x}^{(k+1)} - \mathbf{b}) \end{cases}$$

只要原问题是凸问题，无论 c 怎么取（ c 刚好就是固定步长），该算法总是可以收敛（不考虑计算精度的问题），只是收敛速度不同

例 42.

$$\begin{aligned} \min \quad & \frac{1}{2}x_1^2 + \frac{1}{2}x_2^2 \\ \text{s.t.} \quad & x_1 = 1 \end{aligned}$$

分析.

$$\begin{aligned} L(\mathbf{x}, v) &= \frac{1}{2}x_1^2 + \frac{1}{2}x_2^2 + v(x_1 - 1) \\ \frac{\partial L(\mathbf{x}, v^*)}{\partial \mathbf{x}} \Big|_{\mathbf{x}=\mathbf{x}^*} &= 0 = \begin{bmatrix} x_1 + v^* \\ x_2 \end{bmatrix} \end{aligned}$$

增广拉格朗日法

$$\begin{aligned} L_{c^{(k)}}(\mathbf{x}, v) &= \frac{1}{2}x_1^2 + \frac{1}{2}x_2^2 + v(x_1 - 1) + \frac{c^{(k)}}{2}(x_1 - 1)^2 \\ \mathbf{x}^{(k+1)} &= \arg \min L_{c^{(k)}}(\mathbf{x}, v^{(k)}) \\ \begin{cases} x_1 + v^{(k)} + c^{(k)}(x_1 - 1) = 0 \\ x_2 = 0 \end{cases} &\implies \mathbf{x}^{(k+1)} = \begin{bmatrix} \frac{c^{(k)} - v^{(k)}}{c^{(k)} + 1} \\ 0 \end{bmatrix} \\ v^{(k+1)} &= v^{(k)} + c^{(k)}(x_1^{(k+1)} - 1) \\ &= v^{(k)} + c^{(k)} \left(\frac{c^{(k)} - v^{(k)}}{c^{(k)} + 1} - 1 \right) \\ &= \frac{v^{(k)}}{c^{(k)} + 1} - \frac{c^{(k)}}{c^{(k)} + 1} \\ v^{(k+1)} - v^* &= v^{(k+1)} + 1 = \frac{v^{(k)}}{c^{(k)} + 1} + \frac{1}{c^{(k)} + 1} = \frac{v^{(k)} - v^*}{c^{(k)} + 1} \end{aligned}$$

可以看出取一个固定步长，且大于零，增广拉格朗日的收敛是非常好的（线性收敛）

对于特殊的一些非凸问题，增广拉格朗日也是有效的，如把问题改成

$$\min \left(-\frac{1}{2}x_1^2 + \frac{1}{2}x_2^2 \right)$$

6.6.3 交替方向乘子法

交替方向乘子法(alternating direction method of multipliers, ADMM)同样探究有结构的优化问题。

$$\begin{aligned} \min_{\mathbf{x}, \mathbf{y}} \quad & f(\mathbf{x}) + g(\mathbf{y}) \\ \text{s.t.} \quad & A\mathbf{x} + B\mathbf{y} = 0 \end{aligned}$$

考虑增广拉格朗日函数

$$\begin{aligned} L_c(\mathbf{x}, \mathbf{y}, \mathbf{v}) &= f(\mathbf{x}) + g(\mathbf{y}) + \langle \mathbf{v}, A\mathbf{x} + B\mathbf{y} \rangle + \frac{c}{2} \|A\mathbf{x} + B\mathbf{y}\|_2^2 \\ &= f(\mathbf{x}) + g(\mathbf{y}) + \frac{c}{2} \left(\left\| A\mathbf{x} + B\mathbf{y} + \frac{\mathbf{v}}{c} \right\|_2^2 - \left\| \frac{\mathbf{v}}{c} \right\|_2^2 \right) \end{aligned}$$

若直接用下面的迭代格式

$$\begin{cases} (\mathbf{x}^{(k+1)}, \mathbf{y}^{(k+1)}) = \arg \min_{\mathbf{x}, \mathbf{y}} L_c(\mathbf{x}, \mathbf{y}, \mathbf{v}^{(k)}) \\ \mathbf{v}^{(k+1)} = \mathbf{v}^{(k)} + c(A\mathbf{x}^{(k+1)} + B\mathbf{y}^{(k+1)}) \end{cases}$$

由于在 $\|A\mathbf{x} + B\mathbf{y}\|_2^2$ 中， \mathbf{x} 和 \mathbf{y} 结合在一起，不好优化，故用交替的方法（选主元）来解决

$$\begin{cases} \mathbf{x}^{(k+1)} = \arg \min_{\mathbf{x}} L_c(\mathbf{x}, \mathbf{y}^{(k)}, \mathbf{v}^{(k)}) \\ \quad = \arg \min_{\mathbf{x}} f(\mathbf{x}) + \langle \mathbf{v}^{(k)}, A\mathbf{x} \rangle + \frac{c}{2} \|A\mathbf{x} + B\mathbf{y}^{(k)}\|_2^2 \\ \quad \iff \arg \min_{\mathbf{x}} f(\mathbf{x}) + \frac{c}{2} \|A\mathbf{x} + B\mathbf{y}^{(k)} + \frac{\mathbf{v}^{(k)}}{c}\|_2^2 \quad \text{配方, 关于}\mathbf{y}^{(k)}\text{的项为常数项, 可忽略} \\ \mathbf{y}^{(k+1)} = \arg \min_{\mathbf{y}} L_c(\mathbf{x}^{(k+1)}, \mathbf{y}, \mathbf{v}^{(k)}) \\ \quad \iff \arg \min_{\mathbf{y}} g(\mathbf{y}) + \frac{c}{2} \|A\mathbf{x}^{(k+1)} + B\mathbf{y} + \frac{\mathbf{v}^{(k)}}{c}\|_2^2 \\ \mathbf{v}^{(k+1)} = \mathbf{v}^{(k)} + c(A\mathbf{x}^{(k+1)} + B\mathbf{y}^{(k+1)}) \end{cases}$$

两块的算法依然具有很好的收敛性，但是多块的交替方向乘子法不一定可以收敛。

例 43 (LASSO).

$$\min \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2 + p \|\mathbf{x}\|_1$$

分析. 对原问题进行变形，等价于下述约束问题

$$\begin{aligned} \min \quad & \frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2 + p \|\mathbf{y}\|_1 \\ \text{s.t.} \quad & \mathbf{x} - \mathbf{y} = 0 \end{aligned}$$

构造增广拉格朗日函数

$$L_c(\mathbf{x}, \mathbf{y}, \mathbf{v}) = \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 + p \|\mathbf{y}\|_1 + \mathbf{v}^T(\mathbf{x} - \mathbf{y}) + \frac{c}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$

可以得到交替方向乘子法的迭代格式

$$\begin{cases} \mathbf{x}^{(k+1)} = \arg \min_{\mathbf{x}} L_c(\mathbf{x}, \mathbf{y}^{(k)}, \mathbf{v}^{(k)}) \\ \mathbf{y}^{(k+1)} = \arg \min_{\mathbf{y}} L_c(\mathbf{x}^{(k+1)}, \mathbf{y}, \mathbf{v}^{(k)}) \\ \mathbf{v}^{(k+1)} = \mathbf{v}^{(k)} + c(\mathbf{x}^{(k+1)} - \mathbf{y}^{(k+1)}) \end{cases}$$

对 $\mathbf{x}^{(k+1)}$ 展开并配方，并将非主元项忽略，可求得上式与下面的式子等价

$$\begin{cases} \mathbf{x}^{(k+1)} = \arg \min_{\mathbf{x}} \left(\frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_2^2 + \frac{c}{2} \left\| \mathbf{x} - \mathbf{y}^{(k)} + \frac{\mathbf{v}^{(k)}}{c} \right\|_2^2 \right) \\ \mathbf{y}^{(k+1)} = \arg \min_{\mathbf{y}} \left(p \|\mathbf{y}\|_1 + \frac{c}{2} \left\| \mathbf{x}^{(k+1)} - \mathbf{y} + \frac{\mathbf{v}^{(k)}}{c} \right\|_2^2 \right) \\ \mathbf{v}^{(k+1)} = \mathbf{v}^{(k)} + c(\mathbf{x}^{(k+1)} - \mathbf{y}^{(k+1)}) \end{cases}$$

对于 $\mathbf{x}^{(k+1)}$ ，可直接通过求梯度的方法得到显式解，得到

$$\mathbf{x}^{(k+1)} = (\mathbf{A}^T \mathbf{A} + c\mathbf{I})^{-1}(\mathbf{A}^T \mathbf{b} + c\mathbf{y}^{(k)} - \mathbf{v}^{(k)})$$


对于 $\mathbf{y}^{(k+1)}$ ，由于涉及一范数，故需要求次微分，设 $z_i = x_i^{(k+1)} + \frac{v_i^{(k)}}{c}$ ，可得到类似的软门限表达式

$$y_i = \begin{cases} z_i - \frac{p}{c} & z_i > \frac{p}{c} \\ 0 & z_i \in \left[-\frac{p}{c}, \frac{p}{c}\right] \\ z_i + \frac{p}{c} & z_i < -\frac{p}{c} \end{cases}$$

进而可以迭代求解。

7 大数据中的优化问题与算法

7.1 并行优化



$$\min_{\mathbf{x}} g(\mathbf{x}) + \sum_{i=1}^N f_i(\mathbf{x})$$

针对LASSO问题，每个人都有一个样本 (A_i, \mathbf{b}_i) ，最小化样本之和，以及正则化项

$$\begin{cases} (A_1, \mathbf{b}_1) \implies \frac{1}{2} \|\mathbf{A}_1 \mathbf{x} - \mathbf{b}_1\|_2^2 \\ \vdots \\ (A_n, \mathbf{b}_n) \implies \frac{1}{2} \|\mathbf{A}_n \mathbf{x} - \mathbf{b}_n\|_2^2 \\ g(\mathbf{x}) = v \|\mathbf{x}\|_1 \end{cases}$$

原问题即为

$$\min_x v \|\mathbf{x}\|_1 + \frac{c}{2} \left\| \begin{bmatrix} A_1 & \cdots & A_N \end{bmatrix} \mathbf{x} - \begin{bmatrix} \mathbf{b}_1 & \cdots & \mathbf{b}_N \end{bmatrix} \right\|_2^2$$

7.1.1 并行梯度下降法

$$\begin{cases} \mathbf{x}^{(k+\frac{1}{2})} = \mathbf{x}^{(k)} - \alpha \sum_{i=1}^N \nabla f_i(\mathbf{x}^{(k)}) \\ \mathbf{x}^{(k+1)} = \arg \min g(\mathbf{x}) + \frac{1}{2\alpha} \left\| \mathbf{x} - \mathbf{x}^{(k+\frac{1}{2})} \right\|_2^2 \end{cases}$$

计算简单，只需求梯度，但所有梯度类问题都依赖于条件数。通信开销大。

7.1.2 对偶分解法

$$\begin{aligned} \min \quad & \sum_{i=1}^N f_i(\mathbf{x}_i) + g(\mathbf{z}) \\ \text{s.t.} \quad & \mathbf{x}_i = \mathbf{z}, \forall i \end{aligned}$$

$$L(\mathbf{x}, \mathbf{z}, \mathbf{v}) = \sum_{i=1}^N f_i(\mathbf{x}_i) + g(\mathbf{z}) + \sum_{i=1}^N \langle \mathbf{v}_i, \mathbf{x}_i - \mathbf{z} \rangle$$

$$(\mathbf{x}^{(k+1)}, \mathbf{z}^{(k+1)}) = \arg \min_{\mathbf{x}, \mathbf{z}} L(\mathbf{x}, \mathbf{z}, \mathbf{v}^{(k)})$$

$$\implies \begin{cases} \mathbf{x}_i^{(k+1)} = \arg \min_{\mathbf{x}_i} f_i(\mathbf{x}_i) + \langle \mathbf{v}_i^{(k)}, \mathbf{x}_i - \mathbf{z} \rangle \\ \mathbf{z}^{(k+1)} = \arg \min_{\mathbf{z}} g(\mathbf{z}) - \sum_{i=1}^N \langle \mathbf{v}_i^{(k)}, \mathbf{z} \rangle \\ \mathbf{v}_i^{(k+1)} = \mathbf{v}_i^{(k)} + \alpha \langle \mathbf{x}_i^{(k+1)} - \mathbf{z}^{(k+1)}, \mathbf{v}_i^{(k)} \rangle \end{cases}$$

不依赖于条件数，但每一步都需要求解一个最优解，不一定好求。通信开销小，但拉格朗日类方法收敛性差。

7.1.3 增广拉格朗日函数

$$\sum_{i=1}^n f_i(\mathbf{x}_i) + g(\mathbf{z}) + \sum_{i=1}^n \langle \lambda_i, \mathbf{x}_i - \mathbf{z} \rangle + \frac{c}{2} \sum_{i=1}^n \|\mathbf{x}_i - \mathbf{z}\|^2$$

正则项会产生 \mathbf{x}_i 和 \mathbf{z} 的交叉项，不好处理


注意到 \mathbf{x}_i 之间是没有依赖的，故采用交替方向乘子法，加了增广项，可用固定步长达到最优解

$$\begin{cases} \mathbf{x}_i^{(k+1)} &= \arg \min f_0(\mathbf{x}_i) + \langle \lambda_i^{(k)}, \mathbf{x}_i \rangle + \frac{c}{2} \|\mathbf{x}_i - \mathbf{z}^{(k)}\|^2 \\ \mathbf{z}^{(k+1)} &= \arg \min g(\mathbf{z}) - \langle \sum_{i=1}^n \lambda_i^{(k)}, \mathbf{z} \rangle + \frac{c}{2} \sum_{i=1}^n \|\mathbf{x}_i^{(k+1)} - \mathbf{z}\|^2 \\ \lambda^{(k+1)} &= \lambda^{(k)} + c(\mathbf{x}_i^{(k+1)} - \mathbf{z}^{(k+1)}) \end{cases}$$

每次要多传一倍的变量，以通信量开销换性能提升

7.2 无中心分布式优化

考虑无向图



每个结点自己优化，协同决策

$$\min \sum_{i=1}^n f_i(\mathbf{x})$$

梯度下降法，但由于去中心， $\mathbf{x}^{(k)}$ 无处摆放

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha^{(k)} \sum_{i=1}^n \nabla f_i(\mathbf{x}^{(k)})$$

那就每一个点分配一个本地变量 \mathbf{x}_i ，对邻居的更新做一个加权平均

$$\mathbf{x}^{(k+1)} = \sum_{i=1}^n \omega_{ij} \mathbf{x}_j^{(k)} - \alpha^{(k)} \sum_{i=1}^n \omega_{ij} \nabla f_j(\mathbf{x}_j^{(k)})$$

其中

$$\begin{cases} \omega_{ij} \neq 0 & (i, j) \in E, i = j \\ \omega_{ij} = 0 & \text{otherwise} \end{cases}$$

$$W = [\omega_{ij}], W = W^T, W\mathbf{1} = \mathbf{1}$$

在不可信的系统里面，存在个人隐私等信息，故更激进些，采用自己的梯度进行更新（在本地进行梯度下降），在无人机系统中非常常见

$$\mathbf{x}_i^{(k+1)} = \sum_{i=1}^n \omega_{ij} \mathbf{x}_j^{(k)} - \alpha^{(k)} \nabla f_i(\mathbf{x}_i^{(k)})$$

非常糟糕的算法，如果采用固定步长，则找不到最优解

分析. 反证法, 假设 $\mathbf{x}_i^{(k)} \rightarrow \mathbf{x}^*$, 将 \mathbf{x}^* 代入

$$\mathbf{x}^* = \sum_{j=1}^n \omega_{ij} \mathbf{x}^* - \alpha \nabla f_i(\mathbf{x}^*) \iff \nabla f_i(\mathbf{x}^*) = 0$$

但原问题最优解

$$\sum_{i=1}^n \nabla f_i(\mathbf{x}^*) = 0$$

与上面的式子不等价

改成有约束优化的形式

$$\begin{aligned} \min \quad & \sum_{i=1}^n f_i(\mathbf{x}_i) \\ \text{s.t.} \quad & \mathbf{x}_1 = \mathbf{x}_2 = \cdots = \mathbf{x}_n \end{aligned}$$


写出拉格朗日函数, 对偶分解法

$$\sum_{i=1}^n f_i(\mathbf{x}_i) + \sum_{(i,j) \in E} \langle \boldsymbol{\lambda}_{ij}, \mathbf{x}_i - \mathbf{x}_j \rangle$$

别人的东西都在对偶变量中体现, 求同存异

$$\begin{cases} \mathbf{x}_i^{(k+1)} = \arg \min f_i(\mathbf{x}_i) + \sum_{(i,j) \in E} \langle \boldsymbol{\lambda}_{ij}^{(k)}, \mathbf{x}_i \rangle - \sum_{(j,i) \in E} \langle \boldsymbol{\lambda}_{ij}, \mathbf{x}_i \rangle \\ \boldsymbol{\lambda}_{ij}^{(k+1)} = \boldsymbol{\lambda}_{ij}^{(k)} + \alpha^{(k)} (\mathbf{x}_i^{(k+1)} - \mathbf{x}_j^{(k+1)}) - \sum_{(j,i) \in E} \langle \boldsymbol{\lambda}_{ij}^{(k)}, \mathbf{x}_i \rangle \end{cases}$$

依然要采用递减步长, 才能保证收敛



$$\begin{aligned} \min \quad & \sum_{i=1}^n f_i(\mathbf{x}_i) \\ \text{s.t.} \quad & \mathbf{x}_i = \mathbf{z}_{ij}, \forall (i,j) \in E \\ & \mathbf{x}_j = \mathbf{z}_{ji}, \forall (i,j) \in E \end{aligned}$$

可分线性约束, 进而可以用交替方向乘子法

$$\begin{aligned} \sum_{i=1}^n f_i(\mathbf{x}_i) + \sum_{(i,j) \in E} (\langle \boldsymbol{\alpha}_{ij}, \mathbf{x}_i - \mathbf{z}_{ij} \rangle + \langle \boldsymbol{\beta}_{ij}, \mathbf{x}_j - \mathbf{z}_{ji} \rangle) \\ + \sum_{(i,j) \in E} \frac{c}{2} (\|\mathbf{x}_i - \mathbf{z}_{ij}\|^2 + \|\mathbf{x}_j - \mathbf{z}_{ji}\|^2) \end{aligned}$$

$$\begin{cases} \mathbf{x}_i^{(k+1)} &= \arg \min f_i(\mathbf{x}_i) + \sum_{(i,j) \in E} \langle \alpha_{ij} k^{(k)} \mathbf{x}_i \rangle + \sum_{(i,j) \in E} \langle \beta_{ji}^{(k)}, \mathbf{x}_i \rangle \\ &+ \frac{c}{2} \sum_{(i,j) \in E} \|\mathbf{x}_i - \mathbf{z}_j^{(k)}\|^2 + \frac{c}{2} \sum_{(i,j) \in E} \|\mathbf{x}_i - \mathbf{z}_{ji}^{(k)}\|^2 \\ \mathbf{z}_j^{(k+1)} &= \dots \\ \alpha_{ij}^{(k+1)} &= \dots \\ \beta_{ij}^{(k+1)} &= \dots \end{cases}$$

7.3 有限和优化

n 个样本，每个样本为 $f_i(\mathbf{x})$

$$\min_{\mathbf{x}} \quad \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$$

等价于期望极小化问题

$$\min_{\mathbf{x}} \quad \mathbb{E}(f_i(\mathbf{x}, \xi))$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x}^{(k)})$$

将 k 改为 $i^{(k)}$ ，随机梯度下降(Stochastic gradient descent, SGD)，取了一个无偏的估计[Bottou, NIPS 2010]

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha^{(k)} \nabla f_{i^{(k)}}(\mathbf{x}^{(k)})$$

注意这里需要采用变步长，否则无法收敛到最优解

$$\begin{cases} \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha^{(k)} \nabla f_{i^{(k)}}(\mathbf{x}^{(k)}) \\ \mathbf{x}^* = \mathbf{x}^* - \alpha^{(k)} \nabla f_{i^{(k)}}(\mathbf{x}^*) \end{cases} \implies \nabla f_{i^{(k)}}(\mathbf{x}^*) = 0$$

若问题强凸， $O(\frac{1}{k}) \rightarrow O(\frac{1}{k})$ ；凸， $O(\frac{1}{\sqrt{k}}) \rightarrow O(\frac{1}{\sqrt{k}})$

梯度噪声的问题：选的随机梯度与真正的全梯度不同

7.4 方差消减

方差消减(Variance Reduction)：挑选样本数目增大时，方差会减小

1. 小批量(mini-batch)
2. SURG、SAG、SAGA

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \frac{\alpha}{n} \sum_{i=1}^n y_i^{(k)}$$

对于每一个样本都存储一个梯度值

$$y_i^{(k)} = \begin{cases} \nabla f_i(\mathbf{x}^{(k)}) & i = i^{(k)} \\ y_i^{(k-1)} & i \neq i^{(k)} \end{cases}$$

当时间足够长，每一个里面都存在最优梯度

$$\mathbf{x}^* = \mathbf{x}^* - \frac{\alpha}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x}^*)$$

相当于用空间换时间

7.5 深度神经网络

$$\min \sum_{i=1}^S E^{(i)}$$

其中，

$$E^{(i)} = \frac{1}{2} \left\| \mathbf{x}_n^{(i)} - Y^{(i)} \right\|^2$$

为损失函数， \mathbf{x}_n 为第 n 层的网络输出 $f_n(\mathbf{x}_{n-1}, \omega_n)$ ，与有限和优化问题相同

反向传播算法(Back propagation)：自底向上求出 E 相对于 \mathbf{x}_n 和 w_n 的梯度

$$\begin{cases} \frac{\partial E^{(i)}}{\partial \mathbf{x}_n^{(i)}} = \mathbf{x}_n^{(i)} - Y^{(i)} \\ \frac{\partial E^{(i)}}{\partial w_n} = \frac{\partial E^{(i)}}{\partial \mathbf{x}_n^{(i)}} \frac{\partial \mathbf{x}_n^{(i)}}{\partial w_n} = \frac{\partial E^{(i)}}{\partial \mathbf{x}_n^{(i)}} \frac{\partial f_n(\mathbf{x}_n^{(i)}, w_n)}{\partial w_n} \end{cases}$$

7.6 在线优化

在线优化(Online Learning)：样本不是已有的，而是依照时间给出的

$$\min \frac{1}{T} \sum_{t=1}^T f_t(\mathbf{x})$$

$$\mathbf{x}_{t+1} = \mathbf{x}_t - \alpha_t \nabla f_t(\mathbf{x}_t)$$

Regret分析：将当前值丢进下一刻的优化函数中，如果优化效果好，说明有预测能力

7.7 动态优化

动态优化问题

$$\min f_t(\mathbf{x})$$

$$\mathbf{x}_t = \mathbf{x}_{t-1} - \alpha \nabla f_t(\mathbf{x}_{t-1})$$

7.8 Nesterov加速

Nesterov加速 $\min f(\mathbf{x})$: $O\left(\frac{1}{k^2}\right)$

$$\begin{aligned}\mathbf{x}^{(k+1)} &= \mathbf{y}^{(k)} - \frac{1}{L} \nabla f(\mathbf{y}^{(k)}) \\ \mathbf{y}^{(k+1)} &= (1 - \gamma^{(k)}) \mathbf{x}^{(k+1)} + \gamma^{(k)} \mathbf{x}^{(k)} \\ \beta^{(k)} &= \frac{1 + \sqrt{1 + 4(\beta^{(k-1)})^2}}{2}, \beta^{(0)} = 0 \\ \gamma^{(k)} &= \frac{1 - \beta^{(k)}}{\beta^{(k+1)}}\end{aligned}$$

构造两个序列， \mathbf{y} 为辅助序列，利用问题本身历史信息，做一个凸组合（先跳一步，从 $\mathbf{y}^{(k)}$ 开始做梯度下降）。权重为 γ ，不同时刻权重不同，引入 β 系数。

Trick：为避免权重趋于0（ \mathbf{x} 和 \mathbf{y} 趋同），加速了 n 步后重新设置 β 为0。

梯度下降相当于对 f 做一个二阶近似，二阶Taylor展开。

$$\xrightarrow{\mathbf{x}^{(k)}} f(\mathbf{x}) \longrightarrow \nabla f(\mathbf{x}^{(k)})$$

Nesterov加速是针对确定性优化问题，而机器学习是随机优化问题。

A 矩阵微积分

A.1 基本矩阵知识

定义 23 (正定(positive definite)矩阵). 若矩阵 A 满足

$$\forall \mathbf{z} \neq 0: \mathbf{z}^T A \mathbf{z} > 0$$

则称 A 为正定矩阵。

定义 24 (合同(congruent)矩阵). 若存在可逆矩阵 C 使得 $C^T A C = B$, 则称 A 为 B 合同, 记作 $A \simeq B$

定义 25 (主子式). 从 n 阶矩阵中选取行号和列号相同的 i 列, 行列交汇处的元素形成的行列式称为 n 阶矩阵的一个 i 阶主子式。如果挑选 $1-i$ 行和 $1-i$ 列, 则成为该矩阵的 i 阶顺序主子式。

正定矩阵 A 的等价命题如下

- A 的所有顺序主子式均为正
- A 的所有主子式均为正
- A 的特征值均为正

定义 26 (向量范数). $\|\cdot\|$ 为范数需要满足以下三个条件

1. 数乘: $\|a\mathbf{x}\| = |a| \|\mathbf{x}\|$
 2. 零元: $\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0}$
 3. 三角不等式: $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$
- 0-范数: 非零元素数目, 是伪范数 (不符合第一个定义)
 - 1-范数: 绝对值之和
 - 2-范数: 欧几里得距离
 - p-范数: p 次方之和的 p 次根
 - 无穷范数: 最大值

定义 27 (Taylor 公式). 对 $f(\mathbf{x})$ 在点 \mathbf{x}_0 处展开有

$$f(\mathbf{x}) = f(\mathbf{x}_0) + (\mathbf{x} - \mathbf{x}_0)^T \nabla f(\mathbf{x}_0) + \frac{1}{2!} (\mathbf{x} - \mathbf{x}_0)^T \nabla^2(\mathbf{x})(\mathbf{x} - \mathbf{x}_0) + \cdots$$

A.2 实值函数对向量的导数

设 $f(\mathbf{x}) : \mathbb{R}^n \mapsto \mathbb{R}$, 劈形算子 ∇ 默认对 \mathbf{x} 求导, 可以得到以下公式。

1. $\nabla(\mathbf{v}^T \mathbf{x}) = \mathbf{v}$

分析. 展开, 对每一个元素讨论

$$\frac{\partial \mathbf{v}^T \mathbf{x}}{\partial x_i} = \frac{\partial \sum_{i=1}^n v_i x_i}{\partial x_i} = v_i$$

2. $\nabla \|\mathbf{x}\|_2^2 = \nabla(\mathbf{x}^T \mathbf{x}) = 2\mathbf{x}$

分析. 法一: 考虑每一元素

$$\frac{\partial \mathbf{x}^T \mathbf{x}}{\partial x_i} = \frac{\partial \sum_{i=1}^n x_i^2}{\partial x_i} = 2x_i$$

法二: 变量多次出现的求导法则, 下标 c 代表视为常数

$$\nabla(\mathbf{x}^T \mathbf{x}) = \nabla(\mathbf{x}_c^T \mathbf{x}) + \nabla(\mathbf{x}^T \mathbf{x}_c) = 2\nabla(\mathbf{x}_c^T \mathbf{x}) = 2\mathbf{x}_c = 2\mathbf{x}$$

3. $\nabla(\mathbf{x}^T A \mathbf{x}) = (A + A^T)\mathbf{x}$

分析. 变量多次出现的求导法则

$$\begin{aligned} LHS &= \nabla(\mathbf{x}_c^T A \mathbf{x}) + \nabla(\mathbf{x}^T A \mathbf{x}_c) \\ &= \nabla((A^T \mathbf{x}_c)^T \mathbf{x}) + \nabla((A \mathbf{x}_c)^T \mathbf{x}) \\ &= A^T \mathbf{x}_c + A \mathbf{x}_c \\ &= RHS \end{aligned}$$

4. $\nabla \left(\frac{1}{2} \|A\mathbf{x} - \mathbf{b}\|_2^2 \right) = A^T(A\mathbf{x} - \mathbf{b})$

分析. 法一: 展开括号, 逐一求导

$$\begin{aligned} LHS &= \frac{1}{2} (\nabla((A\mathbf{x} - \mathbf{b})^T (A\mathbf{x} - \mathbf{b}))) \\ &= \frac{1}{2} (\nabla(\mathbf{x}^T A^T A \mathbf{x}) - \nabla(\mathbf{x}^T A^T \mathbf{b}) - \nabla(\mathbf{b}^T A \mathbf{x}) + \nabla(\mathbf{b}^T \mathbf{b})) \\ &= \frac{1}{2} ((A^T A + (A^T A)^T) \mathbf{x} - A^T \mathbf{b} - A^T \mathbf{b}) \\ &= A^T(A\mathbf{x} - \mathbf{b}) \\ &= RHS \end{aligned}$$

法二: 线性变换的求导公式

$$\begin{aligned} LHS &= \frac{1}{2} A^T \nabla_{A\mathbf{x} - \mathbf{b}} \|A\mathbf{x} - \mathbf{b}\|_2^2 \\ &= A^T(A\mathbf{x} - \mathbf{b}) \\ &= RHS \end{aligned}$$

A.3 向量值函数对向量的导数

设 $\mathbf{f}: \mathbb{R}^n \mapsto \mathbb{R}^m$, 则劈形算子

$$\nabla_{\mathbf{x}} \mathbf{f} = \frac{\partial \mathbf{f}}{\partial \mathbf{x}} = \left[\frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right]_{ij} = \left[\frac{\partial f_i}{\partial x_j} \right]$$

得到一个 $m \times n$ 的矩阵, 即为雅可比(Jacobi)矩阵

1. $\nabla_{\mathbf{x}}(A\mathbf{x}) = A$

分析. 基于此式, 由乘法法则可以推出

$$\begin{aligned}\nabla \mathbf{x}^T \mathbf{x} &= (\nabla \mathbf{x}^T) \mathbf{x} + \mathbf{x}^T (\nabla \mathbf{x}) \\ &= (\nabla (I\mathbf{x})^T) \mathbf{x} + \mathbf{x}^T (\nabla I\mathbf{x}) \\ &= I\mathbf{x} + \mathbf{x}^T I \\ &= 2\mathbf{x}\end{aligned}$$

2. $\nabla^2 f = \nabla(\nabla f)$: Hessian矩阵

分析. *Hessian*矩阵其实是 \mathbf{x} 到 ∇f 的*Jacobi*矩阵

$$(\nabla^2 f)_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial \mathbf{x} \partial \mathbf{x}^T} = \frac{\partial^2 f}{\partial \mathbf{x}^T \partial \mathbf{x}}$$

B 参考资料

1. *Convex optimization*, Stephen Boyd and Lieven Vandenberghe
2. 凸优化 (2018年秋季-北京大学), <http://bicmr.pku.edu.cn/~wenzw/opt-2018-fall.html>
3. 机器学习中的矩阵/向量求导, <https://zhuanlan.zhihu.com/p/25063314>
4. 矩阵求导术, <https://zhuanlan.zhihu.com/p/24709748>