

# 最优化理论

陈鸿峥

2019.02\*

## 目录

1	简介	1
1.1	优化概述	1
1.2	分类	2
1.3	历史	2
2	凸集	3

## 1 简介

### 1.1 优化概述

优化(optimization): 从一个可行解的集合中寻找出最好的元素

- 优化变量  $\mathbf{x} \in \mathbb{R}^n$
- 目标/损失函数  $f_0: \mathbb{R}^n \mapsto \mathbb{R}$
- 不等式约束函数  $f_i: \mathbb{R}^n \mapsto \mathbb{R}$
- 等式约束函数  $h_j: \mathbb{R}^n \mapsto \mathbb{R}$
- 可行解  $\mathcal{S} = \{\mathbf{z} \mid f_i(\mathbf{z}) \leq 0, h_j(\mathbf{z}) = 0, i = 1, \dots, m, j = 1, \dots, p\}$
- 最优解  $\mathbf{x}^* \iff \forall \mathbf{z} \in \mathbb{R}^n, \mathbf{z} \in \mathcal{S}: f_0(\mathbf{z}) \geq f_0(\mathbf{x}^*)$ 
$$\begin{aligned} & \text{minimize} && f_0(\mathbf{x}) \\ & \text{subject to} && f_i(\mathbf{x}) \leq 0 && i = 1, \dots, m \\ & && h_j(\mathbf{x}) = 0 && j = 1, \dots, p \end{aligned}$$

例 1. • 最小二乘线性拟合 (凸问题)

---

\*Build 20190228

- 深度神经网络（非凸，见下）

$$\begin{aligned} \mathbf{x}_1^{(i)} &= f_1(\mathbf{x}_0^{(i)}, \mathbf{w}_1) \\ \dots &= \dots \\ \mathbf{x}_n^{(i)} &= f_n(\mathbf{x}_{n-1}^{(i)}, \mathbf{w}_n) \\ \min \sum_{i=1}^m (\mathbf{y}^{(i)} - \mathbf{x}_n^{(i)})^2 \end{aligned}$$

- 图像处理，自然图像通常都是分块光滑的，原图 $\Phi_0$ ，有噪声的新图 $\Phi$   
全变参( $TV$ , *Total Variation*)范数，计算图像每个像素点左侧和下侧的差异

$$\|\Phi\|_{TV} = \sum_y \sum_x \sqrt{(\Phi(x, y) - \Phi(x, y-1))^2 + (\Phi(x, y) - \Phi(x-1, y))^2}$$

可得优化目标：近似自然图像，而且跟原图不能差太远

$$\min(\|\Phi\|_{TV} + \lambda \|\Phi - \Phi_0\|_F^2)$$

- 推荐系统：*Netflix*问题  
矩阵横向为用户，纵向为电影，值为评分值(1~5)，问题是把矩阵补全，这样就可以做推荐了→低秩矩阵补全  
电影很多，但类型不多，关联关系有限→近似低秩<sup>1</sup>  
低秩本来需要最小化 $\mathbf{z}$ 的非零奇异值数目 $\|\mathbf{z}\|_0$ ，但是非凸的；转化为最小化和范数<sup>2</sup> $\|\mathbf{z}\|_*$

$$\begin{aligned} \min \quad & \|\mathbf{z}\|_* := \|\mathbf{z}\|_1 \\ s.t. \quad & \mathbf{z}_{ij} = \mathbf{M}_{ij}, (i, j) \in \Omega \end{aligned}$$

## 1.2 分类

- 线性规划/非线性规划
- 凸规划/非凸规划（更好的分类）

目标函数凸函数，可行解集为凸集则是凸优化，一般容易求解

## 1.3 历史

- Newton-Raphson算法：求零点，等价于求 $\min f^2(x)$
- Gauss-Seidel算法：求解线性方程组 $A\mathbf{x} = \mathbf{b}$ ，等价于求 $\min \|A\mathbf{x} - \mathbf{b}\|_2^2$
- Lagrange
- Kantorovich：苏联，线性规划，诺贝尔经济学奖

---

<sup>1</sup> $A$ 的秩等于非零奇异值 $\sqrt{\text{eig}(A^T A)}$ 数目

<sup>2</sup>矩阵所有奇异值之和

- Dantzig: 美国, 优化决策, 线性规划单纯形
- Von Neumann: 线性规划问题对偶理论
- Karmarkar: 80年代, 线性规划内点法
- Nesterov: 后80年代, 非线性凸优化内点法
- 现代: 并行、随机算法

## 2 凸集

定义 1. 一些集合概念如下

- 仿射集 (*affine set*)

$C$  为仿射集  $\iff$  过  $C$  内任意两点的直线都在  $C$  内

$$\iff \forall x_1, x_2 \in C, \theta \in \mathbb{R}, \theta x_1 + (1 - \theta)x_2 \in C$$

例 2. 用定义易证线性方程组的解集  $C = \{\mathbf{x} \mid A\mathbf{x} = \mathbf{b}\}$  是仿射集; 反过来, 每一个仿射集都可以用线性方程组的解集表示

- 仿射组合

$$\forall x_1, x_2, \dots, x_k \in C, \theta_1, \dots, \theta_k \in \mathbb{R}, \theta_1 + \dots + \theta_k = 1 : \theta_1 x_1 + \dots + \theta_k x_k \in C$$

- 仿射包 (*hull*): 所有仿射组合的集合

$$\text{aff } C := \{\theta_1 x_1 + \dots + \theta_k x_k \mid \forall x_1, \dots, x_k \in C, \theta_1 + \dots + \theta_k = 1\}$$

- 凸集 (*convex set*)

$C$  为凸集  $\iff$  过  $C$  内任意两点的线段都在  $C$  内

$$\iff \forall x_1, x_2 \in C, \theta \in [0, 1], \theta x_1 + (1 - \theta)x_2 \in C$$

- 凸组合

$$\forall x_1, x_2, \dots, x_k \in C, \theta_1, \dots, \theta_k \in [0, 1], \theta_1 + \dots + \theta_k = 1 : \theta_1 x_1 + \dots + \theta_k x_k \in C$$

- 凸包: 最小的凸集

$$\text{conv } C := \{\theta_1 x_1 + \dots + \theta_k x_k \mid \forall x_1, \dots, x_k \in C, \theta_1, \dots, \theta_k \in [0, 1], \theta_1 + \dots + \theta_k = 1\}$$

- 凸锥(*convex cone*)

$$\mathcal{C} \text{ 为凸锥} \iff \forall x_1, x_2 \in \mathcal{C}, \theta_1, \theta_2 \geq 0, \theta_1 x_1 + \theta_2 x_2 \in \mathcal{C}$$

除了空集的凸锥都得包含原点 (取  $\theta_1 = \theta_2 = 0$ )

- 凸锥组合/非负线性组合:

$$\forall x_1, x_2, \dots, x_k \in \mathcal{C}, \theta_1, \dots, \theta_k \geq 0: \theta_1 x_1 + \dots + \theta_k x_k \in \mathcal{C}$$

- 凸锥包: 类似前面定义

由上面的定义易知, 仿射组合/凸锥组合 (强条件) 一定是凸组合。

**定义 2** (超平面(hyperplane)与半空间(halfspace)). 超平面都是比原空间低一维

$$\{\mathbf{x} \mid \mathbf{a}^T \mathbf{x} = b, \mathbf{x}, \mathbf{a} \in \mathbb{R}^n, b \in \mathbb{R}, \mathbf{a} \neq 0\}$$

超平面将空间划分为两个部分, 即半空间

$$\{\mathbf{x} \mid \mathbf{a}^T \mathbf{x} \leq b, \mathbf{a} \neq 0\}$$

若方程特解为  $\mathbf{x}_0$ , 则  $\mathbf{a} \perp (\mathbf{x} - \mathbf{x}_0)$

**定义 3** (欧式球(Euclidean ball)).

$$B(x_c, r) = \{x \mid \|x - x_c\|_2 \leq r\}$$

范数(*norm*)球可类似定义

**定义 4** (椭球(ellipsoid)).

$$\varepsilon(x_c, P) = \{x \mid (x - x_c)^T P^{-1} (x - x_c) \leq 1\}, P \succ 0$$

其中  $P \succ 0$  代表  $P$  对称且正定 ( $P = P^T$ )

分析. 定义内积  $\langle x^T P^{-1} y \rangle$  (需证满足内积条件), 进而  $P$ -范数  $\|x\|_P := \sqrt{x^T P x}$  是范数, 而椭球不过是  $P$ -范数意义下的球, 由定理得椭球是凸的

**定义 5** (多面体(polyhedron)).

$$P = \{\mathbf{x} \mid \mathbf{a}_i^T \mathbf{x} \leq b_i, \mathbf{c}_j^T \mathbf{x} = d_j, i = 1, \dots, m, j = 1, \dots, p\}$$

**例 3.** • 空集、点、 $\mathbb{R}^n$  空间均为仿射

- 任意直线为仿射; 若过原点则为凸锥

- $\mathbb{R}^n$ 空间的子空间<sup>3</sup>为仿射和凸锥
- 超平面为仿射
- 半空间、欧式球、椭球、多面体为凸集

定义 6 (仿射函数).

$$f: \mathbb{R}^n \mapsto \mathbb{R}^m \quad f(\mathbf{x}) = A\mathbf{x} + \mathbf{b}, A \in \mathbb{R}^{m \times n}, \mathbf{b} \in \mathbb{R}^m$$

性质如下:

- $S \subset \mathbb{R}^n$ 为凸  $\implies f(S) = \{f(\mathbf{x}) \mid \mathbf{x} \in S\}$ 为凸
- $C \subset \mathbb{R}^m$ 为凸  $\implies f^{-1}(C) = \{\mathbf{x} \in \mathbb{R}^n \mid f(\mathbf{x}) \in C\}$ 为凸

例 4. 两个集合的和  $S_1 + S_2 = \{x + y \mid x \in S_1, y \in S_2\}$ 保凸

分析. 直积  $S_1 \times S_2 = \{(x, y) \mid x \in S_1, y \in S_2\}$ 显然可以保凸 (相当于在两个集合同时画线)

令  $A = \begin{bmatrix} I & I \end{bmatrix}, \mathbf{x} = \begin{bmatrix} x & y \end{bmatrix}^T, \mathbf{b} = 0$ , 由仿射函数性质知

---

<sup>3</sup>零元、加法封闭、数乘封闭