

线性代数笔记整理V2.2

陈鸿峥

2019.04*

目录

1	矩阵与线性方程组	2
1.1	基本概念	2
1.2	矩阵的逆	3
1.3	分块矩阵	6
1.4	行列式	7
2	向量空间	10
2.1	基本定义	10
2.2	四个基本子空间	11
2.3	线性变换	12
2.4	基、维度与秩	14
2.5	坐标系统	17
3	内积空间	19
3.1	基本定义	19
3.2	正交	19
3.3	正交矩阵	21
4	特征值与特征向量	22
4.1	基本定义	22
4.2	对角化	23
5	对称矩阵与二次型	26
5.1	谱分解	26
5.2	奇异值分解	27
5.3	二次型	28
5.4	带约束的最值问题	29

*Build 20190415

6	仿射空间	29
6.1	仿射组合与凸组合	29
6.2	超平面	30
6.3	多胞形	31
6.4	曲线和表面	32
7	拓展	33
7.1	线性模型与最小二乘	33
7.2	马尔可夫链	34
7.3	复数特征值	34
7.4	离散动力系统	34
7.5	估计特征值	34
7.6	傅里叶级数	35
7.7	统计学应用	35

1 矩阵与线性方程组

1.1 基本概念

在此仅罗列一些基本的知识点的名字，具体内容本文不作赘述.

1. 解线性方程组（高斯消元法）

2. 方程组无解、唯一解、多解的判断，与主元列、主元位置的关系

解的**存在性**：看每一列是否都有主元位置

解的**唯一性**：看有无自由变元（ $A\mathbf{x} = \mathbf{0}$ 是否有**非平凡解**同样看自由变元）

3. 齐次方程 $A\mathbf{x} = \mathbf{0}$ 解的参数表示

非齐次方程 $A\mathbf{x} = \mathbf{b}$ 解的形式为 $\mathbf{x} = \mathbf{p} + t\mathbf{v}, t \in \mathbb{R}$ ，即非齐通解=齐通解+非齐特解，但要注意首先得有解

这两种方程的具体比较见2.2节

4. 线性相关与线性无关

要判定一组向量是线性相关还是线性无关，即判断 $A\mathbf{x} = \mathbf{0}$ 是否有非平凡解

5. 基本矩阵运算（加减乘除、求逆、转置）

定义 1 (基本行变换/初等矩阵变换). 替换、交换、数乘

定义 2 (初等(elementary)矩阵). 对单位矩阵做一次基本行变换所得的矩阵.

下面是线性无关线性相关一些常见的结论.

定理 1. $S = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}, |S| > 1$

(a) S 线性相关，当且仅当至少有一向量可以表示为其他向量的线性组合（注意**不是每一个**）

(b) 若 S 线性相关, $\mathbf{v}_1 \neq 0$, 那么 $\exists \mathbf{v}_j, j > 1$ 可以被表示为 $\mathbf{v}_1, \dots, \mathbf{v}_{j-1}$ 的线性组合

(c) 若 S 的子集 S' 线性相关, 则 S 线性相关; 若 S 线性无关, 则 S' 线性无关 (注意关系不能颠倒)

(d) 初等行变换不改变列之间的线性相关关系

分析. 记 $A = [\mathbf{v}_1, \dots, \mathbf{v}_n]$, $B \sim A$ 为 A 的阶梯形

(a) 必要性: 即 $\exists c_1, \dots, c_n$ 不全为0, 使得 $c_1 \mathbf{v}_1 + \dots + c_n \mathbf{v}_n = \mathbf{0}$.

不妨设 $c_1 \neq 0$, 则 $\mathbf{v}_1 = (-\frac{c_2}{c_1})\mathbf{v}_2 + \dots + (-\frac{c_n}{c_1})\mathbf{v}_n$, 证毕.

充分性: 不妨设 $\mathbf{v}_1 = c_2 \mathbf{v}_2 + \dots + c_n \mathbf{v}_n$, 移项得 $(-1)\mathbf{v}_1 + c_2 \mathbf{v}_2 + \dots + c_n \mathbf{v}_n = \mathbf{0}$.

(b) 用((a))的结论, 设 $\mathbf{v}_p = c_1 \mathbf{v}_1 + \dots + c_{p-1} \mathbf{v}_{p-1} + c_{p+1} \mathbf{v}_{p+1} + \dots + c_n \mathbf{v}_n, p > 1$, 找出最大的 j 使得 $c_j \neq 0$ (\mathbf{v}_p 的系数 $c_p = -1$ 也计入), 进而 $c_1 \mathbf{v}_1 + \dots + c_j \mathbf{v}_j = \mathbf{0}$, 接下来证明方法与((a))相同, \mathbf{v}_j 即为所求.

(c) 因两者互为逆否命题, 故只用证前者, 而前者通过不断扩充 S' 并令扩充部分的权重全为0即可.

(d) $A\mathbf{x} = \mathbf{0}$ 与 $B\mathbf{x} = \mathbf{0}$ 有相同的解, 故线性相关关系不会改变.

1.2 矩阵的逆

如无特殊说明, 在本节中我们讨论的矩阵均为方阵.

定义 3 (逆). A 为 $n \times n$ 的矩阵, 若 $\exists C$ s.t. $CA = I_n, AC = I_n$, 则称 A 可逆.

注意: 在定义中要求左乘右乘都满足才说其可逆.

定理 2. A 是 $m \times n$ 矩阵, 若存在 $n \times m$ 矩阵 C 和 D 使得 $CA = I_n, AD = I_m$, 则 $m = n$ 且 $C = D$

分析. 这个定理告诉我们只有方阵才会存在逆, 下面来证明.

1° 证明若 $CA = I_n$, 则 $m \geq n$

因为 $CA\mathbf{x} = I_n \mathbf{x} = \mathbf{x} = \mathbf{0}$, 故 $A\mathbf{x} = \mathbf{0}$ 只有平凡解, 没有自由变元, 因此 $m \geq n$.

2° 证明若 $AD = I_m$, 则 $m \leq n$

因为 $AD\mathbf{b} = I_m \mathbf{b} = \mathbf{b}$, 也即 $\forall \mathbf{b} \in \mathbb{R}^m, A\mathbf{x} = \mathbf{b}$ 都有解 $\mathbf{x} = D\mathbf{b}$, 因此 $m \leq n$.

3° 由上分析知, $m = n$.

考虑乘积 CAD , 有 $CAD = (CA)D = I_n D = D = C(AD) = CI_m = C$, 故 $C = D$.

定理 3 (二阶矩阵的逆).

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \implies A^{-1} = \frac{1}{\det A} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}, \det A \neq 0$$

命题 1. 若 $A = BC$, B 可逆, 则 $\begin{bmatrix} B & A \end{bmatrix} \sim \begin{bmatrix} I & C \end{bmatrix}$

分析.

$$EB = I \implies E = B^{-1}$$

$$EA = C \implies B^{-1}A = C \iff A = BC$$

算法 1 (求逆).

$$\begin{bmatrix} A & I \end{bmatrix} \sim \begin{bmatrix} I & A^{-1} \end{bmatrix}$$

分析. 在命题1中令 $A \leftarrow I$, $B \leftarrow A$, $C \leftarrow A^{-1}$ 即可.

若令 $A^{-1} = [\mathbf{x}_1, \dots, \mathbf{x}_n]$, 那么也可以将上述求逆过程看成是解下面的这个方程组

$$A\mathbf{x}_1 = \mathbf{e}_1, \quad A\mathbf{x}_2 = \mathbf{e}_2, \quad \dots, \quad A\mathbf{x}_n = \mathbf{e}_n$$

其说明的是矩阵 A 乘上 A^{-1} 的第 i 列, 将得到 I_n 的第 i 列, 也即 \mathbf{e}_i .

虽然只是变换了视角, 但对于一些问题来说这种视角的变换是重要的.

定理 4 (可逆阵定理). 对于 $n \times n$ 矩阵 A , 下列说法均等价

- | | |
|---|--|
| (a) A 可逆 | (m) A 的列构成 \mathbb{R}^n 的一组基 |
| (b) $A \sim I_n$ | (n) $\text{Col } A = \mathbb{R}^n$ |
| (c) A 有 n 个主元位置 | (o) $\dim \text{Col } A = n$ |
| (d) $A\mathbf{x} = \mathbf{0}$ 只有平凡解 | (p) $\text{rank } A = n$ (满秩) |
| (e) A 的列线性无关 | (q) $\text{Nul } A = \{\mathbf{0}\}$ |
| (f) $\mathbf{x} \mapsto A\mathbf{x}$ 是单射 | (r) $\dim \text{Nul } A = 0$ |
| (g) $A\mathbf{x} = \mathbf{b}, \forall \mathbf{b} \in \mathbb{R}^n$ 至少有一解 | (s) 0 不是 A 的特征值 |
| (h) A 的列张成 \mathbb{R}^n | (t) $\det A \neq 0$ |
| (i) $\mathbf{x} \mapsto A\mathbf{x}$ 是满射 | (u) $(\text{Col } A)^\perp = \text{Nul } A^T = \{\mathbf{0}\}$ |
| (j) $\exists n \times n C \text{ s.t. } CA = I$ | (v) $(\text{Nul } A)^\perp = \text{Row } A = \mathbb{R}^n$ |
| (k) $\exists n \times n D \text{ s.t. } AD = I$ | (w) $\text{Row } A = \mathbb{R}^n$ |
| (l) A^T 可逆 | (x) A 有 n 个非零奇异值 |

算法 2 (LU分解). A 为 $m \times n$ 的矩阵, 则 A 一定可以被分解为 $A = LU$, 其中 L 为下三角矩阵, U 为上三角矩阵. 以下为步骤

1. 初等行变换 (只进行替换) 将 A 变成行阶梯形 U , 并记录每次 E_1, \dots, E_p
2. 则 $L = (E_p \cdots E_1)^{-1}$, 相当于将每次初等行变换逆过来, 并将矩阵直接重合即可

注意到LU分解与方阵求逆的方法基本相同, 但它适用于所有矩阵, 算是矩阵分解里最简单的一种了. 用LU分解解方程, 加法乘法计算量会降低不少 (因为只需回代).

命题 2 (消去律). 若 A 可逆, $AB = AC$, 则 $B = C$.

命题 3. 若 AB 可逆, 则 A, B 都可逆. 若 A 或 B 不可逆, 则 AB 不可逆.

分析. $C = AB \implies I = BC^{-1}A \implies A^{-1} = BC^{-1}$, B 同理. 而后面一句为前面一句的逆否命题, 故证毕.

定理 5. 上 (下) 三角矩阵的逆仍为上 (下) 三角

分析. 不妨设 A 为下三角矩阵, 则 $a_{ij} = 0, i \in \{1, \dots, n-1\}, j \in \{i+1, \dots, n\}$.

若 $j \neq n-1$, 注意到 $a_{(n-1)n} = 0$ 一定被包含在 A_{ji} 中, 且一定在 A_{ji} 的对角线上 (最右下角);

若 $j = n-1$, $a_{(n-1)(n-3)} = 0$ 一定被包含在 A_{ji} 中, 且也在 A_{ji} 对角线上 (右下角倒数第二个元素).

又注意到在 $a_{ij} = 0, i \in \{1, \dots, n-1\}, j \in \{i+1, \dots, n\}$ 的前提下, A_{ji} 一定为下三角矩阵, 由上分析知对角线上一定存在0元素, 故代数余子式 C_{ji} 为0. 进而伴随矩阵为下三角, 原矩阵的逆为下三角.

1.3 分块矩阵

需要知道矩阵乘法另外的表示方法

$$AB = A[\mathbf{b}_1, \dots, \mathbf{b}_n] = [A\mathbf{b}_1, \dots, A\mathbf{b}_n]$$

类似地，分块矩阵有

$$AB = [\mathbf{a}_1, \dots, \mathbf{a}_n] \begin{bmatrix} \mathbf{b}_1 \\ \vdots \\ \mathbf{b}_n \end{bmatrix} = \sum_{i=1}^n \mathbf{a}_i \mathbf{b}_i$$

注意区别正常的矩阵乘法（行乘列得到某一位置上的元素），分块矩阵乘法是列乘行得到矩阵。

分块矩阵的转置除了每一个矩阵转置外，大的矩阵内部也需要转，如

$$A = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \Rightarrow A^T = \begin{bmatrix} A_{11}^T & A_{21}^T \\ A_{12}^T & A_{22}^T \end{bmatrix}$$

分块矩阵求逆并不是每一块分别求逆简单合并即可，而是需要将逆设出来，乘开后通过对比系数来求。如下面定理6所示。

定理 6.

$$A = \begin{bmatrix} A_{11} & A_{12} \\ O & A_{22} \end{bmatrix} \Rightarrow A^{-1} = \begin{bmatrix} A_{11}^{-1} & -A_{11}^{-1} A_{12} A_{22}^{-1} \\ O & A_{22}^{-1} \end{bmatrix}$$

特别地，当 A_{12} 为0矩阵，该分块矩阵的逆可以变成各个矩阵分别求逆。实际上对于**对角矩阵**，其 k 次方都是主对角线上的元素直接取 k 次幂，求逆看成是 -1 次幂当然也成立，见推论1。

分析. 设 $B = \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix}$ ，且

$$\begin{bmatrix} A_{11} & A_{12} \\ O & A_{22} \end{bmatrix} \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} I_p & O \\ O & I_q \end{bmatrix}$$

乘开后对比系数有

$$A_{11}B_{11} + A_{12}B_{21} = I_p$$

$$A_{11}B_{12} + A_{12}B_{22} = O$$

$$A_{22}B_{21} = O$$

$$A_{22}B_{22} = I_q$$

由下往上回代即得结果。

推论 1. $A = \begin{bmatrix} B & O \\ O & C \end{bmatrix}$ ， B, C 均为方阵，则 A 可逆，当且仅当 B, C 都可逆。若 A 可逆，则 $A^{-1} = \begin{bmatrix} B^{-1} & O \\ O & C^{-1} \end{bmatrix}$

如求以下这个矩阵的逆就可以划分为对角矩阵后，直接对各块求逆合并.

$$\begin{bmatrix} 1 & 2 & 0 & 0 & 0 \\ 3 & 5 & 0 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 7 & 8 \\ 0 & 0 & 0 & 5 & 6 \end{bmatrix}$$

当然，分块也是需要技巧的，常常需要先观察矩阵的性质，再做出合理划分，见例1.

例 1.

$$A = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ 1 & 1 & 0 & & 0 \\ 1 & 1 & 1 & & 0 \\ \vdots & & & \ddots & \\ 1 & 1 & 1 & \cdots & 1 \end{bmatrix}, \text{ 证明 } B = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ -1 & 1 & 0 & & 0 \\ 0 & -1 & 1 & & 0 \\ \vdots & & \ddots & \ddots & \\ 0 & & \cdots & -1 & 1 \end{bmatrix} \text{ 为 } A \text{ 的逆}$$

分析. 递归定义分块矩阵: $A_{k+1} = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{v} & A_k \end{bmatrix}$, $B_{k+1} = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{w} & B_k \end{bmatrix}$, 并用数学归纳法可证.

定理 7. 两个上(下)三角矩阵的乘积仍为上(下)三角

分析. 不妨设两个矩阵 A, B 都为下三角, 且 $A = [a_{ij}], B = [b_{ij}], C = AB = [c_{ij}]$, 其中

$$c_{ij} = a_{i1}b_{1j} + a_{i2}b_{2j} + \cdots + a_{in}b_{nj}$$

当 $i < j$ 时, $a_{ij} = b_{ij} = 0$, 故(自行画图观察可得以下事实)

$$c_{ij} = \underbrace{a_{i1}}_{\neq 0} \underbrace{b_{1j}}_{=0} + \cdots + \underbrace{a_{ii}}_{\neq 0} \underbrace{b_{ij}}_{=0} + \underbrace{a_{i(i+1)}}_{=0} \underbrace{b_{(i+1)j}}_{=0} + \cdots + \underbrace{a_{ij}}_{=0} \underbrace{b_{jj}}_{\neq 0} + \cdots + \underbrace{a_{in}}_{=0} \underbrace{b_{nj}}_{\neq 0} = 0$$

定理 8 (舒尔(Schur)补). 若 A_{11} 可逆, 则

$$\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} = \begin{bmatrix} I & O \\ X & I \end{bmatrix} \begin{bmatrix} A_{11} & O \\ O & S \end{bmatrix} \begin{bmatrix} I & Y \\ O & I \end{bmatrix}$$

其中 $S = A_{22} - A_{21}A_{11}^{-1}A_{12}$ 称为 A_{11} 的舒尔补, $X = A_{21}A_{11}^{-1}$, $Y = A_{11}^{-1}A_{12}$.

分析. 类似定理6的方法, 乘开后通过对比系数可得.

1.4 行列式

命题 4 (行列式的基本运算).

1. $\det A^T = \det A$

2. $\det AB = (\det A)(\det B) = \det BA$
3. $\det A^{-1} = \frac{1}{\det A}$
4. $\det A^k = (\det A)^k$ (如果把矩阵的逆看成 -1 次幂, 那就是3式)
5. $\det rA = r^n \det A$

命题 5 (行列式基本行变换). 三种基本行变换与矩阵相同, 但替换不改变它的值, 交换乘 (-1) , 数乘乘 k .

定理 9 (拉普拉斯(Laplace)展开). A 为 $n \times n$ 的矩阵, 称 $C_{ij} = (-1)^{i+j} \det A_{ij}$ 为 (i, j) 的代数余子式, 其中 A_{ij} 是 A 删除第 i 行和第 j 列后剩下的矩阵.

对第 i 行展开有

$$\det A = \sum_{j=1}^n a_{ij} C_{ij}$$

对第 j 列展开有

$$\det A = \sum_{i=1}^n a_{ij} C_{ij}$$

特别地, 若 A 是三角矩阵, 则 $\det A =$ 主对角线上元素的积 (因对第一行或第一列展开, 形式不变).

定理 10 (克莱姆(Cramer)法则). $A\mathbf{x} = \mathbf{b}$, 则 $\mathbf{x}_i = \frac{\det A_i(\mathbf{b})}{\det A}$, 其中

$$\det A_i(\mathbf{b}) = \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{b} \swarrow^{\text{col } i} & \cdots & \mathbf{a}_n \end{bmatrix}$$

分析. 直接构造

$$AI_i(\mathbf{b}) = A \begin{bmatrix} \mathbf{e}_1 & \cdots & \mathbf{b} & \cdots & \mathbf{e}_n \end{bmatrix} = \begin{bmatrix} A\mathbf{a}_1 & \cdots & A\mathbf{b} & \cdots & A\mathbf{a}_n \end{bmatrix}$$

左右两边取 \det 得

$$\det AI_i(\mathbf{b}) = (\det A)(\det I_i(\mathbf{b})) = (\det A)\mathbf{x}_i = \det A_i(\mathbf{b})$$

定理 11. 若 A 可逆, 则 $A^{-1} = \frac{1}{\det A} \text{adj } A$, 其中共轭/伴随矩阵 $(\text{adj } A)_{ij} = C_{ji}$

注意: 共轭矩阵元素下标与代数余子式下标不同.

分析. 求逆算法换个角度思考, 记 $B = A^{-1}$ 的第 j 列为 \mathbf{b}_j , 则 $A\mathbf{b}_j = \mathbf{e}_j$,

又记第 i 个元素为 b_{ij} , 则由克莱姆法则, $b_{ij} = \frac{\det A_i(\mathbf{e}_j)}{\det A}$, 分子

$$\det A_i(\mathbf{e}_j) = (-1)^{j+i} \det A_{ji} = C_{ji}$$

(对第 i 列进行展开, 除了第 j 行为1, 其余行均为0), 得证.

定理 12 (行列式的线性性). 记 $T: \mathbb{R}^n \rightarrow \mathbb{R}$, $T(\mathbf{x}) = \det \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_{j-1} & \mathbf{x} & \mathbf{a}_{j+1} & \cdots & \mathbf{a}_n \end{bmatrix}$, 则 T 为线性变换.

注: 这里的线性性只是针对行列式中的一列可变来说的, 若整个行列式都可变, 则不一定有 $\det(A+B) = \det A + \det B$.

定理 13 (线性变换与体积变化). 线性变换 $T: \mathbb{R}^n \rightarrow \mathbb{R}^n$ 的标准矩阵为 A , S 是一块有限的区域, 那么

$$T(S) \text{ 的面积或体积} = |\det A| \cdot S \text{ 的面积或体积}$$

由此定理立得椭圆面积为 πab .

定理 14 (解析几何). 1. 相异两点 $A(x_1, y_1), B(x_2, y_2) \in \mathbb{R}^2$, 则直线 AB 的方程为 $\det \begin{bmatrix} 1 & x & y \\ 1 & x_1 & y_1 \\ 1 & x_2 & y_2 \end{bmatrix} = 0$

2. 过点 $A(x_1, y_1) \in \mathbb{R}^2$, 斜率为 k 的直线方程为 $\det \begin{bmatrix} 1 & x & y \\ 1 & x_1 & y_1 \\ 0 & 1 & k \end{bmatrix} = 0$

3. $A(x_1, y_1), B(x_2, y_2), C(x_3, y_3) \in \mathbb{R}^2$, 三角形 ABC 的面积为 $\frac{1}{2} \left| \det \begin{bmatrix} x_1 & y_1 & 1 \\ x_2 & y_2 & 1 \\ x_3 & y_3 & 1 \end{bmatrix} \right|$

分析. 实际上还有很多类似的结论, 在此不作赘述. 均是做基本行变换后展开即得证.

定理 15 (范德蒙(Vandermonde)矩阵).

$$V = \begin{bmatrix} 1 & \alpha_1 & \alpha_1^2 & \dots & \alpha_1^{n-1} \\ 1 & \alpha_2 & \alpha_2^2 & \dots & \alpha_2^{n-1} \\ 1 & \alpha_3 & \alpha_3^2 & \dots & \alpha_3^{n-1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \alpha_m & \alpha_m^2 & \dots & \alpha_m^{n-1} \end{bmatrix}$$

令首行为变量, 其他行为常量可得 $n-1$ 次多项式, 常被用于多项式插值. 当 $m=n$ 时它的行列式

$$\det(V) = \prod_{1 \leq i < j \leq n} (\alpha_j - \alpha_i)$$

分析. 从第 $n-1$ 列到第1列, 每一列乘上 $-\alpha_n$ 后加到后一列:

$$\begin{aligned}
 \det(V_n) &= \begin{vmatrix} 1 & \alpha_1 - \alpha_n & \alpha_1^2 - \alpha_1 \alpha_n & \cdots & \alpha_1^{n-2} - \alpha_1^{n-3} \alpha_n & \alpha_1^{n-1} - \alpha_1^{n-2} \alpha_n \\ 1 & \alpha_2 - \alpha_n & \alpha_2^2 - \alpha_2 \alpha_n & \cdots & \alpha_2^{n-2} - \alpha_2^{n-3} \alpha_n & \alpha_2^{n-1} - \alpha_2^{n-2} \alpha_n \\ \vdots & \vdots & \vdots & & \vdots & \vdots \\ 1 & \alpha_{n-1} - \alpha_n & \alpha_{n-1}^2 - \alpha_{n-1} \alpha_n & \cdots & \alpha_{n-1}^{n-2} - \alpha_{n-1}^{n-3} \alpha_n & \alpha_{n-1}^{n-1} - \alpha_{n-1}^{n-2} \alpha_n \\ 1 & 0 & 0 & \cdots & 0 & 0 \end{vmatrix} \\
 &= (-1)^{n+1} \begin{vmatrix} \alpha_1 - \alpha_n & \alpha_1(\alpha_1 - \alpha_n) & \cdots & \alpha_1^{n-3}(\alpha_1 - \alpha_n) & \alpha_1^{n-2}(\alpha_1 - \alpha_n) \\ \alpha_2 - \alpha_n & \alpha_2(\alpha_2 - \alpha_n) & \cdots & \alpha_2^{n-3}(\alpha_2 - \alpha_n) & \alpha_2^{n-2}(\alpha_2 - \alpha_n) \\ \vdots & \vdots & & \vdots & \vdots \\ \alpha_{n-1} - \alpha_n & \alpha_{n-1}(\alpha_{n-1} - \alpha_n) & \cdots & \alpha_{n-1}^{n-3}(\alpha_{n-1} - \alpha_n) & \alpha_{n-1}^{n-2}(\alpha_{n-1} - \alpha_n) \end{vmatrix} \quad \text{按最后一行展开} \\
 &= (-1)^{n+1} (\alpha_1 - \alpha_n)(\alpha_2 - \alpha_n) \cdots (\alpha_{n-1} - \alpha_n) \begin{vmatrix} 1 & \alpha_1 & \alpha_1^2 & \cdots & \alpha_1^{n-2} \\ 1 & \alpha_2 & \alpha_2^2 & \cdots & \alpha_2^{n-2} \\ 1 & \alpha_3 & \alpha_3^2 & \cdots & \alpha_3^{n-2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & \alpha_{n-1} & \alpha_{n-1}^2 & \cdots & \alpha_{n-1}^{n-2} \end{vmatrix} \\
 &= (\alpha_n - \alpha_1)(\alpha_n - \alpha_2) \cdots (\alpha_n - \alpha_{n-1}) \det(V_{n-1}) = \prod_{1 \leq i < j \leq n} (\alpha_j - \alpha_i)
 \end{aligned}$$

除了懂得用拉普拉斯展开外, 也要懂得通过基本行变换 (或列变换) 来计算行列式, 如例2.

例 2.

$$A = \begin{bmatrix} 1 & 1 & 1 & \cdots & 1 \\ 1 & 2 & 2 & \cdots & 2 \\ 1 & 2 & 3 & \cdots & 3 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 2 & 3 & \cdots & n \end{bmatrix} \implies \det A = 1$$

分析. 将每行乘 (-1) 后加到下一行, 最后只剩对角线上元素全为1.

2 向量空间

2.1 基本定义

定义 4 (向量空间/线性空间). 给定一个域 F^1 , 若对一个非空集合 V 满足以下十条公理, 则称 V 为 F 上的向量空间:

1. 定义两种运算 $+$ 和 \cdot . $\langle V, +, \cdot \rangle$ 加法是 $V \times V$ 到 V 的一个映射, 数乘是 $F \times V$ 到 V 的一个映射

注: 在说明一个集合构成一个向量空间时, 一定要指出域是什么, 向量加法是怎么定义的, 数乘是怎么定义的, 否则一切都只是空中楼阁.

¹参见[https://en.wikipedia.org/wiki/Field_\(mathematics\)](https://en.wikipedia.org/wiki/Field_(mathematics))

2. 封闭性(对两种运算封闭)

3. V 的基本性质, 设 $u, v, w \in V$, c, d 为常数

(a) 零元 $u + 0 = u$

(b) 单位元 $1 \cdot u = u$

(c) 逆元 $u + (-u) = 0$

(d) 加法交换律 $u + v = v + u$ (暂不定义两向量相乘)

(e) 结合律 $(u + v) + w = u + (v + w), (cd)u = c(du)$

(f) 左右分配律 $c(u + v) = cu + cv, (c + d)u = cu + du$

要注意, 这里的向量空间实际上是很抽象的, F, V 可以是一些很奇怪的东西.

如度为 n 的多项式所构成的集合 \mathbb{P}_n , 有

$$\mathbf{p}(t) = a_0 + a_1t + a_2t^2 + \cdots + a_nt^n$$

的形式(这里的 t 虽然可以取任意值, 但在 $\{1, t, \dots, t^n\}$ 这组标准基下区别不同多项式的是前面的系数, 也即坐标向量. 故考虑其线性性时, 不是考虑 $\mathbf{p}(u+v)$, 而是考虑 $\mathbf{p}(t) + \mathbf{q}(t)$), 这个集合满足以上所有公理, 也被称为向量空间.

甚至于不用显式地表示出来的也可以算是向量空间, 如定义在 $[a, b]$ 上实值函数 f 的集合, 同样是一个向量空间.

2.2 四个基本子空间

定义 5 (子空间). 称 H 是 V 的子空间, 当 $\mathbf{u}, \mathbf{v} \in H$, 有:

1. $\mathbf{0} \in H$

2. $\mathbf{u} + \mathbf{v} \in H$

3. $c\mathbf{u} \in H$

注意: \mathbb{R}^2 并不是 \mathbb{R}^3 的子空间, 向量元素数目都不同, 但可以通过补0来达到目的.

定义 6 (基本子空间). A 为 $m \times n$ 的矩阵, 则列空间 $\text{Col } A$ 、行空间 $\text{Row } A$ 、零空间 $\text{Nul } A$ 、左零空间 $\text{Nul } A^T$ 称为 A 的基本子空间

我们先来探究 A 的零空间与列空间:

同时我们发现:

1. $\text{Nul } A = \{\mathbf{0}\}$ (A 的列线性无关) 当且仅当 $\mathbf{x} \mapsto A\mathbf{x}$ 是一一映射/单射

也说明 A 的每一列都为主元列(n 个), 并且 $m \geq n$, 无自由变元.

2. $\text{Col } A = \mathbb{R}^m$ 当且仅当 $\mathbf{x} \mapsto A\mathbf{x}$ 将 \mathbb{R}^n 映上/满射到 \mathbb{R}^m

也说明 A 的每一行都有主元位置(m 个), 并且 $m \leq n$, 可能存在自由变元.

需要注意:

Nul A	Col A
$\{\mathbf{x} : \mathbf{x} \in \mathbb{R}^n, A\mathbf{x} = \mathbf{0}\}$	$\{\mathbf{b} : \exists \mathbf{x} \in \mathbb{R}^n, A\mathbf{x} = \mathbf{b}\}$
隐性(implicit)定义	显性(explicit)定义
\mathbb{R}^n 的子空间	\mathbb{R}^m 的子空间
考虑有 n 个变量	考虑有 m 个方程
dim = 方程自由变量个数	dim = 主元列数
基得解出来才知道	基为原矩阵的主元列

1. 当 A 不是方阵时, Nul A 与Col A 是两个完全不同的空间; A 是方阵, 则有可能存在非零向量同时属于这两个空间
2. 基本行变换不会影响列之间的相关关系, 但会改变其列空间
3. 基本行变换不会改变其行空间, 阶梯形的非零行形成其行空间的一组基, 也是原矩阵行空间的一组基

分析. B 是由 A 经过行变换得来的矩阵, 则 B 的行是 A 的行的线性组合, 因此 B 的行的线性组合也一定是 A 的行的线性组合, 进而 $\text{Row } B \subset \text{Row } A$; 而行操作又是可逆的, 相反的操作可以说明 $\text{Row } A \subset \text{Row } B$, 因此 $\text{Row } A = \text{Row } B$.

若 B 是阶梯形, 它的非零行一定线性无关, 因为没有有一个非零行是它下面非零行的线性组合 (定理1(c)的逆否命题), 证毕.

定理 16.

$$(\text{Row } A)^\perp = \text{Nul } A, (\text{Col } A)^\perp = \text{Nul } A^T$$

分析. 若 $\mathbf{x} \in \text{Nul } A$, 由矩阵乘法, A 每一行与 \mathbf{x} 都正交, 而 A 的行张成 $\text{Row } A$, 因此 $\text{Nul } A \subset (\text{Row } A)^\perp$.

若 $\mathbf{x} \in (\text{Row } A)^\perp$, 则 \mathbf{x} 与 A 的每一行都正交, 进而 $\mathbf{x} \in \text{Nul } A$, 因此 $(\text{Row } A)^\perp \subset \text{Nul } A$.

故 $(\text{Row } A)^\perp = \text{Nul } A$. 最后令 $A \leftarrow A^T$ 代入即可得第二个结论.

关于四个基本子空间维度之间的关系, 见定理21.

2.3 线性变换

定义 7 (线性变换²). 若 $T: V \rightarrow W$ 满足

$$1. T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v})$$

$$2. T(c\mathbf{u}) = cT(\mathbf{u})$$

则称 T 为线性变换.

注意: 这里并不需要零元的定义, 即 $T(\mathbf{0}) = \mathbf{0} (*)$, 因线性变换保持数乘不变性, 这已经可以推出 $(*)$ 式

线性变换研究的是两个向量空间, 则更加抽象. 如对一个实值连续函数求导, 也可以算是一个线性变换.

²有些地方说线性映射(linear mapping)是从一个向量空间 V 到另一个向量空间 W 的映射且保持加法运算和数量乘法运算, 而线性变换(linear transformation)是线性空间 V 到其自身的线性映射. 但从国外的课本上看, 这两者并没有区分得特别清楚.

定理 17 (标准(standard)矩阵). 对于线性变换 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$, 存在唯一矩阵 A 使得

$$T(\mathbf{x}) = A\mathbf{x}, \forall \mathbf{x} \in \mathbb{R}^n$$

其中 A 是一个 $m \times n$ 的矩阵, 且

$$A = [T(\mathbf{e}_1) \quad \cdots \quad T(\mathbf{e}_n)]$$

称 A 为 T 的标准矩阵.

分析. 1° 存在性:

$$\begin{aligned} T(\mathbf{x}) &= T(x_1\mathbf{e}_1 + \cdots + x_n\mathbf{e}_n) \\ &= x_1T(\mathbf{e}_1) + \cdots + x_nT(\mathbf{e}_n) \\ &= [T(\mathbf{e}_1) \quad \cdots \quad T(\mathbf{e}_n)] \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \\ &= A\mathbf{x} \end{aligned}$$

2° 唯一性: 设存在另一矩阵 B 使得 $T(\mathbf{x}) = B\mathbf{x}, \forall \mathbf{x} \in \mathbb{R}^n$, 故 $A\mathbf{x} = B\mathbf{x}, \forall \mathbf{x} \in \mathbb{R}^n$, 令 $\mathbf{x} = \mathbf{e}_i$ 即得 $A = B$

这里需要注意几点:

1. 由矩阵乘向量的线性性知, 所有的矩阵变换都是线性变换.
2. 线性变换着重于映射的性质, 而矩阵变换则描述了该映射是怎么实施的.
3. 标准矩阵的唯一性是在确定了基的情况下才说的, 如上面的定理是标准基, 非标准基的情况请见定理40.

定义 8 (单射与满射). 线性变换 $T: V \rightarrow W$ 满足:

1. $\forall \mathbf{b} \in W$ 至多可以在 V 中找到一个原像 \mathbf{x} , 则称 T 单射 (即 $T(\mathbf{u}) = T(\mathbf{v}) \implies \mathbf{u} = \mathbf{v}$)
2. $\forall \mathbf{b} \in W$ 至少可以在 V 中找到一个原像 \mathbf{x} , 则称 T 满射
3. $\forall \mathbf{b} \in W$ 在 V 中都有且只有一个原像 \mathbf{x} , 则称 T 双射/一一映射, 称 V 和 W 同构, 记为 $V \cong W$.

定义 9 (核空间与值域空间). $T(\mathbf{x}) = \mathbf{0}$ 的解为 T 的核空间, $T(\mathbf{x}), \forall \mathbf{x}$ 的所有可能值构成 T 的值域空间, 分别对应着矩阵中的零空间和列空间.

定理 18. 线性变换 $T: V \rightarrow W$, $S = \{\mathbf{v}_1, \dots, \mathbf{v}_p\} \in V$, $S' = \{T(\mathbf{v}_1), \dots, T(\mathbf{v}_p)\} \in W$, U 是 V 的子空间

1. 若 S 线性相关, 则 S' 线性相关; 若 S' 线性无关, 则 S 线性无关
2. T 是单射, 若 S' 线性相关, 则 S 线性相关; 若 S 线性无关, 则 S' 线性无关
3. 若 S 为 U 的一组基, 则 S' 张成 $T(U)$
4. $V \cong W$, 若 S 是 V 的线性无关组 (生成集/基), 则 S' 是 W 的线性无关组 (生成集/基)
5. $V \cong W \iff \dim V = \dim W$
6. $T(U)$ 是 W 的子空间

7. $\dim T(U) \leq \dim U$, 当 T 为单射时取等

8. 核是定义域的子空间, 值域空间是对映域的子空间

分析. 1. 不妨设 $\mathbf{v}_p = c_1\mathbf{v}_1 + \cdots + c_{p-1}\mathbf{v}_{p-1}$, 则 $T(\mathbf{v}_p) = T(c_1\mathbf{v}_1 + \cdots + c_{p-1}\mathbf{v}_{p-1}) = c_1T(\mathbf{v}_1) + \cdots + c_{p-1}T(\mathbf{v}_{p-1})$, 说明 S' 也线性相关. 后者为前者的逆否命题, 易知成立.

2. 不妨设 $T(\mathbf{v}_p) = c_1T(\mathbf{v}_1) + \cdots + c_{p-1}T(\mathbf{v}_{p-1})$, 则 $c_1T(\mathbf{v}_1) + \cdots + c_{p-1}T(\mathbf{v}_{p-1}) = T(c_1\mathbf{v}_1 + \cdots + c_{p-1}\mathbf{v}_{p-1}) = T(\mathbf{v}_p)$. 又因 T 是单射, 故 $\mathbf{v}_p = c_1\mathbf{v}_1 + \cdots + c_{p-1}\mathbf{v}_{p-1}$, S 线性相关.

3. $\mathbf{y} \in T(U)$, $\exists T(\mathbf{x}) = \mathbf{y}$, 因 $\mathbf{x} \in U$, 所以 $\mathbf{x} = c_1\mathbf{v}_1 + \cdots + c_p\mathbf{v}_p$, 因 T 为线性, 故 $\mathbf{y} = T(\mathbf{x}) = c_1T(\mathbf{v}_1) + \cdots + c_pT(\mathbf{v}_p)$, 即可说明. (注意这里只能说明 $T(U)$ 的基在 S' 内, 而不能说明 S' 就是基)

4. 结合1,2,3即得证.

5. 结合4, S 为 V 的基, S' 为 W 的基, 都含有 p 个向量, 故维度相同.

6. (a) $\mathbf{0} \in U$, $T(\mathbf{0}) = \mathbf{0} \in T(U)$

(b) $\forall \mathbf{v}_1, \mathbf{v}_2 \in T(U)$, $\exists \mathbf{u}_1, \mathbf{u}_2 \in U$ s.t. $\mathbf{v}_1 = T(\mathbf{u}_1)$, $\mathbf{v}_2 = T(\mathbf{u}_2)$,
 $\therefore \mathbf{u}_1 + \mathbf{u}_2 \in U \quad \therefore T(\mathbf{u}_1 + \mathbf{u}_2) = T(\mathbf{u}_1) + T(\mathbf{u}_2) = \mathbf{v}_1 + \mathbf{v}_2 \in T(U)$

(c) $\forall \mathbf{v} \in T(U)$, $\exists \mathbf{u} \in U$ s.t. $\mathbf{v} = T(\mathbf{u})$,
 $\therefore c\mathbf{u} \in U \quad \therefore T(c\mathbf{u}) = cT(\mathbf{u}) = c\mathbf{v} \in T(U)$

7. 由定理20(d)知 $\dim T(U) \leq \dim U$. 若 S 为 U 的一组基, 则 S' 张成 $T(U)$, 又本题的题2证明了 S' 线性无关, 故 S' 为 $T(U)$ 的一组基, 故 $\dim T(U) = p = \dim U$

8. 记 T 的核为 $\ker T$, 显然 $\mathbf{0} \in \ker T$. 若 $\mathbf{u}, \mathbf{v} \in \ker T$, 即 $T(\mathbf{u}) = \mathbf{0}, T(\mathbf{v}) = \mathbf{0}$, 则 $T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}) = \mathbf{0} \implies \mathbf{u} + \mathbf{v} \in \ker T, T(c\mathbf{u}) = cT(\mathbf{u}) = \mathbf{0} \implies c\mathbf{u} \in \ker T$, 故核是定义域的子空间.

上面6中令 $U \leftarrow V$, 即得值域空间是对映域的子空间.

2.4 基、维度与秩

定义 10 (基). H 是向量空间 V 的子空间, $\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_p\}$ 满足以下两个条件:

1. \mathcal{B} 为线性无关集

2. $\text{Span}\{\mathbf{b}_1, \dots, \mathbf{b}_p\} = H$

则称 \mathcal{B} 是 H 的基. 换言之, 基是极大线性无关组, 也是极小生成集.

由条件2知 $\mathbf{b}_1, \dots, \mathbf{b}_p$ 都得在 H 中, 这个显然的结论看似没用, 但却是 \mathcal{B} 成为基的重要条件 (在后文证明施密特正交化 (算法4) 时也需要说明这一点).

如 $\mathbf{v}_1 = (1, 0, 1), \mathbf{v}_2 = (0, 1, 1), \mathbf{v}_3 = (0, 1, 0)$, 令 $H = \{(s, t, t) : s, t \in \mathbb{R}\}$, 有

$$\begin{bmatrix} s \\ t \\ t \end{bmatrix} = s \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} + (t - s) \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} + s \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

这里 $\mathbf{v}_1, \mathbf{v}_3 \notin H$, 其实 H 只是 $\text{Span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}$ 的子集, 故 $\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}$ 不能称为一组基.

定理 19 (生成集(Spanning set)). $S = \{\mathbf{v}_1, \dots, \mathbf{v}_p\}$ 是 V 中的集合, 令 $H = \text{Span}\{\mathbf{v}_1, \dots, \mathbf{v}_p\}$,

(a) 若 \mathbf{v}_k 是 S 中其余向量的线性组合, 则将 \mathbf{v}_k 移除, S 仍然张成 H

(b) 若 $H \neq \{\mathbf{0}\}$, 则 S 的某个子集是 H 的基

分析. 不妨设 \mathbf{v}_p 可以被其他向量线性表示, 则

$$\mathbf{v}_p = a_1 \mathbf{v}_1 + \dots + a_{p-1} \mathbf{v}_{p-1}$$

将上式代入下式, 可知将 \mathbf{v}_p 移除后, H 中的向量 \mathbf{x} 依然可以被其余 $p-1$ 个向量线性表示, 即 S 仍然张成 H

$$\mathbf{x} = c_1 \mathbf{v}_1 + \dots + c_p \mathbf{v}_p = (c_1 + a_1 c_p) \mathbf{v}_1 + \dots + (c_{p-1} + a_{p-1} c_p) \mathbf{v}_{p-1}$$

不断重复(a)的步骤, 删除线性相关的向量, 那么剩下的向量一定都线性无关, 且可张成 H , 故形成一组基

定义 11 (维度). 向量空间 V 的一组基中向量的个数定义为 V 的维度, 记为 $\dim V$

定义 12 (秩). 对于矩阵 A , 它的秩记为

$$\text{rank } A = \dim \text{Col } A$$

一般地, 对于一组向量集合, 它的秩是极大线性无关组中向量的数目

定理 20. 以下是关于基和维度的一些结论. 设 $S = \{\mathbf{v}_1, \dots, \mathbf{v}_n\} \in V$, $|S| \geq 1$, 且 S 为 V 的基

(a) 在 V 中任取 $p(p > n)$ 个向量, 一定线性相关

(b) 在 V 中任取 $p(p < n)$ 个向量, 一定不能张成 V

(c) V 的所有基都包含 n 个向量

分析. 由假设知 $\dim V = n$, 先将 S 与这 p 个向量改写成坐标向量后 (见 2.5 节), 构造 $n \times p$ 矩阵 A , A 的每一列即为这 p 个向量. 由 2.2 节的讨论知, 若 $n < p$, 则 A 一定存在自由变元, A 的列一定线性相关; 若 $n > p$, 则不能保证每一行都有主元位置, 进而不能张成 \mathbb{R}^n , 对应地也就不能张成 V . 因此, V 的所有基都包含 n 个向量. 直接推论是: 每一个 \mathbb{R}^n 的基都必须包含 n 个向量.

(d) H 是 V 的一个子空间, 则 H 内任一线性无关集都可以被拓展为 H 的一组基, 且 $\dim H \leq \dim V$ (基的存在性)

分析. 若 $H = \{\mathbf{0}\}$, 显然 $\dim H = 0 \leq \dim V$;

否则, 令 $S' = \{\mathbf{u}_1, \dots, \mathbf{u}_k\}$ 是 H 的一个线性无关集. 若 S' 张成 H , 则 S' 是 H 的一组基; 否则, $\exists \mathbf{u}_{k+1} \in H - \text{Span } S'$, 则 $\{\mathbf{u}_1, \dots, \mathbf{u}_k, \mathbf{u}_{k+1}\}$ 将线性无关. 继续这个过程, 可以不断扩展 S' 直至其能张成 H , 也即成为 H 的一组基. 但由 ((a)), S' 中向量的数量不能超过 $\dim V$. 综上, $\dim H \leq \dim V$.

(e) 任一 p 个元素的线性无关集或是可张成 V 的集合自动成为 V 的基

分析. 由((d)), 有 p 个元素的线性无关集 S' 可以被拓展成 V 的基, 但这组基一定得含 p 个元素, 因为 $\dim V = p$, 因此 S' 已经是 V 的基. 假设 S'' 有 p 个元素且可张成 V , 因为 $V \neq \{0\}$, 生成集定理告诉我们 S'' 的某一个子集 S^* 一定是 V 的基, 又因 $\dim V = p$, 所以 S^* 一定包含 p 个向量, 也即 $S^* = S''$.

(f) H 是 V 的 n 维子空间, 则 $H = V$

分析. 若 $\dim V = \dim H = 0$, 则 $V = H = \{0\}$;

若 $\dim V = \dim H > 0$, 则 H 存在一组基 S' 包含 n 个向量, 那么由((e)), S' 也是 V 的基, 因此 $H = V = \text{Span } S'$.

(g) \mathbb{P} 是无限维空间, $C(\mathbb{R})$ 为所有实值连续函数构成的空间, 也是无限维的

分析. 反证法, 假设 $\dim \mathbb{P} = k < \infty$, \mathbb{P}_n 是 \mathbb{P} 的子空间, $\dim \mathbb{P}_{k-1} = k$, 因此 $\dim \mathbb{P}_{k-1} = \dim \mathbb{P}$, 进而 $\mathbb{P}_{k-1} = \mathbb{P}$, 这显然不对, 如 $\mathbf{p}(t) = t^k$ 在 \mathbb{P} 内, 但不在 \mathbb{P}_{k-1} 内, 矛盾.

因 \mathbb{P} 是 $C(\mathbb{R})$ 的子空间, 若 $C(\mathbb{R})$ 为有限维, 则由((d)), \mathbb{P} 也是有限维的, 矛盾.

定理 21 (秩定理).

$$\text{rank } A + \dim \text{Nul } A = n$$

$$\dim \text{Row } A + \dim \text{Nul } A^T = m$$

分析. 由前面2.2节的讨论知道, 列空间的维度为主元列数, 加上零空间的维度为自由变量个数就等于总的列数.

例 3. 若一个非齐次线性方程组有6个方程8个未知数, 已知其有一个有2个自由变元的解, 则无论方程右侧的常数是什么, 该方程组总有解.

分析. $\dim \text{Nul } A = 2, \text{rank} = 8 - 2 = 6, \text{Col } A \in \mathbb{R}^6 \implies \text{Col } A = \mathbb{R}^6$

例 4. $A\mathbf{x} = \mathbf{b}, \forall \mathbf{b} \in \mathbb{R}^m$ 都有解 $\iff A^T \mathbf{x} = \mathbf{0}$ 只有平凡解

分析. $\text{rank } A = \dim \text{Col } A = \dim \text{Row } A = m \implies \dim \text{Nul } A^T = 0$

定理 22 (秩的进阶定理). A 是 $m \times n$ 矩阵, B 是 $n \times p$ 矩阵, 记 $\text{rank } A = r = r_1, \text{rank } B = r_2$, 有以下结论

(a) $\text{rank } AB \leq \text{rank } A, \text{rank } AB \leq \text{rank } B$

分析. 设 $\mathbf{y} \in \text{Col } AB$, 则 $\exists \mathbf{x} \text{ s.t. } \mathbf{y} = AB\mathbf{x}$, 而 $AB\mathbf{x} = A(B\mathbf{x}) = \mathbf{y}$, 因此 $\mathbf{y} \in \text{Col } A$, 故 $\text{Col } AB$ 为 $\text{Col } A$ 的子空间, 由定理20((d))知 $\text{rank } AB \leq \text{rank } A$.

又由秩定理, $\text{rank } AB = \text{rank}(AB)^T = \text{rank } B^T A^T \leq \text{rank } B^T = \text{rank } B$.

(b) P 是 $m \times m$ 可逆矩阵, Q 是 $n \times n$ 可逆矩阵, 则 $\text{rank } PA = \text{rank } AQ = \text{rank } A$

分析. 由(a)有 $\text{rank } PA \leq \text{rank } A = \text{rank}(P^{-1}P)A = \text{rank } P^{-1}(PA) \leq \text{rank } PA \implies \text{rank } PA = \text{rank } A$.

$\text{rank } AQ = \text{rank}(AQ)^T = \text{rank } Q^T A^T = \text{rank } A^T = \text{rank } A$.

(c) 若 $AB = O$, 则 $\text{rank } A + \text{rank } B \leq n$

分析. 由 $AB = O$ 知, B 的每一列都在 $\text{Nul } A$ 中, 故 $\text{Col } B$ 是 $\text{Nul } A$ 的子空间, 故 $\text{rank } B \leq \dim \text{Nul } A$.
 又由秩定理 $n = \text{rank } A + \dim \text{Nul } A \geq \text{rank } A + \text{rank } B$.

$$(d) \text{rank}(A + B) \leq \text{rank } A + \text{rank } B$$

分析. 引理: 一定存在秩分解 $A = CR$, 其中 C 是 $m \times r$ 矩阵, R 是 $r \times n$ 矩阵.

将 A, B 秩分解得 $A = C_1 R_1, B = C_2 R_2$, 构造 $m \times (r_1 + r_2)$ 矩阵 $C = \begin{bmatrix} C_1 & C_2 \end{bmatrix}$, 则

$$A + B = C_1 R_1 + C_2 R_2 = \begin{bmatrix} C_1 & C_2 \end{bmatrix} \begin{bmatrix} R_1 \\ R_2 \end{bmatrix} = CR$$

因 C 有 $r_1 + r_2$ 列, 故 $\text{rank } C \leq r_1 + r_2$, 同理 R 有 $r_1 + r_2$ 行, 故 $\text{rank } R \leq r_1 + r_2$, 进而 $\text{rank}(A + B) \leq r_1 + r_2 = \text{rank } A + \text{rank } B$.

(e) A 的秩为 r 当且仅当 A 包含一个 $r \times r$ 的子矩阵, 且没有更大的方阵是可逆的

分析. 1° 证明 A 一定有 $m \times r$ 且秩为 r 的子矩阵 A_1

令 A_1 包含 A 的 r 个主元列, 因这些列线性无关, 故 A_1 即为所求.

2° 证明 A_1 一定有 $r \times r$ 且可逆的子矩阵 A_2

$\text{rank } A_1 = \dim \text{Row } A_1 = r$, 令 A_2 包含 A_1 的 r 个线性无关的行, 则 A_2 即为所求, 且为方阵故可逆.

$$(f) \text{ 若 } C = \begin{bmatrix} A & O \\ O & B \end{bmatrix}, \text{ 则 } \text{rank } C = \text{rank } A + \text{rank } B$$

分析. 将 A, B 都写成阶梯形, 因分块矩阵其余位置都为 0, 故 C 此时也为阶梯形, C 的秩就等于 A, B 主元列之和.

2.5 坐标系统

定理 23 (向量唯一表示定理). $\mathcal{B} = \{b_1, \dots, b_p\}$ 是向量空间 V 的基, 则 $\forall \mathbf{x} \in V$, 存在唯一 c_1, \dots, c_p 使得 $\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_p \mathbf{b}_p$

分析.

$$0 = \mathbf{x} - \mathbf{x} = (c_1 - d_1) \mathbf{b}_1 + \dots + (c_p - d_p) \mathbf{b}_p$$

由基线性无关, 知上述方程只有平凡解.

定义 13 (坐标向量). $\mathcal{B} = \{b_1, \dots, b_p\}$ 是 H 的基, $\forall \mathbf{x} \in H$, $\mathbf{x} = c_1 \mathbf{b}_1 + \dots + c_p \mathbf{b}_p$, 则 \mathbf{x} 关于 \mathcal{B} 的坐标向量定义为

$$[\mathbf{x}]_{\mathcal{B}} := \begin{bmatrix} c_1 \\ \vdots \\ c_p \end{bmatrix}$$

坐标系统最大的用处是可以将向量空间 V 中奇奇怪怪的东西转换成 \mathbb{R}^n 中我们熟悉的向量, 求解坐标的过程实质上又是解线性方程组, 进而有如下定理.

定理 24 (坐标变换矩阵). 对于 V 的一组基 $\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_n\}$, 存在唯一 $n \times n$ 矩阵 $P_{\mathcal{B}}$ 使得

$$\mathbf{x} = P_{\mathcal{B}}[\mathbf{x}]_{\mathcal{B}}, \forall \mathbf{x} \in V$$

其中 $P_{\mathcal{B}} = [\mathbf{b}_1, \dots, \mathbf{b}_n]$ 称为坐标变换矩阵. 移项即可解出坐标,

$$[\mathbf{x}]_{\mathcal{B}} = P_{\mathcal{B}}^{-1}\mathbf{x}$$

定理 25 (换基). $\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_n\}, \mathcal{C} = \{\mathbf{c}_1, \dots, \mathbf{c}_n\}$ 都是向量空间 V 的基, 那么存在唯一的 $n \times n$ 矩阵 $P_{\mathcal{C} \leftarrow \mathcal{B}}$, 使得

$$[\mathbf{x}]_{\mathcal{C}} = P_{\mathcal{C} \leftarrow \mathcal{B}}[\mathbf{x}]_{\mathcal{B}}$$

其中 $P_{\mathcal{C} \leftarrow \mathcal{B}} = \begin{bmatrix} [\mathbf{b}_1]_{\mathcal{C}} & [\mathbf{b}_2]_{\mathcal{C}} & \cdots & [\mathbf{b}_n]_{\mathcal{C}} \end{bmatrix}$, 称为过渡矩阵.

算法 3 (在 \mathbb{R}^n 中换基). 要求 $P_{\mathcal{C} \leftarrow \mathcal{B}}$, 首先要将 \mathcal{B} 与 \mathcal{C} 之间的关系找到, 即用 \mathcal{C} 中的向量表示 \mathcal{B} 中的向量.

设坐标变换矩阵 $P_{\mathcal{C}} = [\mathbf{c}_1, \dots, \mathbf{c}_n]$, 进而 $\mathbf{b}_i = P_{\mathcal{C}}[\mathbf{b}_i]_{\mathcal{C}}$, 故

$$P_{\mathcal{B}} = P_{\mathcal{C}} P_{\mathcal{C} \leftarrow \mathcal{B}}$$

(注意矩阵下标) 由命题1, 可得以下过程

$$\begin{bmatrix} P_{\mathcal{C}} & P_{\mathcal{B}} \end{bmatrix} \sim \begin{bmatrix} I & P_{\mathcal{C} \leftarrow \mathcal{B}} \end{bmatrix}$$

或者 $P_{\mathcal{B}}[\mathbf{x}]_{\mathcal{B}} = \mathbf{x} = P_{\mathcal{C}}[\mathbf{x}]_{\mathcal{C}} \implies [\mathbf{x}]_{\mathcal{C}} = P_{\mathcal{C}}^{-1}P_{\mathcal{B}}[\mathbf{x}]_{\mathcal{B}} \implies P_{\mathcal{C} \leftarrow \mathcal{B}} = P_{\mathcal{C}}^{-1}P_{\mathcal{B}}$.

定理 26. 关于坐标变换 $T: \mathbf{x} \mapsto [\mathbf{x}]_{\mathcal{B}}$, 其中 $\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_n\}$, 有如下结论.

1. T 是一个双射的线性变换, \mathbf{x} 所处的空间 V 与 $[\mathbf{x}]_{\mathcal{B}}$ 所处的空间 \mathbb{R}^n 同构
2. $S = \{\mathbf{u}_1, \dots, \mathbf{u}_p\}$ 线性无关当且仅当 $S' = \{[\mathbf{u}_1]_{\mathcal{B}}, \dots, [\mathbf{u}_p]_{\mathcal{B}}\}$ 线性无关; S 线性相关当且仅当 S' 线性相关

分析. 1. 若 $[\mathbf{u}]_{\mathcal{B}} = [\mathbf{w}]_{\mathcal{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_n \end{bmatrix}$, 由坐标向量定义 $\mathbf{u} = \mathbf{w} = c_1\mathbf{b}_1 + \cdots + c_n\mathbf{b}_n$, 而 \mathbf{u}, \mathbf{w} 均为 V 中任意

元素, 故 T 为单射. 令 $\mathbf{y} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$, $\mathbf{u} = y_1\mathbf{b}_1 + \cdots + y_n\mathbf{b}_n$, 则由定义 $[\mathbf{u}]_{\mathcal{B}} = \mathbf{y}$, 因 \mathbf{y} 为 \mathbb{R}^n 任意向量,

故 T 为满射.

2. 由定理18易知.

3 内积空间

3.1 基本定义

定义 14 (内积空间). 线性空间 V 上的内积是一个函数 $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$, $\forall u, v, w \in V, c$ 为常数, 满足

1. $\langle \mathbf{u}, \mathbf{v} \rangle = \langle \mathbf{v}, \mathbf{u} \rangle$
2. $\langle \mathbf{u} + \mathbf{v}, \mathbf{w} \rangle = \langle \mathbf{u}, \mathbf{w} \rangle + \langle \mathbf{v}, \mathbf{w} \rangle$
3. $\langle c\mathbf{u}, \mathbf{v} \rangle = c\langle \mathbf{u}, \mathbf{v} \rangle$
4. $\langle \mathbf{u}, \mathbf{u} \rangle \geq 0$, 且 $\langle \mathbf{u}, \mathbf{u} \rangle = 0$ 当且仅当 $u = 0$

定义了内积的向量空间称为内积空间.

定义 15 (长度/模/范数). V 是一个内积空间, 则对于某一向量 $v \in V$ 的长度为 $\|v\| := \sqrt{\langle v, v \rangle}$.

注: 如无特殊说明, 下文在谈论到内积时都是指最简单不加权的内积, 即 $\langle \mathbf{u}, \mathbf{v} \rangle = \mathbf{u} \cdot \mathbf{v} = \mathbf{u}^T \mathbf{v}$.

3.2 正交

定义 16 (正交). 若 $\langle u, v \rangle = 0$, 则称 u, v 正交.

注: 与高中的定义不同, 这里我们可以说 $\mathbf{0}$ 与任意向量正交.

下面这些定理看似简单, 因为有二维三维空间的几何直观作为基础, 但拓展到高维空间这些定理是否还会成立呢? 我们不得而知, 因此还应从公理出发一一证明.

定理 27 (毕达哥拉斯(Pythagoras)定理). u, v 正交当且仅当 $\|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 = \|\mathbf{u} + \mathbf{v}\|^2$

定义 17. 设 W 是向量空间 V 的子空间, V 中与所有与 W 正交的向量构成的集合称为 W 的正交补, 记为 W^\perp .

以下有两条性质

1. $\mathbf{x} \in W^\perp \iff \mathbf{x}$ 与张成 V 的一组向量中的每一个都正交
2. W^\perp 是 V 的子空间

定理 28 (正交必线性无关). $S = \{\mathbf{u}_1, \dots, \mathbf{u}_p\}$ 是 V 的一个由非零向量构成的正交集, 那么 S 线性无关, 因此构成 $\text{Span } S$ 的基.

注: 一定要注意前提条件!!!

分析.

$$\mathbf{0} = c_1 \mathbf{u}_1 + c_2 \mathbf{u}_2 + \dots + c_p \mathbf{u}_p$$

$$\begin{aligned} 0 &= \langle \mathbf{0}, \mathbf{u}_1 \rangle = \langle c_1 \mathbf{u}_1 + c_2 \mathbf{u}_2 + \dots + c_p \mathbf{u}_p, \mathbf{u}_1 \rangle \\ &= \langle c_1 \mathbf{u}_1, \mathbf{u}_1 \rangle + \langle c_2 \mathbf{u}_2, \mathbf{u}_1 \rangle + \dots + \langle c_p \mathbf{u}_p, \mathbf{u}_1 \rangle \\ &= c_1 \langle \mathbf{u}_1, \mathbf{u}_1 \rangle + c_2 \langle \mathbf{u}_2, \mathbf{u}_1 \rangle + \dots + c_p \langle \mathbf{u}_p, \mathbf{u}_1 \rangle \\ &= c_1 \langle \mathbf{u}_1, \mathbf{u}_1 \rangle \end{aligned}$$

因为 $\mathbf{u}_1 \neq \mathbf{0}$, 所以 $c_1 = 0$. 类似地, 可以推出 $c_i = 0, i = 2, \dots, p$, 因此 S 线性无关.

定理 29 (正交分解). $\{\mathbf{u}_1, \dots, \mathbf{u}_p\}$ 是 V 的子空间 W 的一组正交基, 对于 $\mathbf{y} \in V$, 都可以唯一表示成 $\mathbf{y} = \hat{\mathbf{y}} + \mathbf{z}$, 其中 $\hat{\mathbf{y}} \in W, \mathbf{z} \in W^\perp$, 且

$$\hat{\mathbf{y}} = c_1 \mathbf{u}_1 + \dots + c_p \mathbf{u}_p$$

各项为

$$\hat{\mathbf{y}}_i = \text{proj}_{\mathbf{u}_i} \hat{\mathbf{y}} = c_i \mathbf{u}_i = \frac{\langle \hat{\mathbf{y}}, \mathbf{u}_i \rangle}{\langle \mathbf{u}_i, \mathbf{u}_i \rangle} \mathbf{u}_i = \frac{\langle \hat{\mathbf{y}}, \mathbf{u}_i \rangle}{\|\mathbf{u}_i\|} \frac{\mathbf{u}_i}{\|\mathbf{u}_i\|}, i = 1, \dots, p \quad (*)$$

注: 与选的基没有关系, 只和 W 有关.

分析. 类似定理 28 的证明有 $\langle \hat{\mathbf{y}}, \mathbf{u}_i \rangle = \langle c_1 \mathbf{u}_1 + c_2 \mathbf{u}_2 + \dots + c_p \mathbf{u}_p, \mathbf{u}_i \rangle = c_i \langle \mathbf{u}_i, \mathbf{u}_i \rangle$, 移项即得 (*) 式.

$$\begin{aligned} \langle \mathbf{z}, \mathbf{u}_1 \rangle &= \langle \mathbf{y} - \hat{\mathbf{y}}, \mathbf{u}_1 \rangle = \langle \mathbf{y}, \mathbf{u}_1 \rangle - \left\langle \frac{\langle \hat{\mathbf{y}}, \mathbf{u}_1 \rangle}{\langle \mathbf{u}_1, \mathbf{u}_1 \rangle}, \mathbf{u}_1 \right\rangle \mathbf{u}_1 - 0 - \dots - 0 \\ &= \langle \mathbf{y}, \mathbf{u}_1 \rangle - \langle \mathbf{y}, \mathbf{u}_1 \rangle = 0 \end{aligned}$$

类似地可证明 \mathbf{z} 与 W 的每一个基 \mathbf{u}_i 都正交, 进而 $\mathbf{z} \in W^\perp$.

为证明唯一性, 不妨设存在另一表示方法 $\mathbf{y} = \hat{\mathbf{y}}' + \mathbf{z}'$, 其中 $\hat{\mathbf{y}}' \in W, \mathbf{z}' \in W^\perp$ 那么 $\hat{\mathbf{y}} + \mathbf{z} = \hat{\mathbf{y}}' + \mathbf{z}'$, 即 $\hat{\mathbf{y}} - \hat{\mathbf{y}}' = \mathbf{z}' - \mathbf{z}$. 因为 $\mathbf{z}, \mathbf{z}' \in W^\perp$, 所以 $\mathbf{z}' - \mathbf{z} \in W^\perp$, 故 $\hat{\mathbf{y}} - \hat{\mathbf{y}}' \in W^\perp$, 而 $\hat{\mathbf{y}} - \hat{\mathbf{y}}' \in W$, 推出 $\langle \hat{\mathbf{y}} - \hat{\mathbf{y}}', \hat{\mathbf{y}} - \hat{\mathbf{y}}' \rangle = 0$, 即 $\hat{\mathbf{y}} = \hat{\mathbf{y}}'$, 同时 $\mathbf{z}' = \mathbf{z}$.

从 (*) 的最后一个等式可以看出, 实际上正交分解与我们高中所学的向量知识是一致的, 即 \mathbf{y} 在 \mathbf{u}_i 上的投影的长度再乘上该方向上的单位向量.

定理 30 (最佳估计). W 为 V 的子空间, $\mathbf{y} \in V$, 则

$$\|\mathbf{y} - \hat{\mathbf{y}}\| \leq \|\mathbf{y} - \mathbf{v}\|, \forall \mathbf{v} \in W$$

分析.

$$\mathbf{y} - \mathbf{v} = (\mathbf{y} - \hat{\mathbf{y}}) + (\hat{\mathbf{y}} - \mathbf{v})$$

因为 $\hat{\mathbf{y}} - \mathbf{v} \in W, \mathbf{y} - \hat{\mathbf{y}} \in W^\perp$, 所以由毕达哥拉斯定理

$$\|\mathbf{y} - \mathbf{v}\|^2 = \|\mathbf{y} - \hat{\mathbf{y}}\|^2 + \|\hat{\mathbf{y}} - \mathbf{v}\|^2$$

即得结论.

定理 31 (柯西(Cauchy)不等式).

$$\|\mathbf{u}\| \|\mathbf{v}\| \geq |\langle \mathbf{u}, \mathbf{v} \rangle|$$

分析.

$$\|\text{proj}_{\mathbf{u}} \mathbf{v}\| = \frac{\langle \mathbf{u}, \mathbf{v} \rangle}{\|\mathbf{u}\|} \leq \|\mathbf{v}\|$$

定理 32 (三角不等式).

$$\|\mathbf{u}\| + \|\mathbf{v}\| \geq \|\mathbf{u} + \mathbf{v}\|$$

分析. 平方后用柯西不等式.

命题 6. A 是 $m \times n$ 矩阵, $A\mathbf{x} = \mathbf{0}$ 当且仅当 $A^T A\mathbf{x} = \mathbf{0}$, 进而 $\text{Nul } A = \text{Nul } A^T A$.

$A^T A$ 可逆当且仅当 A 的列线性无关. $\text{rank } A^T A = n - \dim \text{Nul } A^T A = \text{Nul } A = \text{rank } A$

分析. $\mathbf{x}^T A^T A\mathbf{x} = 0$

3.3 正交矩阵

定理 33. U 是 $m \times n$ 矩阵, 则 U 每一列都单位正交当且仅当 $U^T U = I$

分析.

$$U^T U = \begin{bmatrix} \mathbf{u}_1^T \\ \vdots \\ \mathbf{u}_n^T \end{bmatrix} [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_n] = \begin{bmatrix} \mathbf{u}_1^T \mathbf{u}_1 & \cdots & \mathbf{u}_1^T \mathbf{u}_n \\ \vdots & \ddots & \vdots \\ \mathbf{u}_n^T \mathbf{u}_1 & \cdots & \mathbf{u}_n^T \mathbf{u}_n \end{bmatrix} = \begin{bmatrix} 1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 1 \end{bmatrix} = I$$

定理 34. U 是 $m \times n$ 矩阵且每一列都单位正交, $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$

1. $\|U\mathbf{x}\| = \|\mathbf{x}\|$
2. $(U\mathbf{x}) \cdot (U\mathbf{y}) = \mathbf{x} \cdot \mathbf{y}$
3. $(U\mathbf{x}) \cdot (U\mathbf{y}) = 0 \iff \mathbf{x} \cdot \mathbf{y} = 0$

分析. $(U\mathbf{x}) \cdot (U\mathbf{y}) = (U\mathbf{x})^T (U\mathbf{y}) = \mathbf{x}^T U^T U \mathbf{y} = \mathbf{x} \cdot \mathbf{y}$, 1, 3 同理可证.

定义 18 (正交矩阵). 若 U 为方阵且每一列都单位正交, 则称 U 为正交矩阵.

注: 从定义上看似乎应该叫单位正交矩阵 (*orthonormal matrix*) 比较合适, 但实际上在线性代数中正交矩阵 (*orthogonal matrix*) 已经包含了单位正交的意思.

由以上定理和定义可知下面几条显然的结论.

命题 7. 1. U 为方阵则一定可逆, 因 $U^T U = I = U^{-1} U = I$

2. U, V 均为正交矩阵, 则 UV 也为正交矩阵
3. U 中的列交换一下得到 V , 则 V 也为正交矩阵

命题 8. $\{\mathbf{u}_1, \dots, \mathbf{u}_p\}$ 是 V 的子空间 W 的一组单位正交基, 则 $\text{proj}_W \mathbf{y} = U U^T \mathbf{y}$, $\forall \mathbf{y} \in V$

算法 4 (施密特(Schmidt)正交化). 设 $\{\mathbf{v}_1, \dots, \mathbf{v}_p\}$ 是 W 的一组基, 定义

$$\begin{aligned} \mathbf{u}_1 &= \mathbf{v}_1 \\ \mathbf{u}_2 &= \mathbf{v}_2 - \text{proj}_{\mathbf{u}_1} \mathbf{v}_2 \\ &\vdots \\ \mathbf{u}_p &= \mathbf{v}_p - \sum_{j=1}^{p-1} \text{proj}_{\mathbf{u}_j} \mathbf{v}_p \end{aligned}$$

则 $\{\mathbf{u}_1, \dots, \mathbf{u}_p\}$ 是 W 的一组正交基, 且

$$\text{Span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\} = \text{Span}\{\mathbf{u}_1, \dots, \mathbf{u}_k\}, \forall 1 \leq k \leq p$$

注: 此过程说明了结合向量空间基的存在性可说明正交基的存在性.

分析. 设 $V_k = \text{Span}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$, $W_k = \text{Span}\{\mathbf{u}_1, \dots, \mathbf{u}_k\}$, $1 \leq k \leq p$, 则 $\mathbf{u}_{k+1} = \mathbf{v}_{k+1} - \text{proj}_{W_k} \mathbf{v}_{k+1}$, 进而 $\mathbf{u}_{k+1} \in W_{k+1}^\perp$, 即每一 \mathbf{u}_i 均与前面的 \mathbf{u}_j , $1 \leq j \leq i-1$ 正交 (也就保证了两两正交). 而 $\mathbf{v}_i \in V_i$, 由向量加减法的封闭性, $\mathbf{u}_i \in V_i$, 故 $\mathbf{u}_i \in V_p$ (因 $V_k \subset V_{k+1}$). 又正交一定线性无关, 且 V 已有一组 p 个向量的基, 故 $\{\mathbf{u}_1, \dots, \mathbf{u}_k\}$ 是 V_k 的一组正交基, 进而 $V_k = W_k$.

定理 35 (QR分解). 若 $m \times n$ 矩阵 A 的列线性无关, 则 A 可被分解为 $A = QR$, 其中 Q 是 $m \times n$ 矩阵且它的列形成 $\text{Col } A$ 的单位正交基, R 是 $n \times n$ 可逆上三角矩阵且对角线上元素全为正数.

注: 在下面的证明可以看出 $A = QR$, 单位正交不是必须的, 但可能因为具有某种性质, 所以才要强调单位正交.

分析. 施密特正交化将 A 的列转为正交基 $\{\mathbf{u}_1, \dots, \mathbf{u}_n\}$, 则 $Q = [\mathbf{u}_1, \dots, \mathbf{u}_n]$.

由算法 4 的分析知 $\mathbf{x}_k \in V_k = W_k$, 故存在 r_{k1}, \dots, r_{kk} , 使得

$$\mathbf{x}_k = r_{k1}\mathbf{u}_1 + \dots + r_{kk}\mathbf{u}_k + 0 \cdot \mathbf{u}_{k+1} + \dots + 0 \cdot \mathbf{u}_n$$

假设 $r_{kk} \geq 0$ (否则给 r_{kk} 和 \mathbf{u}_k 同乘 -1), 令

$$\mathbf{r}_k = \begin{bmatrix} r_{k1} \\ \vdots \\ r_{kk} \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

为 R 的列, 显然 R 为上三角, 即可满足 $\mathbf{x}_k = Q\mathbf{r}_k$.

算法 5 (QR分解). 1. 先将 A 的列向量单位正交化, 得到 Q

2. 通过 $R = IR = Q^T QR = Q^T A$ 计算得 R

4 特征值与特征向量

4.1 基本定义

定义 19. A 为 $n \times n$ 的矩阵, 若 $\exists \lambda, \mathbf{x} \neq \mathbf{0} \text{ s.t. } A\mathbf{x} = \lambda\mathbf{x}$, 则

1. λ 称为 A 的特征值, \mathbf{x} 称为关于 λ 的特征向量
2. $\text{Nul}(A - \lambda I)$ 称为 A 关于 λ 的特征空间
3. $\det(A - \lambda I)$ 称为 A 的特征多项式
4. λ 的代数重数是它在特征多项式中作为根的重数, 几何重数是它对应的特征空间的维度

需要注意:

1. 特征向量不能为 $\mathbf{0}$ ，但特征值可以为0
2. A 不可逆，则0是一个特征值（充要条件）； $A - \lambda I$ 不可逆， A 才有特征值

定理 36. $\lambda_1, \dots, \lambda_r$ 是 $n \times n$ 矩阵 A 不同的特征值，则其对应的特征向量 $\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$ 线性无关.

分析. 反证，假设 $\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$ 线性相关. 令 p 是最小的下标使得 \mathbf{v}_{p+1} 是之前向量的线性组合，即

$$c_1 \mathbf{v}_1 + \dots + c_p \mathbf{v}_p = \mathbf{v}_{p+1} \quad (1)$$

左右同乘 A ，得

$$c_1 A \mathbf{v}_1 + \dots + c_p A \mathbf{v}_p = A \mathbf{v}_{p+1}$$

进而

$$c_1 \lambda_1 \mathbf{v}_1 + \dots + c_p \lambda_p \mathbf{v}_p = \lambda_{p+1} \mathbf{v}_{p+1} \quad (2)$$

将(1)式同乘 λ_{p+1} ，并与(2)式相减得

$$c_1 (\lambda_1 - \lambda_{p+1}) \mathbf{v}_1 + \dots + c_p (\lambda_p - \lambda_{p+1}) \mathbf{v}_p = \mathbf{0}$$

由于 $\{\mathbf{v}_1, \dots, \mathbf{v}_p\}$ 线性无关，则它们的权重 $c_i (\lambda_i - \lambda_{p+1}) = 0, i = 1, \dots, p$. 而 A 的特征值均不同，故 $\lambda_i - \lambda_{p+1} \neq 0$ ，因而 $c_i = 0, i = 1, \dots, p$.

但由(1)又推出 $\mathbf{v}_{p+1} = \mathbf{0}$ ，与特征向量的定义矛盾，故假设不成立.

命题 9. 特征值与矩阵运算

1. λ 为可逆矩阵 A 的特征值，则 λ^{-1} 为 A^{-1} 的特征值
2. λ 是 A 的特征值，当且仅当 λ 是 A^T 的特征值

分析. 前者给 $A\mathbf{x} = \lambda\mathbf{x}$ 左乘 A^{-1} 后显然. 后者 $\det(A - \lambda I) = \det(A - \lambda I)^T = \det(A^T - \lambda I)$ 特征多项式相同

定义 20 (相似性). 矩阵 A, B 满足 $A = P^{-1}BP$ ，则称 A, B 相似.

注：相似性不同于行等价，行变换会改变矩阵的特征值，但相似性不会变

4.2 对角化

定理 37. $n \times n$ 矩阵 A 可对角化当且仅当 A 有 n 个线性无关的特征向量.

分析.

1° 必要性： A 可对角化，即 $A = PDP^{-1}$ ， D 为对角矩阵，也即 $AP = PD$. 设 $P = [\mathbf{v}_1, \dots, \mathbf{v}_n]$ ， $D = [\lambda_1 \mathbf{e}_1, \dots, \lambda_n \mathbf{e}_n]$ （注意这里 \mathbf{v}_i 只是 P 的列，还不是特征向量；同样 λ_i 也还不是 A 的特征值）. 则

$$AP = [A\mathbf{v}_1, \dots, A\mathbf{v}_n] = PD = [\lambda_1 \mathbf{v}_1, \dots, \lambda_n \mathbf{v}_n]$$

进而 $A\mathbf{v}_i = \lambda_i \mathbf{v}_i$ ， λ_i 为 A 的特征值，又 $\mathbf{v}_i \neq \mathbf{0}$ ， \mathbf{v}_i 为 λ_i 对应的特征向量.

由于 P 可逆，故 P 的列，也即 A 的特征向量线性无关.

2° 充分性：令 $P = [\mathbf{v}_1, \dots, \mathbf{v}_n]$ ，其中 \mathbf{v}_i 为 λ_i 对应的特征向量， $D = [\lambda_1 \mathbf{e}_1, \dots, \lambda_n \mathbf{e}_n]$ ，其中 λ_i 为 A 的特征向量.那么

$$AP = [A\mathbf{v}_1, \dots, A\mathbf{v}_n] = [\lambda_1 \mathbf{v}_1, \dots, \lambda_n \mathbf{v}_n] = PD$$

因为 \mathbf{v}_i 线性无关，故 P 可逆，进而 $A = PDP^{-1}$.

注：从以上构造可以知道 λ 相同并不影响对角矩阵的构造，但是 \mathbf{v} 相同则无法保证线性无关.

定理 38. 若 $n \times n$ 矩阵 A 有 n 个不同的特征值，则 A 可对角化.

分析. 从定理 36 可知， $\{\mathbf{v}_1, \dots, \mathbf{v}_r\}$ 线性无关，进而由定理 37， A 可对角化.

算法 6 (对角化).

1. 找到 A 的特征值
2. 找到 A 的线性无关特征向量
3. 构造 P ，其中 $P = [\mathbf{v}_1, \dots, \mathbf{v}_n]$
4. 构造 D ，其中 $D = [\lambda_1 \mathbf{e}_1, \dots, \lambda_n \mathbf{e}_n]$

注：对角化不是唯一的，会随着特征值摆放位置、特征向量的不同而改变. 可逆与可对角化没有必然联系.

定理 39. A 是 $n \times n$ 矩阵， $\lambda_1, \dots, \lambda_p$ 是 A 不同的特征值，则

1. $\forall 1 \leq k \leq p$ ， λ_k 的几何重数 $\leq \lambda_k$ 的代数重数
2. A 可对角化，当且仅当不同特征值的几何重数之和为 n ，而这当且仅当对于每一个 λ_k ，其代数重数都等于几何重数
3. 若 A 可对角化， \mathcal{B}_k 是 λ_k 对应的特征空间的基，那么 $\mathcal{B}_1, \dots, \mathcal{B}_p$ 形成 \mathbb{R}^n 的一组特征向量基

定理 40 (线性变换矩阵). $\mathcal{B} = \{\mathbf{b}_1, \dots, \mathbf{b}_n\}$ 为向量空间 V 的基， $\mathcal{C} = \{\mathbf{b}_{c1}, \dots, \mathbf{b}_{cm}\}$ 为向量空间 W 的基，线性变换 $T: V \rightarrow W$ ，存在唯一 $m \times n$ 矩阵 M 使得

$$[T(\mathbf{x})]_{\mathcal{C}} = M[\mathbf{x}]_{\mathcal{B}}, \forall \mathbf{x} \in V$$

其中

$$M = \begin{bmatrix} [T(\mathbf{b}_1)]_{\mathcal{C}} & [T(\mathbf{b}_2)]_{\mathcal{C}} & \cdots & [T(\mathbf{b}_n)]_{\mathcal{C}} \end{bmatrix}$$

称为 T 关于基 \mathcal{B} 和 \mathcal{C} 的矩阵 (the matrix for T relative to the bases \mathcal{B} and \mathcal{C}).

特别地，当线性空间和基取特殊值时，可以得到我们之前求得的一些矩阵.

1. T 的标准矩阵 (standard matrix for T)

$$A = [T(\mathbf{e}_1), \dots, T(\mathbf{e}_n)], \text{ 当 } V = W = \mathbb{R}^n, \mathcal{B} = \mathcal{C} = \mathcal{E} \text{ (}\mathbb{R}^n\text{ 中的标准基)}$$

2. T 的 \mathcal{B} 矩阵 (the matrix for T relative to \mathcal{B} , or the \mathcal{B} -matrix for T)

$$[T]_{\mathcal{B}} = [[T(\mathbf{b}_1)]_{\mathcal{B}}, \dots, [T(\mathbf{b}_n)]_{\mathcal{B}}], \text{ 当 } V = W, \mathcal{B} = \mathcal{C}$$

3. 坐标变换矩阵 (*change-of-coordinates matrix*), 右乘坐标可以将坐标变换成具体的 \mathbf{x}

$$P_B = [\mathbf{b}_1, \dots, \mathbf{b}_n], \text{ 当 } V = W = \mathbb{R}^n, \mathcal{C} = \mathcal{E}, T(\mathbf{x}) = \mathbf{x}$$

4. 过渡矩阵/ B 到 \mathcal{C} 的坐标变换矩阵 (*change-of-coordinates matrix from B to \mathcal{C}*)

$$P_{\mathcal{C} \leftarrow B} = [[\mathbf{b}_1]_{\mathcal{C}}, \dots, [\mathbf{b}_n]_{\mathcal{C}}], \text{ 当 } V = W, T(\mathbf{x}) = \mathbf{x}$$

分析. 1° 存在性:

$$\begin{aligned} [T(\mathbf{x})]_{\mathcal{C}} &= [T(x_1 \mathbf{b}_1 + \dots + x_n \mathbf{b}_n)]_{\mathcal{C}} \\ &= x_1 [T(\mathbf{b}_1)]_{\mathcal{C}} + \dots + x_n [T(\mathbf{b}_n)]_{\mathcal{C}} \\ &= [[T(\mathbf{b}_1)]_{\mathcal{C}}, \dots, [T(\mathbf{b}_n)]_{\mathcal{C}}] \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \\ &= [[T(\mathbf{b}_1)]_{\mathcal{C}}, \dots, [T(\mathbf{b}_n)]_{\mathcal{C}}] [\mathbf{x}]_B \\ &= M[\mathbf{x}]_B \end{aligned}$$

2° 唯一性: 设存在另一矩阵 M' 使得 $[T(\mathbf{x})]_{\mathcal{C}} = M'[\mathbf{x}]_B$, 故 $M[\mathbf{x}]_B = M'[\mathbf{x}]_B$, 令 $\mathbf{x} = \mathbf{b}_i$ 即得 $M = M'$

命题 10. 若 $A = PDP^{-1}$, D 是 $n \times n$ 的对角矩阵, 若 B 是 $\text{Col } P$ 的一组基, 则 D 是线性变换 $\mathbf{x} \mapsto A\mathbf{x}$ 的 B -矩阵.

分析.

$$\begin{aligned} [T]_B &= [[T(\mathbf{b}_1)]_B, \dots, [T(\mathbf{b}_n)]_B] \\ &= [A\mathbf{b}_1]_B, \dots, [A\mathbf{b}_n]_B \\ &= [P^{-1}A\mathbf{b}_1, \dots, P^{-1}A\mathbf{b}_n] \quad \text{坐标变换} \\ &= P^{-1}A[\mathbf{b}_1, \dots, \mathbf{b}_n] \\ &= P^{-1}AP = D \end{aligned}$$

求解方法 $\begin{bmatrix} P & AP \end{bmatrix} \sim \begin{bmatrix} I & P^{-1}AP \end{bmatrix}$. 由上面分析知 D 不需是对角矩阵, 只要 A 与 D 相似即可.

如下图所示³, 一个线性变换 T 对于标准基 (或其他基) 的矩阵为 A , 为了更清楚地通过矩阵看出这个线性变换的效果, 就将 A 对角化: $A = PDP^{-1}$. 这其实相当于先把标准基换成由特征向量组成的基(P^{-1} 的意义), 于是每一个基向量在经过 T 变换后都只是乘了个常数(D 的意义), 最后再把由特征向量组成的基换回标准基(P 的意义). 因此对角化其实是用一组比标准基更好的基来描述线性变换, 也就是由特征向量组成的基. 至于更好的基, 由特征向量组成的规范正交基 (谱定理) 描述的则更好.

定义 21 (迹(trace)). A 为 $n \times n$ 的方阵, A 主对角线上元素之和称为 A 的迹, 定义为

$$\text{tr } A = \sum_{i=1}^n a_{ii}$$

定理 41. 若 A, B 均为 $n \times n$ 的方阵, 则 $\text{tr}(AB) = \text{tr}(BA)$

³图根据课本重绘, 话摘自线性变换的矩阵为什么要强调在这组基下? - 匡世珉的回答 - 知乎 <https://www.zhihu.com/question/22218306/answer/88697757>

$$\begin{array}{ccc}
\mathbf{x} & \xrightarrow{\text{乘} A} & A\mathbf{x} \\
\downarrow \text{乘} P^{-1} & & \uparrow \text{乘} P \\
[\mathbf{x}]_B & \xrightarrow{\text{乘} D} & [A\mathbf{x}]_B
\end{array}$$

分析.

$$\text{tr}(AB) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} b_{ji} = \sum_{j=1}^n \sum_{i=1}^n a_{ji} b_{ij} = \sum_{i=1}^n \sum_{j=1}^n b_{ij} a_{ji} = \text{tr}(BA)$$

定理 42 (相似性一些定理). 已知 A 与 B 相似,

1. 若 A 可逆, 则 A^{-1} 与 B^{-1} 相似
2. 则 A^k 与 B^k 相似
3. A 与 C 相似, 则 B 与 C 相似
4. A 可对角化, 则 B 也可对角化
5. $A = PBP^{-1}$, \mathbf{x} 是 A 关于 λ 的特征向量, 则 $P^{-1}\mathbf{x}$ 是 B 关于 λ 的特征向量
6. $\text{rank } A = \text{rank } B$

5 对称矩阵与二次型

5.1 谱分解

定义 22 (对称矩阵). $A^T = A$ (显然得是方阵)

定理 43. A 为对称矩阵, 任两个不同特征空间的特征向量一定正交

分析. 设 $\mathbf{v}_1, \mathbf{v}_2$ 为不同特征值 λ_1, λ_2 对应的特征向量

$$\begin{aligned}
\lambda_1 \mathbf{v}_1 \cdot \mathbf{v}_2 &= (\lambda_1 \mathbf{v}_1)^T \mathbf{v}_2 = (A\mathbf{v}_1)^T \mathbf{v}_2 \\
&= \mathbf{v}_1^T A^T \mathbf{v}_2 = \mathbf{v}_1^T (A\mathbf{v}_2) \\
&= \lambda_2 \mathbf{v}_1 \cdot \mathbf{v}_2
\end{aligned}$$

进而 $(\lambda_1 - \lambda_2) \mathbf{v}_1 \cdot \mathbf{v}_2 = 0$, 而 λ_1, λ_2 不同, 故 $\mathbf{v}_1 \cdot \mathbf{v}_2 = 0$

定义 23 (正交对角化). 若存在对角矩阵 D 和正交矩阵 P 使得 $A = PDP^T = PDP^{-1}$, 则称 A 可正交对角化

算法 7 (正交对角化).

1. 先将矩阵一般对角化, 暂不用求 P^{-1}
2. 然后将 P 的列施密特单位正交化, 使 P 变为正交矩阵
3. $P^T = P^{-1}$ 直接求得 P 的逆

定理 44 (谱定理). A 为 $n \times n$ 的对称矩阵, 则

1. A 有 n 个实特征值（包含重数）
2. $\dim W_{\lambda_i} = \lambda_i$ 的代数重数
3. 特征空间相互正交，对应不同特征值的特征向量都正交
4. A 可以被正交对角化（充要条件）

注：正交矩阵不一定可以被正交对角化，正交对角化一定会产生正交矩阵，要理清关系。

定理 45 (谱分解). A 为对称矩阵，记正交矩阵 P 的列为 \mathbf{u}_i ，则 $A = \lambda_1 \mathbf{u}_1 \mathbf{u}_1^T + \lambda_2 \mathbf{u}_2 \mathbf{u}_2^T + \cdots + \lambda_n \mathbf{u}_n \mathbf{u}_n^T$

定义 24 (投影矩阵). A 是对称矩阵且 $A^2 = A$ ，则称其为投影矩阵

命题 11. 若 $A = \mathbf{u} \mathbf{u}^T$ ，其中 $\mathbf{u} \in \mathbb{R}^n$ 为单位向量，则

1. A 是投影矩阵
2. $A\mathbf{x} = \text{proj}_{\mathbf{u}} \mathbf{x}$
3. \mathbf{u} 是 A 的特征向量

5.2 奇异值分解

定理 46. $A^T A$ 的特征值均为非负数

分析. $\forall \mathbf{u}_i, \|\mathbf{A}\mathbf{u}_i\|^2 = (\mathbf{A}\mathbf{u}_i)^T \mathbf{A}\mathbf{u}_i = \mathbf{u}_i^T (A^T A) \mathbf{u}_i = \mathbf{u}_i^T \lambda_i \mathbf{u}_i = \lambda_i \mathbf{u}_i \cdot \mathbf{u}_i = \lambda_i \|\mathbf{u}_i\|^2 \geq 0 \implies \lambda_i \geq 0$ ，故记 $\sigma_i = \sqrt{\lambda_i} = \|\mathbf{A}\mathbf{u}_i\|$ 为 A 的奇异值，注意这里的 λ_i 都为 $A^T A$ 的特征值。

定义 25 (奇异值). A 的奇异值是 $A^T A$ 的特征值的算术平方根，记为 $\sigma_i := \sqrt{\lambda_i}, \forall 1 \leq i \leq n$ ，且呈递减序列。

定理 47. A 为 $m \times n$ 矩阵， $A^T A = \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^T$ ，假设有 r 个非零特征值，不妨设 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > \lambda_{r+1} = \cdots = \lambda_n = 0$ ，则 $\{\mathbf{A}\mathbf{u}_1, \dots, \mathbf{A}\mathbf{u}_r\}$ 是 $\text{Col } A$ 正交基，且 $\text{rank } A = r$ 。

分析. $\|\mathbf{A}\mathbf{u}_i\| = \sqrt{\lambda_i} \neq 0, i = 1, \dots, r$

正交性: $\forall i \neq j, (\mathbf{A}\mathbf{u}_i) \cdot (\mathbf{A}\mathbf{u}_j) = \mathbf{u}_i^T A^T \mathbf{A} \mathbf{u}_j = \lambda_j \mathbf{u}_i^T \mathbf{u}_j = 0$

任取 $\mathbf{v} \in \text{Col } A$ ，即 $\exists \mathbf{x} \in \mathbb{R}^n$ s.t. $A\mathbf{x} = \mathbf{v}$ ，其中 $\mathbf{x} = c_1 \mathbf{u}_1 + \cdots + c_n \mathbf{u}_n$ ，则 $\mathbf{v} = c_1 \mathbf{A}\mathbf{u}_1 + \cdots + c_n \mathbf{A}\mathbf{u}_n = c_1 \mathbf{A}\mathbf{u}_1 + \cdots + c_r \mathbf{A}\mathbf{u}_r + 0 + \cdots + 0$ ，即说明 \mathbf{v} 可由 $\{\mathbf{A}\mathbf{u}_1, \dots, \mathbf{A}\mathbf{u}_r\}$ 线性表示，故证毕。

定理 48 (奇异值分解(SVD)). A 是 $m \times n$ 的矩阵， $\text{rank } A = r$ ，则存在 $m \times n$ 矩阵 $\Sigma = \begin{bmatrix} D & O \\ O & O \end{bmatrix}$ ，其中 D 的对角线是前 r 个 A 的奇异值，且 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ ，那么存在 $m \times m$ 正交矩阵 U 和 $n \times n$ 正交矩阵 V 使得 $A = U \Sigma V^T$ 。

分析. 设 $A^T A = \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^T$ ，其有 r 个非零特征值， $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_r > 0$ 。

$\{\mathbf{A}\mathbf{u}_1, \dots, \mathbf{A}\mathbf{u}_r\}$ 是 $\text{Col } A$ 正交基，将其标准化，得 $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ ，其中 $\mathbf{u}_i = \frac{\mathbf{A}\mathbf{v}_i}{\|\mathbf{A}\mathbf{v}_i\|} = \frac{1}{\sigma_i} \mathbf{A}\mathbf{v}_i$ ，即 $\mathbf{A}\mathbf{v}_i = \sigma_i \mathbf{u}_i$ 。将 $\{\mathbf{u}_1, \dots, \mathbf{u}_r\}$ 拓展为 \mathbb{R}^m 的正交基 $\{\mathbf{u}_1, \dots, \mathbf{u}_m\}$ ，令

$$U = [\mathbf{u}_1 \quad \cdots \quad \mathbf{u}_m], V = [\mathbf{v}_1 \quad \cdots \quad \mathbf{v}_n]$$

那么 U, V 均为正交矩阵, 而且

$$AV = \begin{bmatrix} A\mathbf{v}_1 & \cdots & A\mathbf{v}_r & \mathbf{0} \cdots \mathbf{0} \end{bmatrix} = \begin{bmatrix} \sigma_1 \mathbf{u}_1 & \cdots & \sigma_r \mathbf{u}_r & \mathbf{0} \cdots \mathbf{0} \end{bmatrix}$$

进而

$$\begin{aligned} U\Sigma &= \begin{bmatrix} \mathbf{u}_1 & \cdots & \mathbf{u}_m \end{bmatrix} \begin{bmatrix} D & O \\ O & O \end{bmatrix} \\ &= \begin{bmatrix} A\mathbf{v}_1 & \cdots & A\mathbf{v}_r & \mathbf{0} \cdots \mathbf{0} \end{bmatrix} = \begin{bmatrix} \sigma_1 \mathbf{u}_1 & \cdots & \sigma_r \mathbf{u}_r & \mathbf{0} \cdots \mathbf{0} \end{bmatrix} \\ &= AV \end{aligned}$$

因为 V 为正交矩阵, 故 $U\Sigma V^T = AVV^T = A$.

算法 8 (奇异值分解). 分为以下几个步骤

1. 对 $A^T A$ 正交对角化
2. 建立起 Σ 和 V
3. 建立起 U

5.3 二次型

定义 26 (二次型). $Q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}$, 其中 A 是对称矩阵

将二次型合并为矩阵的写法, 平方项放对角线, 交叉项取一半对称写. 以三元二次型为例, 观察下面各个元素的去向.

$$\begin{aligned} Q(\mathbf{x}) &= \mathbf{x}^T A \mathbf{x} = \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} \\ &= a_{11}x_1^2 + a_{22}x_2^2 + a_{33}x_3^2 + (a_{12} + a_{21})x_1x_2 + (a_{13} + a_{31})x_1x_3 + (a_{23} + a_{32})x_2x_3 \end{aligned}$$

定理 49 (主轴定理). $\mathbf{x} = P\mathbf{y}$, 存在 P 将二次型 $\mathbf{x}^T A \mathbf{x}$ 转为 $\mathbf{y}^T D \mathbf{y}$, 其中 P 的列 (A 的单位特征向量) 称为 $\mathbf{x}^T A \mathbf{x}$ 的主轴.

算法 9 (标准型变换). 将矩阵 A 正交对角化后, 得到 $A = PDP^{-1}$, 做变换 $\mathbf{x} = P\mathbf{y}$, 可得 $\mathbf{x}^T A \mathbf{x} = \mathbf{y}^T D \mathbf{y}$, 由于 D 为对角矩阵, 由上面的分析即可知变换后的二次型不存在交叉项, 这种形式称为**标准型**. 又 $\mathbf{x} = P\mathbf{y}$, 令 $\mathbf{y} = \mathbf{e}_i$ (变换后的主轴在坐标轴上), 可得 $\mathbf{x} = \mathbf{u}_i$, 即原来的主轴为 P 的列, 也即 A 的特征向量.

定义 27. 对于二次型 $Q(\mathbf{x})$

1. 若 $Q(\mathbf{x}) > 0 \forall \mathbf{x} \neq \mathbf{0}$, 正定 $\iff \forall \lambda > 0$; $Q(\mathbf{x}) \geq 0 \forall \mathbf{x} \neq \mathbf{0}$, 半正定
2. 若 $Q(\mathbf{x}) < 0 \forall \mathbf{x} \neq \mathbf{0}$, 负定 $\iff \forall \lambda < 0$; $Q(\mathbf{x}) \leq 0 \forall \mathbf{x} \neq \mathbf{0}$, 半负定
3. $Q(\mathbf{x})$ 正负值都有, 不定

分析. 对二次型进行标准型变换使其没有交叉项, $Q(\mathbf{x}) = \mathbf{x}^T A \mathbf{x} = \mathbf{y}^T D \mathbf{y} = \lambda_1 y_1^2 + \cdots + \lambda_n y_n^2$, 进而得证.

命题 12. 1. B 为 $m \times n$ 矩阵, $B^T B$ 为半正定; 若 B 为方阵且可逆, 则 $B^T B$ 正定.

分析. $\mathbf{x}^T (B^T B) \mathbf{x} = \|B\mathbf{x}\|^2 \geq 0$, 可逆则 $B\mathbf{x} = \mathbf{0}$ 只有平凡解.

2. A 为方阵且正定, 那么存在一个正定方阵 B 使得 $A = B^T B$

命题 13. A, B 均为方阵, 且特征值均为正数, 则 $A + B$ 的特征值也全为正数.

分析. $\mathbf{x}^T A \mathbf{x} > 0, \mathbf{x}^T B \mathbf{x} > 0 \implies \mathbf{x}^T (A + B) \mathbf{x} > 0$

5.4 带约束的最值问题

定理 50. 二次型 Q , $\min_{\|\mathbf{x}\|=1} Q(\mathbf{x}) = \lambda_{\min}, \max_{\|\mathbf{x}\|=1} Q(\mathbf{x}) = \lambda_{\max}$

分析. 化为标准型后直接放缩即可.

定理 51. A 为 $m \times n$ 矩阵, $\min_{\|\mathbf{x}\|=1} \|A\mathbf{x}\| = \lambda_{\min}, \max_{\|\mathbf{x}\|=1} \|A\mathbf{x}\| = \lambda_{\max}$

分析. $\|A\mathbf{x}\|^2 = (A\mathbf{x})^T A\mathbf{x} = \mathbf{x}^T (A^T A) \mathbf{x}$ 进而转化为二次型. 实际上 $\|A\mathbf{x}\| \leq \lambda \|\mathbf{x}\|$.

6 仿射空间

由于这一章涉及的概念太多, 且比较难找到对应的中文术语, 故在专业术语后都会标上对应的英文名称.

6.1 仿射组合与凸组合

定义 28 (仿射组合与凸组合). \mathbb{R}^n 中的向量 $\mathbf{v}_1, \dots, \mathbf{v}_p$ 的线性组合 $c_1 \mathbf{v}_1 + \dots + c_p \mathbf{v}_p$, 若满足权重 $c_1 + \dots + c_p = 1$, 则该线性组合称为仿射组合, 集合 S 所有点仿射组合的集合称为仿射包(affine hull)或仿射生成(affine span)集, 记为 $\text{aff } S$. 在仿射组合的基础上满足权重 $c_i \geq 0, i = 1, \dots, p$, 则该线性组合称为凸组合, 集合 S 所有点凸组合的集合称为凸包(convex hull), 记为 $\text{conv } S$.

由定义得知, $S = \{\mathbf{v}_1\}$ 时, $\text{aff } S$ 和 $\text{conv } S$ 均为一个点 \mathbf{v}_1 ; $S = \{\mathbf{v}_1, \mathbf{v}_2\}$ 时, $\text{aff } S$ 是通过 $\mathbf{v}_1, \mathbf{v}_2$ 的直线(定比分点), $\text{conv } S$ 则是线段 $\overline{\mathbf{v}_1 \mathbf{v}_2}$; $S = \{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}$ 时, $\text{aff } S$ 是通过 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ 的平面, $\text{conv } S$ 则是三角形 $\triangle \mathbf{v}_1 \mathbf{v}_2 \mathbf{v}_3$; 以此类推.

定义 29 (仿射(affine)与凸性(convex)). 对于集合 S , 若 $\forall \mathbf{u}, \mathbf{v} \in S, (1-t)\mathbf{u} + t\mathbf{v} \in S, \forall t \in \mathbb{R}$, 则称 S 是仿射集. 若 $\forall \mathbf{u}, \mathbf{v} \in S, \overline{\mathbf{u} \mathbf{v}} \in S$, 则称 S 是凸集.

定理 52. 以下是关于仿射集和凸集的一些定理.

1. S 是仿射集当且仅当 $S = \text{aff } S$; S 是凸集当且仅当 $S = \text{conv } S$
2. 仿射集的子集是仿射集, 凸集的子集是凸集

定义 30. \mathbb{R}^n 的一个集合 S 经向量 \mathbf{p} 的平移(translate)变为 $S + \mathbf{p} = \{\mathbf{s} + \mathbf{p} | \mathbf{s} \in S\}$. \mathbb{R}^n 的一个面(flat)⁴是 \mathbb{R}^n 子空间的一个平移. 若一个面是另一个的平移, 则两个面平行. 一个面的维度是它对应的平行子空间的维度. S 的维度是包含 S 最小的面的维度. \mathbb{R}^n 中的线是一维的面, \mathbb{R}^n 中的超平面(hyperplane)是 $n - 1$ 维的面.

注: 由于子空间必须包含零点, 故经过平移的子空间就不是子空间了, 就称为面. 真(proper)面即不包含自己的面.

定义 31 (齐次(homogeneous)坐标). 对于 $\mathbf{v} \in \mathbb{R}^n$, 其标准齐次坐标为 $\tilde{\mathbf{v}} = \begin{bmatrix} \mathbf{v} \\ 1 \end{bmatrix} \in \mathbb{R}^{n+1}$

引入齐次坐标的好处有以下几点.

1. 合并矩阵加法乘法运算
2. 引入无穷远点等同于其他点

定义 32 (仿射无关). 若存在 c_1, \dots, c_p 不全为 0, 使得 $c_1 + \dots + c_p = 0, c_1 \mathbf{v}_1 + \dots + c_p \mathbf{v}_p = \mathbf{0}$, 则称 $\{\mathbf{v}_1, \dots, \mathbf{v}_p\} \in \mathbb{R}^n$ 仿射相关, 否则称为仿射无关.

定理 53. $S = \{\mathbf{v}_1, \dots, \mathbf{v}_p\} \in \mathbb{R}^n, p \geq 2$, 以下命题都等价

1. S 仿射相关
2. S 其中一个点是其他点的仿射组合
3. $\{\mathbf{v}_2 - \mathbf{v}_1, \dots, \mathbf{v}_p - \mathbf{v}_1\} \in \mathbb{R}^n$ 线性相关
4. $\{\tilde{\mathbf{v}}_1, \dots, \tilde{\mathbf{v}}_p\} \in \mathbb{R}^{n+1}$ 线性相关

定理 54 (向量唯一表示定理 (仿射组合)). $S = \{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ 是 \mathbb{R}^n 的仿射无关集, 那么 $\forall \mathbf{p} \in \text{aff } S$ 有唯一向量表示

$$\mathbf{p} = c_1 \mathbf{v}_1 + \dots + c_k \mathbf{v}_k \quad \text{且} \quad c_1 + \dots + c_k = 1$$

其中 c_1, \dots, c_p 称为 \mathbf{p} 的质心(barycentric)坐标或仿射坐标.

分析. 相当于解 $\tilde{\mathbf{p}} = c_1 \tilde{\mathbf{v}}_1 + \dots + c_k \tilde{\mathbf{v}}_k$, 通过高斯消元初等行变换可得. 广泛应用于图像渐变、透视关系.

定理 55. 1. 一个非空子集 S 是仿射集当且仅当它是一个面

2. S 仿射无关, $\mathbf{p} \in \text{aff } S$, 那么 $\mathbf{p} \in \text{conv } S$ 当且仅当 \mathbf{p} 的质心坐标全部非负
3. $\text{conv } S$ 是所有包含 S 的凸集之交

定理 56 (Caratheodory). S 是 \mathbb{R}^n 的一个非空子集, 那么 $\text{conv } S$ 的每一个点都可以被表示成 S 中小于等于 $n + 1$ 个点的凸组合

6.2 超平面

定义 33 (线性泛函(linear functional)). 线性变换 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 是一个线性泛函. $\forall d \in \mathbb{R}, [f: d] := \{\mathbf{x} \in \mathbb{R}^n : f(\mathbf{x}) = d\}$. 零泛函是使得 $f(\mathbf{x}) = 0, \forall \mathbf{x} \in \mathbb{R}^n$ 的变换, 其他均称为非零.

⁴[https://en.wikipedia.org/wiki/Flat_\(geometry\)](https://en.wikipedia.org/wiki/Flat_(geometry))

定理 57. \mathbb{R}^n 的子集 H 是一个超平面当且仅当 $H = [f : d]$, 其中 f 是非零泛函, $d \in \mathbb{R}$. 因此, 若 H 是一个超平面, 则存在一个非零向量 \mathbf{n} 和 $d \in \mathbb{R}$ 使得 $H = \{\mathbf{x} : \mathbf{n} \cdot \mathbf{x} = d\}$

定义 34 (拓扑概念). $\forall \mathbf{p} \in \mathbb{R}^n, \delta > 0$, 中心为 \mathbf{p} , 半径为 δ 的开球(open ball)记为 $B(\mathbf{p}, \delta) := \{\mathbf{x} : \|\mathbf{x} - \mathbf{p}\| < \delta\}$. 给定集合 $S \in \mathbb{R}^n$, 若 $\exists \delta > 0$ s.t. $B(\mathbf{p}, \delta) \subset S$, 则称 \mathbf{p} 是 S 的内点(interior point). 若每一个中心在 \mathbf{p} 的开球都与 S 和 S 的补相交, 则 \mathbf{p} 是 S 的边界点(boundary point). 若 S 不包含任一边界点, 则称 S 是开的(open); 若 S 包含所有边界点, 则称 S 是闭的(closed); 否则既不开也不闭. 若 $\exists \delta > 0$ s.t. $S \subset B(\mathbf{0}, \delta)$, 则称 S 是有界的(bounded). S 同时是闭的, 又是有界的, 则称 S 是紧的(compact). (欧氏空间上有界闭集等于紧集)

定理 58. 开集的凸包是开的, 紧集的凸包是紧的, 但闭集的凸包不一定是闭的

定义 35. 称超平面 $H = [f : d]$ 将集合 A, B 分隔(separate), 若满足以下其一

1. $f(A) \leq d$ 且 $f(B) \geq d$
2. $f(A) \geq d$ 且 $f(B) \leq d$

定理 59. A, B 均为非空凸集, A 是紧集, B 是闭集, 那么存在一个超平面 H 严格分割 A, B , 当且仅当 $A \cap B = \emptyset$

定理 60. A, B 均为非空紧集, 那么那么存在一个超平面 H 严格分割 A, B , 当且仅当 $(\text{conv } A) \cap (\text{conv } B) = \emptyset$

6.3 多胞形

定义 36 (多胞形(polytopes)). \mathbb{R}^n 中的多胞形是有限集合的凸包. \mathbb{R}^2 中, 多胞体就是简单的多边形; \mathbb{R}^3 , 则是多面体.

定义 37. S 是 \mathbb{R}^n 紧致的凸集, F 是 S 的非空子集, 若 $F \neq S$, $\exists H = [f : d]$ s.t. $F = S \cap H$ 以及 $f(S) \leq d$ 或 $f(S) \geq d$, 则称 F 为 S 的面(face). H 称为 S 的支撑超平面(supporting hyperplane). 若 $\dim F = k$, 则 F 称为 S 的 k -面. 若 P 是 k 维的多胞体, 称 P 为 k -多胞体. P 的 0-面称为顶点(vertex/vertices), 1-面称为边(edge), $k-1$ -面是 S 的 facet.

定义 38 (端点). S 是凸集, 若 $\mathbf{x}, \mathbf{y} \in S, \mathbf{p} \in \overline{\mathbf{x}\mathbf{y}}$, 则 $\mathbf{p} = \mathbf{x}$ 或 $\mathbf{p} = \mathbf{y}$ 称为 S 的端点(extreme point), S 的所有端点称为 S 的轮廓(profile).

定义 39 (最小表示). 若多胞形 $P = \text{conv}\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ 且 $\mathbf{v}_i \notin \text{conv}\{\mathbf{v}_j : j \neq i\}, \forall i = 1, \dots, k$, 则称 $\{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ 是 P 的最小表示(minimal representation).

定理 61. $M = \{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ 是多胞形 P 的最小表示, 则以下说法等价

1. $\mathbf{p} \in M$
2. \mathbf{p} 是 P 的顶点
3. \mathbf{p} 是 P 的端点

定理 62. S 是非空紧致凸集, 则 S 是它轮廓 (S 的端点) 的凸包

定理 63. f 是一个定义在非空紧致凸集 S 上的线性泛函, 则存在 S 的端点 $\hat{\mathbf{v}}, \hat{\mathbf{w}}$ 使得

$$f(\hat{\mathbf{v}}) = \max_{\mathbf{v} \in S} f(\mathbf{v}) \quad f(\hat{\mathbf{w}}) = \min_{\mathbf{v} \in S} f(\mathbf{v})$$

注: 线性规划极值点取得依据

定义 40 (单纯形(simplex)). 单纯形是有限仿射无关向量构成的集合的凸包. \mathbb{R}^2 中, 多胞体就是简单的多边形; \mathbb{R}^3 , 则是多面体.

0-单纯形 S^0 : 一个点 $\{\mathbf{v}_1\}$

\vdots

k -单纯形 S^k : $\text{conv}(S^{k-1} \cup \{\mathbf{v}_{k+1}\})$, 其中 $\mathbf{v}_{k+1} \notin S^{k-1}$

定义 41 (超立方体(hypercube)). $I_i = \overline{0\mathbf{e}_i}$, 向量和(vector sum)⁵ $C^k = I_1 + I_2 + \cdots + I_k$ 称为 k -维超立方体

定理 64 (欧拉(Euler)公式). 记 $f_k(P)$ 为 n -维多胞形 P 的 k -维面的数目, 则

$$\sum_{k=0}^{n-1} (-1)^k f_k(P) = 1 + (-1)^{n-1}$$

特别地, 当 $n = 3$ 时, 有 $v - e + f = 2$, 其中 v, e, f 分别为顶点、边、面的数量.

6.4 曲线和表面

定义 42 (贝塞尔(Bézier)曲线). 三阶贝塞尔曲线

$$\mathbf{x}(t) = \begin{bmatrix} \mathbf{p}_0 & \mathbf{p}_1 & \mathbf{p}_2 & \mathbf{p}_3 \end{bmatrix} \begin{bmatrix} 1 & -3 & 3 & -1 \\ 0 & 3 & -6 & 3 \\ 0 & 0 & 3 & -3 \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ t \\ t^2 \\ t^3 \end{bmatrix} = G M_B \mathbf{u}(t)$$

其中 G 为四个控制点构成的几何(geometry)矩阵, M_B 为贝塞尔基底矩阵. 换种形式表示

$$\mathbf{x}(s) = \mathbf{u}(s)^T M_B^T G^T = \begin{bmatrix} (1-s)^3 & 3s(1-s)^2 & 3s^2(1-s) & s^3 \end{bmatrix} \begin{bmatrix} \mathbf{p}_0 \\ \mathbf{p}_1 \\ \mathbf{p}_2 \\ \mathbf{p}_3 \end{bmatrix}$$

⁵ $A + B = \{\mathbf{c} : \mathbf{c} = \mathbf{a} + \mathbf{b}, \forall \mathbf{a} \in A, \mathbf{b} \in B\}$

定义 43 (贝塞尔表面).

$$GM_B \mathbf{u}(t) \begin{bmatrix} \mathbf{p}_{11} & \mathbf{p}_{12} & \mathbf{p}_{13} & \mathbf{p}_{14} \\ \mathbf{p}_{21} & \mathbf{p}_{22} & \mathbf{p}_{23} & \mathbf{p}_{24} \\ \mathbf{p}_{31} & \mathbf{p}_{32} & \mathbf{p}_{33} & \mathbf{p}_{34} \\ \mathbf{p}_{41} & \mathbf{p}_{42} & \mathbf{p}_{43} & \mathbf{p}_{44} \end{bmatrix} \begin{bmatrix} (1-t)^3 \\ 3t(1-t)^2 \\ 3t^2(1-t) \\ t^3 \end{bmatrix}$$

进而,

$$\mathbf{x}(s, t) = \mathbf{u}(s)^T M_B^T GM_B \mathbf{u}(t), 0 \leq s, t \leq 1$$

7 拓展

7.1 线性模型与最小二乘

定理 65 (最小二乘). A 为 $m \times n$ 的矩阵, $\mathbf{b} \in \mathbb{R}^m$, $A\mathbf{x} = \mathbf{b}$ 的最小二乘解是 $\hat{\mathbf{x}} \in \mathbb{R}^n$ 使得

$$\|\mathbf{b} - A\hat{\mathbf{x}}\| \leq \|\mathbf{b} - A\mathbf{x}\|$$

则 $\hat{\mathbf{b}} = \text{proj}_{\text{Col } A} \mathbf{b}$, 解与 $A^T A \mathbf{x} = A^T \mathbf{b}$ 相同.

若 A 可被 QR 分解 (定理 35), 则 $\hat{\mathbf{x}} = R^{-1} Q^T \mathbf{b}$.

分析. $\mathbf{a}_j \cdot (\mathbf{b} - A\hat{\mathbf{x}}) = \mathbf{a}_j^T (\mathbf{b} - A\hat{\mathbf{x}}) = 0 \implies A^T (\mathbf{b} - A\hat{\mathbf{x}}) = \mathbf{0} \implies A^T A \mathbf{x} = A^T \mathbf{b}$

算法 10 (最小二乘估计). 直接计算 $A^T A \mathbf{x} = A^T \mathbf{b}$ 即可.

定义 44 (一般线性模型). $\mathbf{y} = X\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, X 为设计矩阵, $\boldsymbol{\beta}$ 为参数向量, \mathbf{y} 为观测向量, $\boldsymbol{\varepsilon}$ 为残差向量, 满足这种形式的方程称为线性模型. 使 $\boldsymbol{\varepsilon}$ 得长度最小化, 即找出 $X\boldsymbol{\beta} = \mathbf{y}$ 的最小二乘解.

以下是一些例子.

1. 直线拟合

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

2. 抛物线拟合

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

3. 多重回归

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & u_1 & v_1 \\ 1 & u_2 & v_2 \\ \vdots & \vdots & \vdots \\ 1 & u_n & v_n \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

7.2 马尔可夫链

定义 45 (马尔可夫(Markov)链). 具有非负分量的数值且相加等于1的向量 $\mathbf{x}_0, \mathbf{x}_1, \dots$ 称为**概率向量**, 各列向量均为概率向量的方阵 P 称为**随机矩阵**, 则**马尔可夫链**为 $\mathbf{x}_{k+1} = P\mathbf{x}_k, k = 0, 1, 2, \dots$, 其中 \mathbf{x}_k 称为**状态向量**.

定理 66 (马尔可夫链收敛定理⁶). 马尔可夫链 $\{\mathbf{x}_{k+1}\}$ 一定会收敛至**平衡向量** \mathbf{q} , 其中 \mathbf{q} 满足 $P\mathbf{q} = \mathbf{q}$.

7.3 复数特征值

定理 67. 当 A 为实矩阵时, 它的复特征值成对出现.

分析. $A\bar{\mathbf{x}} = \bar{A}\bar{\mathbf{x}} = \overline{A\mathbf{x}} = \overline{\lambda\mathbf{x}} = \bar{\lambda}\bar{\mathbf{x}}$

定理 68. A 为 2×2 实矩阵, 有复特征值 $\lambda = a - bi (b \neq 0)$ 及对应 \mathbb{C}^2 中的复特征向量 \mathbf{v} , 则

$$A = PCP^{-1}, \text{ 其中 } P = \begin{bmatrix} \Re \mathbf{v} & \Im \mathbf{v} \end{bmatrix}, C = \begin{bmatrix} a & -b \\ b & a \end{bmatrix}$$

分析. 证明利用了结论: A 是实矩阵, 则 $A(\Re \mathbf{x}) = \Re A\mathbf{x}$, $A(\Im \mathbf{x}) = \Im A\mathbf{x}$. $\Re \mathbf{x}$ 与 $\Im \mathbf{x}$ 线性无关

7.4 离散动力系统

若 A 可对角化, 有 n 个线性无关的特征向量 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 和对应的特征值 $\lambda_1, \dots, \lambda_n$, 且由大到小排列. 由于 $\{\mathbf{v}_1, \dots, \mathbf{v}_n\}$ 为 \mathbb{R}^n 的基. 故任一初始向量可唯一表示为 $\mathbf{x}_0 = c_1\mathbf{v}_1 + \dots + c_n\mathbf{v}_n$, 则

$$\mathbf{x}_k = A^k \mathbf{x}_0 = c_1(\lambda_1)^k \mathbf{v}_1 + \dots + c_n(\lambda_n)^k \mathbf{v}_n$$

线性动力系统中, 只有原点才可能是吸引子($|\lambda| < 1$)或者排斥子($|\lambda| > 1$), 但非线性系统中可能存在多个吸引子或排斥子, 其可用雅可比矩阵的特征值定义. 若特征值正负都有, 则原点为鞍点.

7.5 估计特征值

幂算法、逆幂法、QR算法

若 A 可对角化, 特征向量 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 是 \mathbb{R}^n 的基, 且

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$$

⁶具体情况比较复杂

(注意第一个符号为严格大) 其中 λ_1 称为主特征值

$$\mathbf{x}_k = A^k \mathbf{x}_0 = c_1(\lambda_1)^k \mathbf{v}_1 + \cdots + c_n(\lambda_n)^k \mathbf{v}_n$$

假设 $c_1 \neq 0$, 左右同除 λ_1^k , 可知 $(\lambda_1)^{-k} A^k \mathbf{x} \rightarrow c_1 \mathbf{v}_1 (k \rightarrow \infty)$

7.6 傅里叶级数

$\forall n \geq 1, \{1, \cos t, \cos 2t, \dots, \cos nt, \sin t, \sin 2t, \dots, \sin nt\}$, 定义内积 $\langle f, g \rangle = \int_0^{2\pi} f(t)g(t) dt$, 知这个集合为正交集

定理 69 (傅里叶(Fourier)级数).

$$f(t) = \frac{a_0}{2} + \sum_{k=1}^{\infty} (a_k \cos kt + b_k \sin kt)$$

当 $k \geq 1$ 时,

$$a_k = \frac{\langle f, \cos kt \rangle}{\langle \cos kt, \cos kt \rangle} = \frac{1}{\pi} \int_0^{2\pi} f(t) \cos kt dt, \quad b_k = \frac{\langle f, \sin kt \rangle}{\langle \sin kt, \sin kt \rangle} = \frac{1}{\pi} \int_0^{2\pi} f(t) \sin kt dt$$

常数项,

$$\frac{\langle f, 1 \rangle}{\langle 1, 1 \rangle} = \frac{a_0}{2}$$

7.7 统计学应用

定义 46 (平均值). $p \times N$ 的观测矩阵 $A = [\mathbf{X}_1, \dots, \mathbf{X}_N]$ (即有 N 个样本, 每个样本有 p 个维度的信息), 则其样本均值为 $\mathbf{M} = \frac{1}{N}(\mathbf{X}_1 + \dots + \mathbf{X}_N)$. 平均偏差形式为 $B = [\hat{\mathbf{X}}_1, \dots, \hat{\mathbf{X}}_N]$, 其中 $\hat{\mathbf{X}}_k = \mathbf{X}_k - \mathbf{M}$.

定义 47 (方差). 协方差矩阵为 $S = \frac{1}{N-1} B B^T$ ($B B^T$ 正定, 故 S 正定), 其中元素 s_{ii} 称为 x_i (某一行) 的方差, $s_{ij}, i \neq j$ 称为 x_i 与 x_j 的协方差, 而总方差 $\text{TVar } B = \text{tr } S$

定义 48 (主成分分析). 假设 $A = [\mathbf{X}_1, \dots, \mathbf{X}_N]$ 为平均偏差形式, 找到 $p \times p$ 正交矩阵 $P = [\mathbf{u}_1, \dots, \mathbf{u}_p]$ 使得 $\mathbf{X} = P\mathbf{Y}$, 其中 y_1, \dots, y_p 都线性无关且方差递减. $\mathbf{u}_1, \dots, \mathbf{u}_p$ 为数据的主成分, 第一主成分是 S 最大的特征值对应的特征向量.

注: 主成分分析等同于正交回归

分析. $\mathbf{X}_k = P\mathbf{Y}_k \implies \mathbf{Y}_k = P^{-1}\mathbf{X}_k = P^T\mathbf{X}_k, k = 1, \dots, N \implies S = P D P^T, P^T S P = D$

可以验证对于任意正交矩阵 P , $\mathbf{Y}, \dots, \mathbf{Y}_N$ 的协方差矩阵都是 $P^T S P$

变量的正交变换 $\mathbf{X} = P\mathbf{Y}$ 不改变数据的总方差, 且 $\text{TVar } \mathbf{X} = \text{TVar } \mathbf{Y} = \text{tr } D = \lambda_1 + \dots + \lambda_p$, 商 $\lambda_j / \text{tr } S$ 表明 y_j 的占比, 用于降维