

# 数值计算方法

陈鸿峥

2019.05\*

## 目录

<b>1</b>	<b>简介</b>	<b>2</b>
1.1	误差 . . . . .	2
1.2	需要注意的问题 . . . . .	2
<b>2</b>	<b>插值</b>	<b>2</b>
2.1	拉格朗日插值 . . . . .	3
2.2	牛顿插值 . . . . .	3
2.3	埃尔米特插值 . . . . .	5
2.4	三次样条插值 . . . . .	5
<b>3</b>	<b>线性方程组直接解法</b>	<b>5</b>
3.1	高斯消元法 . . . . .	5
3.2	三角分解 . . . . .	6
3.3	LU分解 . . . . .	6
3.4	乔列斯基(Choleskey)分解 . . . . .	6
3.5	追赶法 . . . . .	7
3.6	分块三角分解 . . . . .	7
<b>4</b>	<b>线性方程组迭代解法</b>	<b>7</b>
4.1	范数与条件数 . . . . .	7
4.2	基本迭代法 . . . . .	9
<b>5</b>	<b>函数逼近</b>	<b>10</b>
5.1	内积与正交多项式 . . . . .	10
5.2	最佳一致逼近 . . . . .	12
5.3	最佳平方逼近 . . . . .	13
5.4	最小二乘法 . . . . .	13

---

\*Build 20190520

<b>6 数值积分与数值微分</b>	<b>14</b>
6.1 基本公式 . . . . .	14
6.2 牛顿-科茨公式 . . . . .	16
6.3 高斯公式 . . . . .	17
6.4 多重积分 . . . . .	17
6.5 数值微分 . . . . .	17
<b>7 非线性方程求根</b>	<b>18</b>

## 1 简介

### 1.1 误差

- 原始误差：模型误差
- 观测误差：测量数据产生的误差
- 方法误差：截断误差
- 计算误差：舍入误差

### 1.2 需要注意的问题

- 避免相近的数相减，如 $\sqrt{1001} - \sqrt{1000}$ 有效数字会损失，分子有理化可使误差减小。数学上等价的公式在计算上是不等价的！
- 避免数量级相差太大的两数相除，容易溢出
- 避免大数和小数相加减，浮点数计算要对阶
- 简化计算步骤

## 2 插值

**定理 1 (唯一性).**  $n$ 次插值多项式存在且唯一

**分析.** 设 $n$ 次多项式 $p(x) = a_0 + a_1x + \cdots + a_nx^n$ 为函数 $f(x)$ 在 $[a, b]$ 上 $n + 1$ 个互异节点 $x_i (i = 0, 1, \dots, n)$ 上的插值多项式，则求 $p(x)$ 的系数 $a_i$ 相当于解线性方程组

$$\begin{cases} a_0 + a_1x_0 + \cdots + a_nx_0^n = y_0 \\ a_0 + a_1x_1 + \cdots + a_nx_1^n = y_1 \\ \vdots \\ a_0 + a_1x_n + \cdots + a_nx_n^n = y_n \end{cases}$$

其系数行列式为范德蒙特行列式  $V = \prod_{i=1}^n \prod_{j=0}^{i-1} (x_i - x_j)$ , 因为  $x_i$  互不相同, 故  $V \neq 0$ 。进而由克莱姆法则,  $a_i$  解存在且唯一。

由于  $p(x)$  为线性空间  $P_n(x)$ <sup>1</sup> 的一个点, 因而其基底/插值基函数  $\phi(x)$  不唯一, 有多种表示方法 (不同的线性组合)

$$p(x) = a_0\phi_0(x) + a_1\phi_1(x) + \cdots + a_n\phi_n(x)$$

## 2.1 拉格朗日插值

**定义 1** (拉格朗日插值基函数). 节点  $x_k$  上的插值基函数  $l_k(x)$  满足

$$l_k(x_k) = \begin{cases} 1 & i = k \\ 0 & i \neq k \end{cases}$$

由定义知  $l_k(x)$  的零点为  $x_i, i \neq k$ , 待定系数  $A_k$

$$l_k(x) = A_k(x - x_0)(x - x_1) \cdots (x - x_{k-1})(x - x_{k+1}) \cdots (x - x_n)$$

可求得  $A_k$ , 进而得到插值基函数

$$l_k(x) = \prod_{\substack{i=0 \\ i \neq k}}^n \frac{(x - x_i)}{x_k - x_i}$$

因此拉格朗日插值函数为

$$L_n(x) = \sum_{k=0}^n f(x_k) \prod_{\substack{i=0 \\ i \neq k}}^n \frac{(x - x_i)}{x_k - x_i}$$

其中  $L_1(x)$  称为线性插值,  $L_2(x)$  称为抛物线插值

误差估计

$$R_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \prod_{i=0}^n (x - x_i), \quad \xi = \xi(x) \in (a, b)$$

## 2.2 牛顿插值

**定义 2** (牛顿插值基函数).

$$\begin{cases} \varphi_0(x) = 1 \\ \varphi_j(x) = \prod_{i=0}^{j-1} (x - x_i), \quad j = 1, 2, \dots, n \end{cases}$$

进而牛顿插值函数为

$$N_n(x) = a_0 + a_1(x - x_0) + a_2(x - x_0)(x - x_1) + \cdots = a_0 + \sum_{i=1}^n a_i \prod_{j=0}^{i-1} (x - x_j)$$

---

<sup>1</sup>次数小于等于  $n$  的代数多项式的集合

实际上就是将 $x_i$ 之后的项全部为0消掉了。

由 $f(x_k) = N_n(x_k)$ , 对比系数可得

$$\begin{aligned} a_0 &= f(x_0) \\ a_1 &= \frac{f(x_1) - f(x_0)}{x_1 - x_0} \\ a_2 &= \frac{\frac{f(x_2) - f(x_0)}{x_2 - x_0} - \frac{f(x_1) - f(x_0)}{x_1 - x_0}}{x_2 - x_1} \end{aligned}$$

**定义 3** (差商). 一阶差商 $f[x_i, x_k] = \frac{f(x_k) - f(x_i)}{x_k - x_i}$ , 二阶差商 $f[x_i, x_j, x_k] = \frac{f[x_i, x_k] - f[x_j, x_k]}{x_k - x_j}$ , 高阶差商为

$$f[x_0, x_1, \dots, x_{k-1}, x_k] = \frac{f[x_0, x_1, \dots, x_{k-2}, x_k] - f[x_0, x_1, \dots, x_{k-1}]}{x_k - x_{k-1}}$$

由差商定义可得以下差商表 (注: 下面 $f_i := f(x_i)$ )

$x_k$	$y_k$	一阶	二阶	三阶
$x_0$	$f_0$			
$x_1$	$f_1$	$f[x_0, x_1]$		
$x_2$	$f_2$	$f[x_1, x_2]$	$f[x_0, x_1, x_2]$	
$x_3$	$f_3$	$f[x_2, x_3]$	$f[x_1, x_2, x_3]$	$f[x_0, x_1, x_2, x_3]$

并且有

$$\begin{aligned} a_0 &= f(x_0) \\ a_1 &= f[x_0, x_1] \\ a_2 &= f[x_0, x_1, x_2] \\ &\vdots \\ a_n &= f[x_0, x_1, \dots, x_n] \end{aligned}$$

由误差估计的计算可得差商与导数之间的关系

$$f[x_0, x_1, \dots, x_k] = \frac{f^{(k)}(\xi)}{k!}$$

可以看出, 当增加一个节点时, 牛顿插值只需增加一项, 而拉格朗日插值需要全部重新算。

**定义 4** (差分). 设已知函数 $f(x)$ 在等距节点 $x_i = x_0 + ih (i = 0, 1, 2, \dots, n)$ 上的函数值为 $f(x_i) = f_i$ , 其中 $h > 0$ 为步长, 则称 $\Delta f_i = f(x_i + h) - f(x_i) = f_{i+1} - f_i$ 为 $f(x)$ 在 $x_i$ 处步长为 $h$ 的一阶向前差分。称 $\Delta^2 f_i = \Delta(\Delta f_i) = \Delta f_{i+1} - \Delta f_i$ 为函数 $f(x)$ 在 $x_i$ 处的二阶向前差分。一般地 $\Delta^n f_i = \Delta(\Delta^{n-1} f_i)$ 为函数 $f(x)$ 在 $x_i$ 处的 $n$ 阶向前差分。并规定,  $\Delta^0 f_i = f_i$ 为零阶差分。

差分与差商的关系为

$$f[x_0, x_1, \dots, x_k] = \frac{\Delta^k f_0}{k! h^k}, \quad k = 1, 2, \dots, n$$

则牛顿插值公式的向前差分形式为

$$N_n(x) = N_n(x_0 + th) = f_0 + \frac{t}{1!} \Delta f_0 + \frac{t(t-1)}{2!} \Delta^2 f_0 + \cdots + \frac{t(t-1) \cdots (t-n+1)}{n!} \Delta^n f_0, t \in [0, 1]$$

类似于泰勒展开。

### 2.3 埃尔米特插值

不仅要求插值点的函数值  $H(x_i)$  与原函数的值  $f(x_i)$  相同，还要求它们有公切线，即  $H'(x_i) = f'(x_i)$ 。若所有插值点都要满足上述条件，则埃尔米特(Hermite)插值多项式为  $2n+1$  次的。

### 2.4 三次样条插值

分多段，每段用三次函数逼近

三次样条条件

- 插值条件：  $s_k(x_j) = y_j, j = k-1, k, k = 1, 2, \dots, n$ ，共  $2n$  个条件
- 端点导数条件：  $\lim_{x \rightarrow x_k^-} s^{(p)}(x) = \lim_{x \rightarrow x_k^+} s^{(p)}(x), p = 1, 2, k = 1, \dots, n-1$ ，共  $2n-2$  个条件
- 边界条件：
  - 第一类边界条件：  $s'(x_0) = f'_0, s'(x_n) = f'_n$ ，其中  $f'_0, f'_n$  为给定值
  - 第二类边界条件：  $s''(x_0) = f''_0, s''(x_n) = f''_n$ ，其中  $f''_0, f''_n$  为给定值，若为0，则为自然边界条件
  - 周期性条件：  $\lim_{x \rightarrow x_0^+} s^{(p)}(x) = \lim_{x \rightarrow x_n^-} s^{(p)}(x), p = 1, 2$

三转角方法，用一阶导数求解；三弯矩方法，用二阶导数求解。

$$\begin{bmatrix} 2 & 1 & & & & \\ \mu_1 & 2 & \lambda_1 & & & \\ & \mu_2 & 2 & \lambda_2 & & \\ & & \ddots & \ddots & \ddots & \\ & & & \mu_{n-1} & 2 & \lambda_{n-1} \\ & & & & 1 & 2 \end{bmatrix} \begin{bmatrix} M_0 \\ M_1 \\ M_2 \\ \vdots \\ M_{n-1} \\ M_n \end{bmatrix} = \begin{bmatrix} d_0 \\ d_1 \\ d_2 \\ \vdots \\ d_{n-1} \\ d_n \end{bmatrix}$$

## 3 线性方程组直接解法

### 3.1 高斯消元法

即逐行做消元，变为上三角矩阵后回代

但由于浮点误差，高斯消元容易产生“大数吃小数”的现象，而达到错误的解（不稳定），如下式

$$\begin{cases} \varepsilon x_1 + x_2 = 1 \\ x_1 + x_2 = 2 \end{cases}$$

- 列主元高斯消去法：每次选择一列中最大的元素所在行，然后与当前行交换
- 全主元消去法：每次选择矩阵中最大元素所在行，与当前行交换

### 3.2 三角分解

### 3.3 LU分解

- 杜利脱尔(Doolittle)分解：由高斯消元法， $A = L_1^{-1} \cdots L_{n-1}^{-1} U = LU$ ，其中 $L$ 为单位下三角矩阵， $U$ 为上三角
- 克洛脱(Crout)分解： $A = LU$ ，其中 $L$ 为下三角， $U$ 为单位上三角
- LDU分解： $A = LD\tilde{U}$ ，其中 $L$ 为单位下三角， $D = \text{diag}(u_{11}, u_{22}, \dots, u_{nn})$ ， $\tilde{U} = D^{-1}U$ 为单位上三角

杜利脱尔分解要求对 $A$ 高斯消去时，所有主元元素 $a_{ii}^{(i)}$ 不为零

**定理 2.** 主元元素 $a_{ii}^{(i)}$ 不为零的充要条件为 $n$ 阶矩阵 $A$ 的所有顺序主子式均不为0

**定理 3.** 若 $A$ 的所有顺序主子式均不为0，则矩阵 $A$ 的 $LU$ 分解都具有唯一性

### 3.4 乔列斯基(Choleskey)分解

当 $A$ 为对称正定矩阵时，所有顺序主子式都大于0，因而存在唯一LU分解。用LDU分解， $D$ 为非奇异的对角矩阵，由 $A$ 的对称性有

$$A = LDU = U^T D U^T$$

又由分解的唯一性，有 $L = D^T$ ，得 $A = LDL^T$

设 $D = \text{diag}(d_1, \dots, d_n)$ ,  $d_i \neq 0$ ，则 $D$ 的对角元素均为正数

记 $D^{1/2} = \text{diag}(\sqrt{d_1}, \sqrt{d_2}, \dots, \sqrt{d_n})$ ，则

$$A = LDL^T = LD^{1/2} D^{1/2} L^T = (LD^{1/2})(LD^{1/2})^T = GG^T$$

求解方法为平方根法。

### 3.5 追赶法

设 $n$ 阶方程组 $A\mathbf{x} = \mathbf{d}$ ，其中 $A$ 为三对角方程

$$A = \begin{bmatrix} b_1 & c_1 & & & \\ a_2 & b_2 & c_2 & & \\ & \ddots & \ddots & \ddots & \\ & & a_{n-1} & b_{n-1} & c_{n-1} \\ & & & a_n & b_n \end{bmatrix}, \mathbf{d} = \begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_{n-1} \\ d_n \end{bmatrix}$$

对矩阵 $A$ 做克洛脱分解，有

$$L = \begin{bmatrix} l_1 & & & & \\ v_2 & l_2 & & & \\ & \ddots & \ddots & & \\ & & v_{n-1} & l_{n-1} & \\ & & & v_n & l_n \end{bmatrix}, U = \begin{bmatrix} 1 & u_1 & & & \\ & 1 & u_2 & & \\ & & \ddots & \ddots & \\ & & & 1 & u_{n-1} \\ & & & & 1 \end{bmatrix}$$

进而 $A = LU$ ，做两次回代即可

$$\begin{cases} L\mathbf{y} = \mathbf{d} \\ U\mathbf{x} = \mathbf{y} \end{cases}$$

### 3.6 分块三角分解

$$\mathbf{L} = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{E} & \mathbf{I} \end{bmatrix}, \mathbf{U} = \begin{bmatrix} \mathbf{F} & \mathbf{G} \\ \mathbf{0} & \mathbf{H} \end{bmatrix}$$

且满足 $\mathbf{A} = \mathbf{LU}$ ，经计算有

$$\mathbf{L} = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{CA}^{-1} & \mathbf{I} \end{bmatrix}, \mathbf{U} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{0} & \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B} \end{bmatrix}$$

其中 $\mathbf{S} = \mathbf{D} - \mathbf{CA}^{-1}\mathbf{B}$ 为 $\mathbf{A}$ 的舒尔(schur)补。

## 4 线性方程组迭代解法

### 4.1 范数与条件数

**定义 5** (向量的范数). 对任意 $n$ 维向量 $\mathbf{x}$ ，若对应非负实数 $\|\mathbf{x}\|$ ，满足

1.  $\|\mathbf{x}\| \geq 0$ ，当且仅当 $\mathbf{x} = \mathbf{0}$ 时等号成立
2. 对任意 $\alpha \in \mathbb{R}$ ， $\|\alpha\mathbf{x}\| = |\alpha| \cdot \|\mathbf{x}\|$

3. 对任意的 $n$ 维向量 $\mathbf{x}$ 和 $\mathbf{y}$ , 满足三角不等式 $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$

则称 $\|\mathbf{x}\|$ 为 $\mathbf{x}$ 的范数, 其中1-范数、2-范数、无穷范数定义如下

$$\begin{aligned}\|\mathbf{x}\|_1 &= \sum_{i=1}^n |x_i| \\ \|\mathbf{x}\|_2 &= \sqrt{\sum_{i=1}^n |x_i|^2} \\ \|\mathbf{x}\|_\infty &= \max_{1 \leq i \leq n} |x_i|\end{aligned}$$

**定义 6** (矩阵的范数). 对于 $n$ 阶方阵 $\mathbf{A}$ , 若对应非负实数 $\|\mathbf{A}\|$ , 满足

1.  $\|\mathbf{A}\| \geq 0$ , 当且仅当 $\mathbf{A} = \mathbf{0}$ 时等号成立
2. 对任意 $\alpha \in \mathbb{R}$ ,  $\|\alpha \mathbf{A}\| = |\alpha| \cdot \|\mathbf{A}\|$
3. 对任意两个 $n$ 阶方阵 $\mathbf{A}$ 和 $\mathbf{B}$ , 满足三角不等式 $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|$
4. 对任意两个 $n$ 阶方阵 $\mathbf{A}$ 和 $\mathbf{B}$ , 满足矩阵乘法要求 $\|\mathbf{AB}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{B}\|$

则称 $\|\mathbf{A}\|$ 为方阵 $\mathbf{A}$ 的矩阵范数。记 $\rho(\mathbf{A}) = \max_{1 \leq i \leq n} |\lambda_i|$ 为 $\mathbf{A}$ 的谱半径, 这里 $\lambda_i$ 为 $\mathbf{A}$ 的特征值, 矩阵的1-范数、2-范数、无穷范数和 $F$ 范数分别定义如下

$$\begin{aligned}\|\mathbf{A}\|_1 &= \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}| \\ \|\mathbf{A}\|_2 &= \sqrt{\rho(\mathbf{A}^T \mathbf{A})} \\ \|\mathbf{A}\|_\infty &= \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}| \\ \|\mathbf{A}\|_F &= \sqrt{\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2}\end{aligned}$$

注意矩阵的 $F$ -范数才是向量2-范数的直接推广, 而矩阵的2-范数是计算 $\mathbf{A}^T \mathbf{A}$ 的谱半径, 又被称为谱范数

相容的向量范数和矩阵范数, 满足

$$\|\mathbf{Ax}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|$$

一些相容的范数如下

- 矩阵1-范数与向量1-范数
- 矩阵2-范数与向量2-范数
- 矩阵无穷范数与向量无穷范数
- 矩阵 $F$ 范数与向量2-范数

**定义 7** (条件数). 设 $\mathbf{A}$ 为 $n$ 阶非奇异矩阵, 称数 $\text{cond}(\mathbf{A}) = \|\mathbf{A}\| \|\mathbf{A}^{-1}\|$ 为线性方程组 $\mathbf{Ax} = \mathbf{b}$ 或矩阵 $\mathbf{A}$ 的条件数。其对方程组的解的相对误差起到关键的控制作用



## 4.2 基本迭代法

给定线性方程组 $\mathbf{Ax} = \mathbf{b}$ ，设 $\mathbf{A} = \mathbf{M} - \mathbf{N}$ ，其中 $\mathbf{M}$ 为非奇异矩阵，则原式变为

$$\mathbf{Mx} = \mathbf{Nx} + \mathbf{b}$$

左右乘上 $\mathbf{M}^{-1}$ ，有

$$\mathbf{x} = \mathbf{M}^{-1}\mathbf{Nx} + \mathbf{M}^{-1}\mathbf{b} = \mathbf{Bx} + \mathbf{g}$$

给定初始向量 $\mathbf{x}^{(0)}$ ，按照下式迭代

$$\mathbf{x}^{(n+1)} = \mathbf{Bx}^{(n)} + \mathbf{g}$$

最终若收敛至 $\mathbf{x}^*$ ，则原方程得出解。实际迭代还是用

$$\mathbf{Mx}^{(k+1)} = \mathbf{Nx}^{(k)} + \mathbf{b}$$

将 $\mathbf{A}$ 拆分成三个矩阵之和（只是将矩阵 $\mathbf{A}$ 元素分块而已）

$$\mathbf{A} = \mathbf{D} - \mathbf{L} - \mathbf{U}$$

对角线阵 $\mathbf{D}$ 、负的严格下三角阵 $\mathbf{L}$ 和严格上三角阵 $\mathbf{U}$

### 4.2.1 雅可比迭代法

取 $\mathbf{M} = \mathbf{D}$ 和 $\mathbf{N} = \mathbf{L} + \mathbf{U}$ ，即得雅可比迭代法

$$\mathbf{Dx}^{(k+1)} = (\mathbf{L} + \mathbf{U})\mathbf{x}^{(k)} + \mathbf{b}$$

### 4.2.2 高斯-赛德尔迭代法

如果在雅可比迭代算法的第三步，将算出来的 $\mathbf{x}^{(k+1)}$ 的分量立即投入到下一个迭代方程，则得到Gauss-Seidel迭代法

$$\mathbf{Dx}^{(k+1)} = \mathbf{Lx}^{(k+1)} + \mathbf{Ux}^{(k)} + \mathbf{b}$$

### 4.2.3 超松弛(SOR)迭代法

将GS迭代改写为

$$\begin{aligned}\mathbf{x}^{(k+1)} &= \mathbf{D}^{-1}(\mathbf{Lx}^{(k+1)} + \mathbf{Ux}^{(k)} + \mathbf{b}) \\ &= \mathbf{x}^{(k)} + \mathbf{D}^{-1}(\mathbf{Lx}^{(k+1)} + \mathbf{Ux}^{(k)} - \mathbf{Dx}^{(k)} + \mathbf{b})\end{aligned}$$

等号右侧第二项为修正量，为获得更快的收敛速度，在其前面乘系数 $\omega$ ，即得到逐次超松弛(SOR)迭代法，其中 $\omega$ 为松弛因子

$$\mathbf{x}^{(k+1)} = (\mathbf{D} - \omega\mathbf{L})^{-1}[(1 - \omega)\mathbf{D} + \omega\mathbf{U}]\mathbf{x}^{(k)} + \omega(\mathbf{D} - \omega\mathbf{L})^{-1}\mathbf{b}$$

此时迭代矩阵为

$$\mathbf{B}_{SOR} = (\mathbf{D} - \omega \mathbf{L})^{-1}[(1 - \omega)\mathbf{D} + \omega \mathbf{U}]$$

## 5 函数逼近

用函数 $f(x)$ 和 $p(x)$ 的最大误差

$$\|p - f\|_{\infty} = \max_{a \leq x \leq b} |p(x) - f(x)|$$

作为度量逼近函数 $p(x)$ 对被逼近函数 $f(x)$ 的逼近程度。若存在一个函数序列满足

$$\lim_{n \rightarrow \infty} \|p_n(x) - f(x)\|_{\infty} = 0$$

则意味着序列 $\{p_n(x)\}$ 在区间 $[a, b]$ 上一致收敛至 $f(x)$ 。序列 $\{p_n(x)\}$ 对 $f(x)$ 的逼近称为**一致逼近**。

也可用积分

$$\|p - f\|_2 = \left( \int_a^b (p(x) - f(x))^2 dx \right)^{\frac{1}{2}}$$

作为度量函数。若存在一个函数序列满足

$$\lim_{n \rightarrow \infty} \|p_n(x) - f(x)\|_2 = 0$$

则意味着序列 $\{p_n(x)\}$ 在区间 $[a, b]$ 上平方收敛至 $f(x)$ 。序列 $\{p_n(x)\}$ 对 $f(x)$ 的逼近称为**平方逼近**。

### 5.1 内积与正交多项式

**定义 8** (权函数). 设 $[a, b]$ 为有限或无限区间,  $\rho(x)$ 是定义在 $[a, b]$ 上的非负函数,  $\int_a^b x^k \rho(x) dx$ 对 $k = 0, 1, \dots$ 都存在, 且对非负的 $f(x) \in C[a, b]^2$ , 若 $\int_a^b f(x) \rho(x) dx = 0$ , 则 $f(x) \equiv 0$ , 称 $\rho(x)$ 为 $[a, b]$ 上的权函数, 其刻画了点 $x$ 在 $[a, b]$ 上的重要性

**定义 9** (内积). 设 $f(x), g(x) \in C[a, b]$ ,  $\rho(x)$ 为 $[a, b]$ 上的权函数, 则函数 $f(x)$ 和 $g(x)$ 的内积为

$$\langle f, g \rangle := \int_a^b \rho(x) f(x) g(x) dx$$

定义了内积的线性空间称为内积空间。内积需满足

1.  $\langle f, g \rangle = \langle g, f \rangle$
2.  $\langle c_1 f + c_2 g, h \rangle = c_1 \langle f, h \rangle + c_2 \langle g, h \rangle$ ,  $c_1, c_2$ 为常数
3.  $\langle f, f \rangle \geq 0 \iff f \equiv 0, \langle f, f \rangle = 0$

---

<sup>2</sup> $C[a, b]$ 表示区间 $[a, b]$ 上连续函数的全体

**定义 10 (范数).** 对内积空间  $C[a, b]$  中的每一个函数  $f(x)$ , 都赋予一个数值

$$\|f\| = \sqrt{\int_a^b \rho(x)[f(x)]^2 dx}$$

范数需满足

1.  $\|f\| \geq 0$ , 当且仅当  $f \equiv 0$  时,  $\|f\| = 0$
2.  $\|cf\| = |c| \cdot \|f\|$ ,  $c$  是常数
3.  $\|f + g\| \leq \|f\| + \|g\|$

正交函数系

**定义 11 (正交).** 设  $f(x), g(x) \in C[a, b]$ ,  $\rho(x)$  为  $[a, b]$  上的权函数, 若内积

$$\langle f, g \rangle = \int_a^b \rho(x)f(x)g(x) dx = 0$$

则称  $f(x), g(x)$  在  $[a, b]$  上带权  $\rho(x)$  正交

### 5.1.1 勒让德多项式

勒让德(Legendre)多项式是区间  $[-1, 1]$  上权函数  $\rho(x) = 1$  的正交多项式

$$P_0(x) = 1, \quad P_n(x) = \frac{1}{2^n n!} \frac{d^n}{dx^n} (x^2 - 1)^n$$

勒让德多项式有许多重要的性质

1. 正交性

$$\langle P_n, P_m \rangle = \int_{-1}^1 P_n(x)P_m(x) dx = \begin{cases} 0 & m \neq n \\ \frac{2}{2n+1} & m = n \end{cases}$$

2. 递推公式

$$(n+1)P_{n+1}(x) = (2n+1)xP_n(x) - nP_{n-1}(x), P_0(x) = 1, P_1(x) = x$$

### 5.1.2 切比雪夫多项式

切比雪夫(Chebyshev)多项式为区间  $[-1, 1]$  上关于权函数  $\rho(x) = \frac{1}{\sqrt{1-x^2}}$  的正交多项式

$$T_n(x) = \cos(n \arccos x)$$

1. 正交性

$$\langle T_n, T_m \rangle = \int_{-1}^1 \frac{T_n(x)T_m(x)}{\sqrt{1-x^2}} dx = \begin{cases} 0 & m \neq n \\ \frac{\pi}{2} & m = n \neq 0 \\ \pi & m = n = 0 \end{cases}$$

分析. 令  $x = \cos \theta$ , 由三角函数正交性<sup>3</sup>即得结论

## 2. 递推公式

$$T_{n+1}(x) = 2xT_n(x) - T_{n-1}(x), T_0(x) = 1, T_1(x) = x$$

分析. 同样三角代换  $x = \cos \theta$ , 并结合和差化积即得结论

## 3. 奇偶性

$$T_n(-x) = (-1)^n T_n(x)$$

4.  $T_n(x)$  在  $(-1, 1)$  内的  $n$  个零点为  $x_k = \cos \frac{2k-1}{2n}\pi$ , 在  $[-1, 1]$  上有  $n+1$  个极值点  $y_k = \cos \frac{k}{n}\pi$

5.  $T_n(x)$  的最高次幂  $x^n$  的系数为  $2^{n-1}, n \geq 1$

### 5.1.3 其他正交多项式

1. 拉盖尔(Laguerre)多项式

2. 埃尔米特(Hermite)多项式

## 5.2 最佳一致逼近

定义 12. 设  $f(x) \in C[a, b]$ , 以及多项式序列  $p_n(x)$ , 若  $\forall \varepsilon, \exists N, n > N$ , 不等式

$$\max_{a \leq x \leq b} |p_n(x) - f(x)| < \varepsilon$$

成立, 则称多项式  $p_n(x)$  在  $[a, b]$  上一致逼近于  $f(x)$

定义 13. 若  $\exists x_0 \in [a, b]$ , 使得

$$|p(x_0) - f(x_0)| = \mu = \|p - f\|_\infty = \max_{a \leq x \leq b} |p(x) - f(x)|$$

则称  $x_0$  是  $p(x)$  关于  $f(x)$  的正/负偏差点

定理 4 (Chebyshev).  $p_n^*(x) \in P_n$  是  $f(x) \in C[a, b]$  的最佳一致逼近多项式的充分必要条件是: 在  $[a, b]$  上至少有  $n+2$  个交替为正负的偏差点, 即至少有  $n+2$  个点  $a \leq x_1 < x_2 < \dots < x_{n+2} \leq b$ , 使得

$$p_n^*(x_k) - f(x_k) = (-1)^k \sigma \|f - p_n^*\|_\infty, \sigma = \pm 1, k = 1, 2, \dots, n+2$$

上述点  $\{x_k\}_1^{n+2}$  称为切比雪夫交错点组

线性最佳一致逼近: 设  $f(x)$  在  $[a, b]$  上有二阶导数, 且  $f''(x)$  在  $[a, b]$  上不变号,  $p_1(x) = a_0 + a_1x$  为线性最佳一致逼近, 其中

$$\begin{cases} a_0 = \frac{1}{2}(f(a) + f(x_2)) - \frac{a+x_2}{2} \frac{f(b)-f(a)}{b-a} & f'(x_2) = a_1 \\ a_1 = \frac{f(b)-f(a)}{b-a} \end{cases}$$

<sup>3</sup>数学分析傅里叶级数一节, 三角函数系  $\{1, \cos x, \sin x, \dots, \cos nx, \sin nx, \dots\}$  中任意两个不同函数在  $[-\pi, \pi]$  都正交

即拟合直线的斜率与连接 $a, b$ 两点的割线斜率相同(Lagrange切线,  $x_2$ 为切点), 且过 $a$ 和 $x_2$ 的中点。

### 5.3 最佳平方逼近

**定义 14** (最佳平方逼近). 设 $f(x) \in C[a, b]$ , 如果存在 $s^*(x) \in \varphi$ , 使

$$\int_a^b \rho(x)[f(x) - s^*(x)]^2 dx = \min_{s(x) \in \varphi} \int_a^b \rho(x)[f(x) - s(x)]^2 dx$$

则称 $s^*$ 为 $f(x)$ 在集合 $\varphi$ 中的最佳平方逼近函数。若 $\varphi = P_n = \text{Span}\{1, x, \dots, x^n\}$ , 则 $s^*(x)$ 为 $f(x)$ 的 $n$ 次最佳平方逼近多项式。

$$G_n = \begin{bmatrix} \langle \varphi_0, \varphi_0 \rangle & \langle \varphi_0, \varphi_1 \rangle & \cdots & \langle \varphi_n, \varphi_n \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle \varphi_n, \varphi_0 \rangle & \langle \varphi_n, \varphi_1 \rangle & \cdots & \langle \varphi_n, \varphi_n \rangle \end{bmatrix}$$

希尔伯特(Hilbert)矩阵

$$H_{n+1} = \begin{bmatrix} 1 & \frac{1}{2} & \cdots & \frac{1}{n+1} \\ \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n+2} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{n+1} & \frac{1}{n+2} & \cdots & \frac{1}{2n+1} \end{bmatrix}$$

法方程为

$$H_{n+1} \mathbf{a} = \mathbf{d}$$

解为 $\mathbf{a} = \mathbf{a}^*$ , 进而得到最佳平方逼近式 $p_n^*(x)$

### 5.4 最小二乘法

拟合函数为

$$\sum_{j=0}^n a_j \varphi_j(x)$$

$\varphi_i(x)$ 为基函数, 且线性无关, 求解下面法方程

$$\begin{bmatrix} \langle \varphi_0, \varphi_0 \rangle & \langle \varphi_0, \varphi_1 \rangle & \cdots & \langle \varphi_n, \varphi_n \rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle \varphi_n, \varphi_0 \rangle & \langle \varphi_n, \varphi_1 \rangle & \cdots & \langle \varphi_n, \varphi_n \rangle \end{bmatrix} \begin{bmatrix} a_0 \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} \langle f, \varphi_0 \rangle \\ \vdots \\ \langle f, \varphi_n \rangle \end{bmatrix}$$

其中

$$\begin{cases} \langle \varphi_j, \varphi_k \rangle = \sum_{i=0}^m \varphi_j(x_i) \varphi_k(x_i) \\ \langle f, \varphi_k \rangle = \sum_{i=0}^m f(x_i) \varphi_k(x_i) \end{cases}$$

特别地，如果用代数多项式拟合，即取

$$\{\varphi_0, \varphi_1, \dots, \varphi_n\} = \{1, x, \dots, x^n\}$$

有法方程

$$\begin{bmatrix} \sum_{i=1}^m 1 & \sum_{i=1}^m x_i & \cdots & \sum_{i=1}^m x_i^n \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{i=0}^m x_i^n & \sum_{i=0}^m x_i^{n+1} & \cdots & \sum_{i=0}^m x_i^{2n} \end{bmatrix}$$

例 1. 用最小二乘法求下面数据的二次拟合  $y = a\theta + b\theta^2$

$\theta$	1	2	3	4
$f$	0.8	1.5	1.8	2.0

分析. 注意基底分别为  $\varphi_1(x) = \theta, \varphi_2(x) = \theta^2$ , 则

$$\begin{bmatrix} \sum_{i=1}^4 \theta_i^2 & \sum_{i=1}^4 \theta_i^3 \\ \sum_{i=1}^4 \theta_i^3 & \sum_{i=1}^4 \theta_i^4 \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^4 \theta_i f_i \\ \sum_{i=1}^4 \theta_i^2 f_i \end{bmatrix}$$

代入数据可解得

$$\begin{cases} a = 0.9491 \\ b = -0.11274 \end{cases}$$

## 6 数值积分与数值微分

只要  $\max_{a \leq x \leq b} |f(x) - P_n(x)| \leq \varepsilon$ , 就有误差估计

$$\left| \int_a^b f(x) \, dx - \int_a^b P_n(x) \, dx \right| \leq (b-a)\varepsilon$$

### 6.1 基本公式

- 中点公式

$$I = \int_a^b f(x) \, dx \approx (b-a)f\left(\frac{a+b}{2}\right)$$

$$R = \frac{1}{24}(b-a)^3 f''(\xi)$$

- 梯形公式 (一次插值)

$$I = \int_a^b f(x) \, dx \approx \frac{1}{2}(b-a)[f(a) + f(b)]$$

$$R = -\frac{1}{12}(b-a)^3 f''(\xi)$$

- 辛普森公式（二次插值）

$$I = \int_a^b f(x) \, dx \approx \frac{1}{6}(b-a) \left[ f(a) + 4f\left(\frac{a+b}{2}\right) + f(b) \right]$$

$$R = -\frac{(b-a)^5}{2880} f^{(4)}(\xi)$$

分析. 误差公式的推导通常在某一点处展开, 然后结合积分第一中值定理计算。如下例计算中点公式误差, 由泰勒公式

$$f(x) = f\left(\frac{a+b}{2}\right) + f'\left(\frac{a+b}{2}\right)\left(x - \frac{a+b}{2}\right) + \frac{1}{2}f''(\eta(x))\left(x - \frac{a+b}{2}\right)^2, \eta(x) \in (a, b)$$

左右两边积分, 连续用两次积分第一中值定理有

$$\begin{aligned} \int_a^b f(x) \, dx &= \int_a^b f\left(\frac{a+b}{2}\right) \, dx + f'\left(\frac{a+b}{2}\right) \int_a^b \left(x - \frac{a+b}{2}\right) \, dx + \frac{1}{2} \int_a^b f''(\eta(x)) \left(x - \frac{a+b}{2}\right)^2 \, dx, \eta(x) \in (a, b) \\ &= (b-a)f\left(\frac{a+b}{2}\right) + 0 + \frac{1}{2}f''(\xi) \int_a^b \left(x - \frac{a+b}{2}\right)^2 \, dx, \xi \in (a, b) \\ &= \frac{1}{24}(b-a)^3 \end{aligned}$$

通常记

$$I[f] = \int_a^b f(x) \, dx \approx \sum_{i=0}^n \omega_i f(x_i) = Q[f]$$

为求积公式, 其中  $x_i$  为求积节点,  $\omega_i$  为求积系数, 误差/余项则记为

$$R[f] = I[f] - Q[f]$$

**定义 15** (代数精度). 对所有次数小于等于  $m$  的多项式  $f(x)$ , 等式

$$\int_a^b f(x) \, dx = \sum_{i=0}^n \omega_i f(x_i)$$

成立, 但对于  $m+1$  次的某个多项式不精确成立, 则称该求积公式代数精度为  $m$  次。

对于使代数精度尽可能高的题目, 都是令  $f(x) = 1, x, x^2, \dots$  (相当于取特殊值), 然后左右两边相等解方程组。

记

$$x_{i+\frac{1}{2}} = \frac{1}{2}(x_i + x_{i+1})$$

由定积分性质

$$\int_a^b f(x) \, dx = \sum_{i=0}^{n-1} \int_{x_i}^{x_{i+1}} f(x) \, dx$$

进而每一个小段都可以用前面的基本公式, 进而得到复合积分公式。记  $h = \frac{b-a}{n}$ , 则

- 复合中点公式

$$M_n := \sum_{i=0}^{n-1} h f\left(x_{i+\frac{1}{2}}\right)$$

$$R_M = \sum_{i=0}^{n-1} \frac{1}{24} h^3 f''(\xi_i)$$

- 复合梯形公式

$$T_n := \frac{h}{2} [f(a) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b)]$$

$$R_T = -\frac{1}{12} (b-a) h^2 f''(\eta), \eta \in (a, b)$$

- 复合辛普森公式

$$S_n := \frac{h}{6} \left[ f(a) + 4 \sum_{i=0}^{n-1} f(x_{i+\frac{1}{2}}) + 2 \sum_{i=1}^{n-1} f(x_i) + f(b) \right]$$

$$R_S = -\frac{1}{2880} (b-a) h^4 f^{(4)}(\eta)$$

龙贝格(Romberg)求积方法

$$T_n^{(m)} = \frac{T_{2n}^{(m-1)} - 2^{-2(m-1)} T_n^{(m-1)}}{1 - 2^{-2(m-1)}}$$

可证  $T_n^{(m)} (m \leq n)$  的计算精度为  $O(h^{2m})$

## 6.2 牛顿-科茨公式

直接用  $n$  次的拉格朗日函数代替被积函数，即得牛顿-科茨(Newton-Cotes)公式

$$Q = (b-a) \sum_{i=0}^n \frac{(-1)^{n-i}}{ni!(n-i)!} \left( \int_0^n \prod_{j=0, j \neq i}^n (t-j) dt \right) f(x_i)$$

$$= \sum_{i=0}^n (b-a) C_i^{(n)} f(x_i)$$

$$= \sum_{i=0}^n \omega_i f(x_i)$$

其中  $C_i^{(n)}$  为科茨系数，有以下性质

- $\sum_{i=0}^n C_i^{(n)} = 1$
- $C_i^{(n)}$  对  $i$  有对称性:  $C_i^{(n)} = C_{n-1-i}^{(n)}$
- $n \geq 8$  科茨系数有正有负，求积公式稳定性得不到保证，故一般不采用太高阶

**定理 5.** 当  $n$  为奇数时，牛顿-科茨公式代数精度至少为  $n$  次；而当  $n$  为偶数时，代数精度至少为  $n+1$  次



### 6.3 高斯公式

前面的方法都基于等分节点，而高斯公式则基于非等分节点

**定义 16.** 若对于节点  $x_i \in [a, b]$  及求积系数  $\omega_i$ ，求积公式

$$I[f] = \int_a^b \rho(x) f(x) dx \approx \sum_{i=0}^n \omega_i f(x_i)$$

的代数精度为  $2n + 1$ ，则称节点  $x_i$  为高斯点， $\omega_i$  为高斯系数

**定理 6.**  $x_i$  是求积公式的高斯点的充分必要条件是，多项式  $\Pi(x) = \prod_{i=0}^n (x - x_i)$  与任意次数不超过  $n$  的多项式  $q(x)$  关于权函数  $\rho(x)$  正交，即

$$\int_a^b \rho(x) \Pi(x) q(x) dx = 0$$

几种常见的高斯公式如下

1. 高斯-勒让德(Legendre)多项式:  $\rho \equiv 1, [a, b] = [-1, 1]$
2. 高斯-切比雪夫公式:  $\rho(x) = \frac{1}{\sqrt{1-x^2}}, [a, b] = [-1, 1]$
3. 高斯-拉盖尔公式:  $\rho(x) = e^{-x}, [a, b] = [0, \infty)$
4. 高斯-埃尔米特(Hermite)公式:  $\rho(x) = e^{-x^2}, (a, b) = (-\infty, +\infty)$

第一步都先变换积分区间，然后查表代入  $x_i$  和  $\omega_i$

### 6.4 多重积分

记  $\omega_i, \omega_j$  分别为  $x, y$  方向的求积系数

$$I = \iint_O \text{mega} f(x, y) dx dy \approx \sum_{i=0}^n \sum_{j=0}^m \omega_{ij} f(x_i, y_j)$$

### 6.5 数值微分

利用拉格朗日函数可以做线性、二次和高次插值，得到微分近似公式

两点公式: 向前差商公式和向后差商公式，误差均为  $O(h)$ ，精度都一阶

$$\begin{cases} f'(x_0) = \frac{f(x_1)-f(x_0)}{h} - \frac{h}{2} f''(\xi), \xi \in (x_0, x_1) \\ f'(x_1) = \frac{f(x_1)-f(x_0)}{h} - \frac{h}{2} f''(\xi), \xi \in (x_0, x_1) \end{cases}$$

三点求导公式: 其中第二条为中心差商公式，精度均为二阶

$$\begin{cases} f'(x_0) = \frac{1}{2h} [-3f(x_0) + 4f(x_1) - f(x_2)] + \frac{h^2}{3} f^{(3)}(\xi) \\ f'(x_1) = \frac{1}{2h} [-f(x_0) + f(x_2)] - \frac{h^2}{6} f^{(3)}(\xi) \\ f'(x_2) = \frac{1}{2h} [f(x_0) - 4f(x_1) + 3f(x_2)] + \frac{h^2}{3} f^{(3)}(\xi) \end{cases}$$

## 7 非线性方程求根

对于下式，分别取 $r = 1, 2, 3$ 时为线性收敛、平方收敛和立方收敛，当 $r \in (1, 2)$ 时为超线性收敛

$$\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^r} = C, C > 0$$

- 二分法：如果指定精度为 $\varepsilon$ ，则最多需要迭代步数为

$$k = \lceil \log_2 \frac{b-a}{\varepsilon} \rceil$$

- 不动点法： $x^* = \phi(x^*)$

**定理 7.** 设一元函数 $\phi(x)$ 在包含区间 $[a, b]$ 的开区间上一阶连续可导，且

- $\forall x \in [a, b] : \phi(x) \in [a, b]$
- $\exists L \in [0, 1), \forall x \in [a, b] : |\phi'(x)| \leq L$

则有下列结论成立：

- $\forall x_0 \in [a, b]$ ，由 $x_{k+1} = \phi(x_k)$ 产生的迭代序列 $\{x_k\}$ 必然收敛于函数 $\phi(x)$ 在区间 $[a, b]$ 上的唯一不动点，即 $x^* = \phi(x^*)$
- 序列 $\{x_k\}$ 的收敛速度估计

$$|x_k - x^*| \leq \frac{1}{1-L} |x_{k+1} - x_k|$$

和

$$|x_k - x^*| \leq \frac{L^k}{1-L} |x_1 - x_0|$$

迭代加速：利用导数估计 $\phi'(\xi) \approx L$ ，得到

$$\phi(\bar{x}) = \frac{\phi(x) - Lx}{1-L}$$

为新的不动点函数

牛顿法：下式的不动点迭代方法

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)}$$

牛顿下山法：

$$x_{k+1}(\lambda) = x_k - \lambda \frac{f(x_k)}{f'(x_k)}$$

割线法：

$$x_{k+1} = x_k - f(x_k) \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}$$