

概率论与数理统计笔记整理V2.0

陈鸿峥

2019.01 *

目录

1	基本概念	2
1.1	事件与概率	2
1.2	条件概率	2
2	随机变量及其分布	3
2.1	基本概念	3
2.2	随机变量的函数的分布	5
2.3	常见的离散分布	5
2.4	常见的连续分布	7
3	多维随机变量及其分布	9
3.1	边缘分布	9
3.2	随机变量的函数的分布	10
3.3	数字特征	11
4	大数定律	12
4.1	大数定律	12
4.2	中心极限定理	13
5	参数估计	14
5.1	样本与抽样	14
5.2	抽样分布	14
5.3	参数估计	16
5.4	可视化	17
6	假设检验	17
6.1	假设检验	17
6.2	分布拟合检验	18

*Build 20190103

7 方差分析及回归分析	18
7.1 单因素方差分析	18
7.2 一元线性回归	19

1 基本概念

1.1 事件与概率

命题 1. 事件的基本运算

1. 分配律: $A \cup (B \cap C) = (A \cup B) \cap (A \cup C)$, $A \cap (B \cup C) = (A \cap B) \cup (A \cap C)$
2. 德摩根律: $\overline{A \cup B} = \overline{A} \cap \overline{B}$, $\overline{A \cap B} = \overline{A} \cup \overline{B}$

注意概率是对一个集合的函数, 有如下定义.

定义 1 (概率). 随机试验 E 的所有可能结果构成 E 的样本空间 Ω , Ω 的子集称为事件, Ω 的幂集构成 E 的事件空间 \mathcal{F} , 记概率函数 $\mathbb{P}(\cdot) : \mathcal{F} \mapsto \mathbb{R}$ 满足:

1. 非负性: $\mathbb{P}(A) \geq 0, \forall A \in \mathcal{F}$
2. 规范性: $\mathbb{P}(\Omega) = 1$
3. 可列可加性: A_1, A_2, \dots 为两两不相容的事件, $\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$

由定义可得概率一些基本性质:

1. $\mathbb{P}(\emptyset) = 0, \mathbb{P}(A) \leq 1$
2. 有限可加性: A_1, A_2, \dots 两两不相容, $\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n \mathbb{P}(A_i)$
3. 若 $A \subset B$, 则 $\mathbb{P}(B - A) = \mathbb{P}(B) - \mathbb{P}(A)$, $\mathbb{P}(B) \geq \mathbb{P}(A)$
4. 逆事件概率: $\mathbb{P}(\overline{A}) = 1 - \mathbb{P}(A)$
5. 容斥原理:

$$\mathbb{P}\left(\bigcup_{i=1}^n A_i\right) = \sum_{k=1}^n \left((-1)^{k-1} \sum_{\substack{I \subset \{1, \dots, n\} \\ |I|=k}} \mathbb{P}\left(\bigcap_{i \in I} A_i\right) \right)$$

本章的重点在于组合计数, 正确计算事件数目并套用相应的公式即可.

1.2 条件概率

定义 2 (条件概率). 设 A, B 为两个事件, 且 $\mathbb{P}(A) > 0$, 则称

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(AB)}{\mathbb{P}(A)}$$

为在事件 A 发生的条件下事件 B 发生的条件概率

进而有

$$\mathbb{P}(B | A) \mathbb{P}(A) = \mathbb{P}(AB) = \mathbb{P}(A | B) \mathbb{P}(B)$$

定理 1 (乘法公式). 设 A_1, A_2, \dots, A_n 为 n 个事件, $n \geq 2$, 且 $\mathbb{P}(A_1 A_2 \cdots A_{n-1}) > 0$, 则

$$\mathbb{P}(A_1 A_2 \cdots A_{n-1}) = \mathbb{P}(A_n | A_1 A_2 \cdots A_{n-1}) \mathbb{P}(A_{n-1} | A_1 A_2 \cdots A_{n-2}) \cdots \mathbb{P}(A_2 | A_1) \mathbb{P}(A_1)$$

定义 3 (划分). 两两交为空, 所有并为全集

定理 2 (全概率公式). 设试验 E 的样本空间为 S , A 为 E 的事件, B_1, B_2, \dots, B_n 为 S 的一个划分, 且 $\mathbb{P}(B_i) > 0$, 则

$$\mathbb{P}(A) = \mathbb{P}(AB_1) + \mathbb{P}(AB_2) + \cdots + \mathbb{P}(AB_n) = \mathbb{P}(A | B_1) \mathbb{P}(B_1) + \mathbb{P}(A | B_2) + \cdots + \mathbb{P}(A | B_n) \mathbb{P}(B_n)$$

定理 3 (贝叶斯(Bayes)公式). 设试验 E 的样本空间为 S , A 为 E 的事件, B_1, B_2, \dots, B_n 为 S 的一个划分, 且 $\mathbb{P}(A) > 0, \mathbb{P}(B_i) > 0$, 则

$$\mathbb{P}(B_i | A) = \frac{\mathbb{P}(B_i A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A | B_i) \mathbb{P}(B_i)}{\sum_{i=1}^n \mathbb{P}(A | B_i) \mathbb{P}(B_i)}$$

特别地, 当 $n = 2$ 时有

$$\mathbb{P}(B | A) = \frac{\mathbb{P}(A | B) \mathbb{P}(B)}{\mathbb{P}(A | B) \mathbb{P}(B) + \mathbb{P}(A | \bar{B}) \mathbb{P}(\bar{B})}$$

注意贝叶斯公式是用先验概率推后验概率.

在计算条件概率时一定要注意前提条件是什么, 并将题设进行转换.

定义 4 (独立性). 对于事件 A_1, \dots, A_n ,

- 若 $\mathbb{P}(A_i \cap A_j) = \mathbb{P}(A_i) \mathbb{P}(A_j), \forall i, j$, 则称 $\{A_1, \dots, A_n\}$ 两两(pairwise)独立
- 若 $\mathbb{P}\left(\bigcap_{j \in I} A_j\right) = \prod_{j \in I} \mathbb{P}(A_j), \forall I \in 2^{[n]}$, 其中 $2^{[n]}$ 为 $\{A_i\}_{i=1}^n$ 的所有子集, 则称 $\{A_1, \dots, A_n\}$ 相互(mutually)独立

区分以下两个概念

1. A, B 对立(exclusive)/不相容 $\Leftrightarrow \mathbb{P}(A \cap B) = 0$, 即不相交(disjoint)
2. A, B 独立(independent) $\Leftrightarrow \mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$, 即不相关(unrelated)

2 随机变量及其分布

2.1 基本概念

定义 5. 对于离散随机变量 X , 其概率质量函数(PMF)为 $f_X(k) = \mathbb{P}(X = k)$, 分布函数为 $F_X(x) = \mathbb{P}(X \leq x) = \sum_{k \leq x} f_X(k)$

定义 6. 对于连续随机变量 X , 其累积密度函数 (CDF) 为 $F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^x f_X(z) \, dz$. 其中 $f_X(x)$ 为 X 的概率密度函数 (PDF), 也即 $f_X(x) = \frac{dF_X(x)}{dx}$. 一定要注意, $f_X(x) \neq \mathbb{P}(X = x)$!

注意积分区间! 注意要写变量范围!

定义 7 (期望). 设 Y 是随机变量 X 的连续函数 $Y = g(X)$

$$\begin{aligned} \mathbb{E}(X) &= \sum_x x f_X(x) & \mathbb{E}(g(X)) &= \sum_x g(x) f_X(x) \\ \mathbb{E}(X) &= \int_{-\infty}^{+\infty} x f_X(x) \, dx & \mathbb{E}(g(X)) &= \int_{-\infty}^{+\infty} g(x) f_X(x) \, dx \end{aligned}$$

期望具有线性性, 即

$$\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y), \mathbb{E}(cX) = c\mathbb{E}(X)$$

若 X, Y 相互独立, 则

$$\mathbb{E}(XY) = \mathbb{E}(X) \mathbb{E}(Y)$$

但反过来不能推相互独立

定义 8 (方差).

$$\begin{aligned} \mathbb{D}(X) = \text{Var}(X) &= \sigma^2 = \mathbb{E}((X - \mathbb{E}(X))^2) = \mathbb{E}(X^2) - \mathbb{E}(X)^2 \geq 0 \\ &= \sum_{k=1}^{\infty} [x_k - \mathbb{E}(X)]^2 p_k \\ &= \int_{-\infty}^{\infty} [X - \mathbb{E}(X)]^2 f(x) \, dx \end{aligned}$$

标准差或均方差则是 σ

一般通过求 $\mathbb{E}(X)$ 和 $\mathbb{E}(X^2)$ 来求方差

由方差定义和期望的线性性有

$$\mathbb{D}(aX + b) = a^2 \mathbb{D}(X)$$

注意方差并不是线性的

$$\begin{aligned} \mathbb{D}(X + Y) &= \mathbb{E}((X + Y)^2) - (\mathbb{E}(X) + \mathbb{E}(Y))^2 \\ &= \mathbb{E}(X^2) - \mathbb{E}(X)^2 + \mathbb{E}(Y^2) - \mathbb{E}(Y)^2 + 2(\mathbb{E}(XY) - \mathbb{E}(X) \mathbb{E}(Y)) \\ &= \mathbb{D}(X) + \mathbb{D}(Y) + 2\text{Cov}(X, Y) \end{aligned}$$

定义 9 (上 α 分位点).

$$\mathbb{P}(X > z_\alpha) = \alpha, \alpha \in (0, 1)$$

2.2 随机变量的函数的分布

定理 4. 若 X 为连续型随机变量, g 为单调递增函数 (反函数存在且单调递增), 且 $Y = g(X)$, 那么

$$f_Y(y) = f_X(g^{-1}(y))(g^{-1})'(y)$$

特别地, 对于 $Y = X^2$

$$f_Y(y) = \frac{1}{2\sqrt{y}}[f_X(\sqrt{y}) + f_X(-\sqrt{y})], y > 0$$

一般情况则先求 Y 的概率分布函数 $F_Y(y)$, 然后对 $F_Y(y)$ 求导

2.3 常见的离散分布

1. 伯努利/两点/0-1分布 **Bernoulli(p)** (二项分布的特殊情形)

$$f_X(k) = \begin{cases} 1-p & k=0 \\ p & k=1 \end{cases}$$

$$\mathbb{E}(X) = p$$

$$\mathbb{D}(X) = p(1-p)$$

2. 二项分布 **Binomial(n,p)**

$$f_X(k) = \binom{n}{k} p^k (1-p)^{n-k}, 0 \leq k \leq n$$

$$\mathbb{E}(X) = n \cdot p$$

$$\mathbb{D}(X) = np(1-p)$$

e.g. 扔 n 次硬币扔到 k 次正面 (做实验 n 次, 记录成功的次数)

3. 几何分布 **Geometric(p)** (负二项分布的特殊情形)

$$f_X(k) = (1-p)^k \cdot p, k \geq 0$$

$$\mathbb{E}(X) = \frac{1-p}{p}$$

e.g. 扔 k 次反面直至扔到正面 (做实验直到你成功, 记录失败的次数)

4. 负二项分布 **NegativeBinomial(r,p)**

$$f_X(k) = \binom{k+r-1}{r-1} p^r (1-p)^k, k \geq 0$$

$$\mathbb{E}(X) = r \cdot \frac{1-p}{p}$$

$$\begin{aligned}
\mathbb{E}(X) &= \sum_{k=0}^{\infty} \binom{k+r-1}{r-1} p^r (1-p)^k \\
&= \sum_{k=0}^{\infty} r \left(\binom{k+r}{r} - \binom{k+r-1}{r-1} \right) p^r (1-p)^k \quad k \binom{n}{k} = n \binom{n-1}{k-1} \text{的变形} \\
&= r p^r \left(\sum_{k=0}^{\infty} \binom{k+r}{r} (1-p)^k - \sum_{k=0}^{\infty} \binom{k+r-1}{r-1} (1-p)^k \right) \\
&= r p^r \left(\sum_{k=0}^{\infty} \binom{k+r}{k} (1-p)^k - \sum_{k=0}^{\infty} \binom{k+r-1}{k} (1-p)^k \right) \\
&= r p^r \left(\sum_{k=0}^{\infty} (-1)^k \binom{-r-1}{k} (1-p)^k - \sum_{k=0}^{\infty} (-1)^k \binom{-r}{k} (1-p)^k \right)
\end{aligned}$$

这步是关键，将变化的 $(k+r)$ 转成 $(-r-1)$ ，使得可以正常使用二项式定理

$$\begin{aligned}
&= r p^r \left(\sum_{k=0}^{\infty} \binom{-r-1}{k} 1^{-r-1-k} (p-1)^k - \sum_{k=0}^{\infty} \binom{-r}{k} 1^{-r-k} (p-1)^k \right) \\
&= r p^r \left((1 + (p-1))^{-r-1} - (1 + (p-1))^{-r} \right) \quad \text{牛顿二项式} \\
&= r(p^{-1} - 1) \\
&= r \frac{1-p}{p}
\end{aligned}$$

补充证明：

$$\begin{aligned}
\binom{k+r}{k} &= \frac{(k+r)(k+r-1)\cdots(r+1)}{k(k-1)\cdots 1} \\
&= (-1)^k \frac{(-k-r)(-k-r-1)\cdots(-r-1)}{k(k-1)\cdots 1} \\
&= (-1)^k \frac{(-r-1)(-r-2)\cdots(-r-1-k+1)}{k(k-1)\cdots 1} \quad \text{把分子各项逆过来} \\
&= (-1)^k \binom{-r-1}{k}
\end{aligned}$$

e.g. 扔 k 次反面直到有 r 个正面（做实验直到你获得 r 次成功，记录失败次数）

5. 超几何分布 **HyperGeometric(N,n,M)**

$$\begin{aligned}
f_X(k) &= \frac{\binom{M}{k} \cdot \binom{N-M}{n-k}}{\binom{N}{n}} \\
\mathbb{E}(X) &= n \frac{M}{N}
\end{aligned}$$

e.g. M 个产品中有 N 个次品，检查 n 次得到 k 个次品

6. 泊松分布 **Poisson(λ)**, $\lambda > 0$

$$\begin{aligned}
f_X(k) &= \frac{\lambda^k}{k!} e^{-\lambda}, \quad \lambda > 0, k \geq 0 \\
\mathbb{E}(X) &= \lambda
\end{aligned}$$

$X \sim B(n, p)$, 若 $p = \frac{\lambda}{n}$, 且 n 非常大, 则

$$\begin{aligned}\mathbb{P}(X = k) &= \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \\ &= \frac{n(n-1) \cdots (n-k+1)}{k!} \frac{\lambda^k}{n^k} \left(1 + \frac{-\lambda}{n}\right)^{n-k} \\ &\approx \frac{\lambda^k}{k!} e^{-\lambda}\end{aligned}$$

一般 $n \geq 20, p \leq 0.05$ 时, 即可用近似

$$\begin{aligned}\mathbb{E}(X) &= \sum_{k=0}^{\infty} k \frac{\lambda^k}{k!} e^{-\lambda} \\ &= \lambda e^{-\lambda} \sum_{k=1}^{\infty} \frac{\lambda^{k-1}}{(k-1)!} \\ &= \lambda e^{-\lambda} e^{\lambda} = \lambda\end{aligned}$$

注意泊松分布具有无记忆性(memoryless), 即

$$\mathbb{P}(X \geq a \mid X \geq b) = \mathbb{P}(X \geq a - b)$$

2.4 常见的连续分布

1. 均匀分布 **Uniform(a,b)**, $a < b$

$$\begin{aligned}f_X(x) &= \frac{1}{b-a}, \quad a \leq x \leq b \\ \mathbb{E}(X) &= \frac{a+b}{2} \\ \mathbb{D}(X) &= \frac{(b-a)^2}{12}\end{aligned}$$

2. 指数分布 **Exponential(θ)**, $\theta > 0$

$$\begin{aligned}f_X(x) &= \frac{1}{\theta} e^{-\frac{x}{\theta}}, \quad x > 0 \\ \mathbb{E}(X) &= \theta = \frac{1}{\lambda}\end{aligned}$$

与泊松分布类似, 同样具有无记忆性

3. 正态分布 **Normal(μ, σ^2)**

$$\begin{aligned}f_X(x) &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}} \\ \mathbb{E}(X) &= \mu\end{aligned}$$

标准正态分布 $N(0, 1)$

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2}$$

$$\Phi(x) = \int_{-\infty}^x \varphi(t) \, dt$$

$$\Phi(-x) = 1 - \Phi(x)$$

算平方

$$\begin{aligned} I^2 &= \left(\int_{-\infty}^{+\infty} e^{\frac{-x^2}{2}} \, dx \right)^2 \\ &= \int_{-\infty}^{+\infty} e^{\frac{-x^2}{2}} \, dx \int_{-\infty}^{+\infty} e^{\frac{-y^2}{2}} \, dy \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{\frac{-(x^2+y^2)}{2}} \, dx \, dy \\ &= \int_0^{2\pi} \int_0^{+\infty} r e^{\frac{-r^2}{2}} \, dr \, d\theta \end{aligned}$$

重积分极坐标变量代换 $dS = r \, dr \, d\theta$

$$\begin{aligned} &= - \int_0^{2\pi} \int_0^{+\infty} d e^{\frac{-r^2}{2}} \, d\theta \\ &= - \int_0^{2\pi} (0 - 1) \, d\theta \\ &= \int_0^{2\pi} 1 \, d\theta = 2\pi \end{aligned}$$

也即 **概率积分** $I = \sqrt{2\pi}$

若 $X \sim N(\mu, \sigma^2)$, 则 $Y = aX + b \sim N(a\mu + b, (a\sigma)^2)$, 特别地,

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

若 $X_i \sim N(\mu_i, \sigma_i^2)$ 相互独立, 则它们的和

$$Z = X_1 + X_2 + \cdots + X_n \sim N(\mu_1 + \mu_2 + \cdots + \mu_n, \sigma_1^2 + \sigma_2^2 + \cdots + \sigma_n^2)$$

若 $X \sim N(0, 1)$, 且 $Y = X^2$, 则

$$f_Y(y) = \frac{1}{\sqrt{2\pi}} y^{-1/2} e^{-y/2} \implies Y \sim \Gamma(\frac{1}{2}, 2)$$

4. 伽马分布 $\mathbf{Gamma}(\alpha, \beta) \equiv \Gamma(\alpha, \beta) \equiv \Gamma(k, \theta), k = \alpha, \theta = 1/\beta$

$$f_X(x; \alpha, \beta) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, x, \alpha, \beta > 0$$

$$f_X(x; k, \theta) = \frac{1}{\Gamma(k)\theta^k} x^{k-1} e^{-\frac{x}{\theta}}, x, k, \theta > 0$$

$$F(x; k, \theta) = \int_0^x f(u; k, \theta) du = \frac{\gamma(k, \frac{x}{\theta})}{\Gamma(k)}$$

$$\mathbb{E}(X) = \frac{\alpha}{\beta} = k\theta$$

$$\mathbb{D}(X) = \frac{\alpha}{\beta^2} = k\theta^2$$

若 $X_i \sim \Gamma(k_i, \theta)$ 相互独立, 则它们的和

$$Z = \sum_{i=1}^N X_i \sim \Gamma\left(\sum_{i=1}^n k_i, \theta\right)$$

注: 通过 $B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$ 证明

3 多维随机变量及其分布

3.1 边缘分布

定义 10. 二维随机变量 (X, Y) 的分布函数/联合 (*joint*) 分布函数定义如下

$$F(x, y) = \mathbb{P}(X \leq x, Y \leq y) = \sum_{x_i \leq x} \sum_{y_i \leq y} p_{ij} = \int_{-\infty}^y \int_{-\infty}^x f(u, v) du dv$$

其中, $f(x, y)$ 为 X, Y 的联合密度函数

进而, 对于离散型随机变量有,

$$\mathbb{P}(x_1 < X \leq x_2, y_1 < Y \leq y_2) = F(x_2, y_2) - F(x_2, y_1) + F(x_1, y_1) - F(x_1, y_2)$$

连续型随机变量有,

$$\mathbb{P}((X, Y) \in G) = \iint_G f(x, y) dx dy$$

若 $f(x, y)$ 在 (x, y) 连续, 则 $\frac{\partial^2 F(x, y)}{\partial x \partial y} = f(x, y)$

定义 11 (边缘(marginal)分布).

$$\begin{aligned}
 F_X(x) &= \mathbb{P}(X \leq x, Y < \infty) = \lim_{y \rightarrow \infty} F(x, y) = F(x, \infty) \\
 &= \int_{-\infty}^x \left[\int_{-\infty}^{\infty} f(x, y) \, dy \right] \, dx \\
 &= \int_{-\infty}^x f_X(x) \, dx \\
 f_X(x) &= \int_{-\infty}^{\infty} f(x, y) \, dy
 \end{aligned}$$

注意积分区间不一定是从负无穷到正无穷，而是概率有(0,1)之间值的区域
对于二元随机变量的概率密度和概率分布函数有如下关系

$$\begin{array}{ccccc}
 f(x, y) & \xrightarrow{\text{Int } y} & f_X(x) & \xrightarrow{\text{Int } x} & F_X(x) \\
 \downarrow \text{Int } x & & & \searrow \text{Int } x \, y & \uparrow y \rightarrow \infty \\
 f_Y(y) & & & & \\
 \downarrow \text{Int } y & & & & \\
 F_Y(y) & \xleftarrow{x \rightarrow \infty} & F(x, y) & &
 \end{array}$$

定义 12 (条件概率密度与分布函数).

$$\begin{aligned}
 f_{X|Y}(x | y) &= \frac{f(x, y)}{f_Y(y)} \\
 F_{X|Y}(x | y) &= \mathbb{P}(X \leq x | Y = y) = \int_{-\infty}^x \frac{f(x, y)}{f_Y(y)} \, dx
 \end{aligned}$$

定义 13 (相互独立).

$$\begin{aligned}
 F(x, y) &= F_X(x)F_Y(y) \\
 f(x, y) &= f_X(x)f_Y(y)
 \end{aligned}$$

3.2 随机变量的函数的分布

均通过求 $F_Z(z) = \mathbb{P}(z \leq Z)$ 交换积分次序得到

3.2.1 $Z = X + Y$

$$f_{X+Y}(z) = \int_{-\infty}^{\infty} f(z - y, y) \, dy = \int_{-\infty}^{\infty} f(x, z - x) \, dx$$

若X和Y相互独立，则有卷积公式

$$f_X * f_Y = \int_{-\infty}^{\infty} f_X(z - y, y) f_Y(y) \, dy$$

3.2.2 $Z = X/Y$

$$f_{Y/X}(z) = \int_{-\infty}^{\infty} |x| f(x, xz) \, dx$$

3.2.3 $Z = XY$

$$f_{XY}(z) = \int_{-\infty}^{+\infty} \frac{1}{|x|} f(x, \frac{z}{x}) \, dx$$

3.2.4 $Z = \max\{X_1, \dots, X_n\}$

$$F_{\max}(z) = F_{X_1}(z) F_{X_2}(z) \cdots F_{X_n}(z)$$

3.2.5 $Z = \min\{X_1, \dots, X_n\}$

$$F_{\min}(z) = 1 - [1 - F_{X_1}(z)][1 - F_{X_2}(z)] \cdots [1 - F_{X_n}(z)]$$

3.2.6 函数分布

若 Z 是随机变量 X, Y 的连续函数 $Z = g(X, Y)$, 则

$$\mathbb{E}(Z) = \mathbb{E}(g(x, y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} g(x, y) f(x, y) \, dx \, dy$$

根据这条式子, 方差、协方差等等均可以直接通过积分计算

3.3 数字特征

定义 14 (协方差).

$$\text{Cov}(X, Y) = \mathbb{E}([X - \mathbb{E}(X)][Y - \mathbb{E}(Y)]) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$$

协方差的性质:

$$\text{Cov}(aX, bY) = ab\text{Cov}(X, Y)$$

$$\text{Cov}(X_1 + X_2, Y) = \text{Cov}(X_1, Y) + \text{Cov}(X_2, Y)$$

定义 15 (相关系数). 用来表征 X, Y 线性关系的量

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sqrt{\mathbb{D}(X)}\sqrt{\mathbb{D}(Y)}}$$

$|\rho_{XY}|$ 较大, 均方误差小, 线性关系强; $\rho_{XY} \leq 1$, 取等的充要条件为 $\exists a, b$ 使得 $\mathbb{P}(Y = a + bX) = 1$

相关性与独立性没有必然联系：相关性是对线性关系来说的，而独立性是对一般关系来说的

定义 16 (矩). 设 X, Y 为随机变量, 若 $\mathbb{E}(X^k)$ 存在, 则称它为 X 的 k 阶(原点)矩, 称 $\mathbb{E}([X - \mathbb{E}(X)]^k)$ 为 k 阶中心矩, 称 $\mathbb{E}(X^k Y^l)$ 为 $k + l$ 阶混合矩, 称 $\mathbb{E}([X - \mathbb{E}(X)]^k [Y - \mathbb{E}(Y)]^l)$ 为 $k + l$ 阶混合中心矩

定义 17 (协方差矩阵). 设 n 维随机变量 (X_1, X_2, \dots, X_n) 的二阶混合中心矩

$$c_{ij} = \text{Cov}(X_i, X_j) = \mathbb{E}([X_i - \mathbb{E}(X_i)][X_j - \mathbb{E}(X_j)])$$

都存在, 则协方差矩阵

$$\mathbf{C} = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1n} \\ c_{21} & c_{22} & \cdots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \cdots & c_{nn} \end{bmatrix}$$

又 $c_{ij} = c_{ji}$, 故上述矩阵是个对称矩阵

定理 5. 若 X_1, \dots, X_n 独立, 则

$$\begin{aligned} \mathbb{E}\left(\prod_{i=1}^n X_i\right) &= \prod_{i=1}^n \mathbb{E}(X_i) \\ \mathbb{D}\left(\prod_{i=1}^n X_i\right) &= \sum_{i=1}^n \mathbb{D}(X_i) \\ \text{Cov}(X_i, X_j) &= 0, i \neq j \end{aligned}$$

$Y = g(X)$ 的随机变量分布一般通过求分布函数后求导得到其概率密度函数

4 大数定律

4.1 大数定律

定理 6 (切比雪夫(Chebyshev)不等式). 设随机变量 X 的数学期望 $\mathbb{E}(X) = \mu$, 方差 $\mathbb{D}(X) = \sigma^2$

$$\mathbb{P}(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

或

$$\mathbb{P}(|X - \mu| < \varepsilon) \geq \frac{\sigma^2}{\varepsilon^2}$$

定理 7 (弱大数定律(辛钦)). 若 X_1, X_2, \dots 为独立随机变量且同等分布(iid), $\mathbb{E}(X_i) = \mu, \mathbb{D}(X_i) = \sigma^2$, 则

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| \geq \varepsilon\right) = 0, \forall \varepsilon > 0$$

或

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| < \varepsilon\right) = 1, \forall \varepsilon > 0$$

可记成 $\bar{X} \xrightarrow{P} \mu$

定理 8 (实际推断原理). 概率很小的事件在一次试验中实际上几乎是不发生的

定理 9 (强大数定律). 若 X_1, X_2, \dots 为独立随机变量且同等分布, $\mathbb{E}(X_i) = \mu, \mathbb{D}(X_i) = \sigma^2$, 则

$$\mathbb{P}\left(\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{i=1}^n X_i = \mu\right) = 1$$

4.2 中心极限定理

定义 18 (标准化变量). 若随机变量 X 的均值为 μ , 方差为 σ^2 , 则 X 的标准化变量为

$$Z = \frac{X - \mu}{\sigma}$$

有 $\mathbb{E}(Z) = 0, \mathbb{D}(Z) = 1$

定理 10 (独立同分布的中心极限定理). 若 X_1, X_2, \dots 为独立随机变量且同等分布, 且 $\mathbb{E}(X_k) = \mu, \mathbb{D}(X_k) = \sigma^2 > 0$, 则随机变量之和的标准化变量

$$Y_n = \frac{\sum_{k=1}^n X_k - \mathbb{E}(\sum_{k=1}^n X_k)}{\sqrt{\mathbb{D}(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n\sigma^2}}$$

的分布函数 $F_n(x)$ 对任意 x 满足

$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} \mathbb{P}(Y_n \leq x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt = \Phi(x)$$

也即, 近似地

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

努力将原变量转化为标准化变量形式, 以使用标准正态分布解题

推论 (棣莫弗-拉普拉斯(De Moivre-Laplace)定理). 设随机变量 η_1, η_2, \dots 服从参数为 $n, p (0 < p < 1)$ 的二项分布, 则对于任意 x , 有

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{\eta_n - np}{\sqrt{np(1-p)}} \leq x\right) = \Phi(x)$$

定理 11 (李雅普诺夫(Lyapunov)定理). 若 X_1, X_2, \dots 为独立随机变量且同等分布, 且 $\mathbb{E}(X_k) = \mu, \mathbb{D}(X_k) = \sigma^2 > 0$, 记 $B_n^2 = \sum_{k=1}^n \sigma_k^2$ 若存在 $\delta > 0$, 使得

$$\lim_{n \rightarrow \infty} \frac{1}{B_n^{2+\delta}} \sum_{k=1}^n \mathbb{E}(|X_k - \mu|^{2+\delta}) = 0$$

则随机变量之和的标准化变量

$$Z_n = \frac{\sum_{k=1}^n X_k - \mathbb{E}(\sum_{k=1}^n X_k)}{\sqrt{\mathbb{D}(\sum_{k=1}^n X_k)}} = \frac{\sum_{k=1}^n X_k - \sum_{k=1}^n \mu_k}{B_n}$$

5 参数估计

5.1 样本与抽样

定义 19 (简单随机样本). 在相同的条件下对总体 X 进行 n 次重复的、独立的观察, 将 n 次观察结果按照实验的次序记为 X_1, X_2, \dots, X_n , 则这些变量都**相互独立**且与 X 有**相同分布**

5.2 抽样分布

5.2.1 基本概念

定义 20 (统计量). 样本平均

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

样本方差 (期望估计量 $\mathbb{E}((S^2) = \sigma^2)$)

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)$$

样本 k 阶中心矩

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

经验分布函数

$$F_n(x) = \frac{1}{n} S(x)$$

其中 $S(x)$ 是 X_1, X_2, \dots, X_n 中不大于 x 的随机变量的个数

定理 12. 设总体 X (不管服从什么分布), 均值为 μ , 方差为 σ^2 , X_1, X_2, \dots, X_n 为来自 X 的一个样本, \bar{X} 为样本均值, S^2 为样本方差, 则

$$\mathbb{E}(\bar{X}) = \mu, \mathbb{D}(\bar{X}) = \sigma^2/n$$

定理 13. 设 X_1, X_2, \dots, X_n 是来自正态总体 $N(\mu, \sigma^2)$ 的样本, 则

1. $\bar{X} \sim N(\mu, \sigma^2/n)$ (注意 $\mathbb{D}(X) = (\sigma/\sqrt{n})^2$)
2. $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$
3. \bar{X} 与 S^2 相互独立
4. $\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$

定理 14. 对于两个正态总体的样本 X 和 Y 有

1. $\frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1-1, n_2-1)$

2. 当 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 时

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$$

其中,

$$S_w^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}, \quad S_w = \sqrt{S_w^2}$$

5.2.2 常见的抽样分布

1. χ^2 分布

设 X_1, X_2, \dots, X_n 是来自总体 $N(0, 1)$ 的样本, 则统计量

$$\chi^2 = X_1^2 + X_2^2 + \dots + X_n^2 \sim \Gamma\left(\frac{n}{2}, 2\right)$$

服从自由度为 n 的 χ^2 分布, 记为 $\chi^2 \sim \chi^2(n)$

$$f(x) = \frac{1}{2^{n/2} \Gamma(n/2)} x^{n/2-1} e^{-x/2}, \quad x > 0$$

$$\mathbb{E}(\chi^2) = n$$

$$\mathbb{D}(\chi^2) = 2n$$

χ^2 具有可加性, 因 Gamma 分布有可加性

$$\chi_1^2(n_1) + \chi_2^2(n_2) \sim \chi^2(n_1 + n_2)$$

2. t 分布/Student 分布

设 $X \sim N(0, 1)$, $Y \sim \chi^2(n)$, 且 X, Y 相互独立, 则

$$t = \frac{X}{\sqrt{Y/n}}$$

服从自由度为 n 的 t 分布, 记为 $t \sim t(n)$

$$h(t) = \frac{\Gamma[(n+1)/2]}{\sqrt{\pi n} \Gamma(n/2)} \left(1 + \frac{t^2}{n}\right)^{-(n+1)/2}, \quad t \in (-\infty, +\infty)$$

3. F 分布

设 $U \sim \chi^2(n_1)$, $Y \sim \chi^2(n_2)$, 且 U, V 相互独立, 则

$$F = \frac{U/n_1}{V/n_2}$$

服从自由度 (n_1, n_2) 的 F 分布, 记为 $F \sim F(n_1, n_2)$

$$\psi(x) = \frac{\Gamma[(n_1 + n_2)/2](n_1/n_2)^{n_1/2} x^{(n_1/2)-1}}{\Gamma(n_1/2)\Gamma(n_2/2)[1 + (n_1 x/n_2)]^{(n_1+n_2)/2}}, x > 0$$

5.3 参数估计

5.3.1 估计量

定义 21 (估计). X_1, X_2, \dots, X_n 为独立随机变量, 从有参数 $\mu, \sigma, \theta, \dots$ 的分布 f 中得到, 对参数 θ 的估计是函数 $T(X_1, \dots, X_n)$, 称 T 是期望(*expected*)估计, 若

$$\mathbb{E}(T(X_1, \dots, X_n)) = \theta$$

相合(*probable*)的估计, 若

$$\mathbb{P}(|T(X_1, \dots, X_n) - \theta| > \varepsilon) \rightarrow 0, n \rightarrow \infty$$

$$\begin{aligned} \mathbb{E}(S^2) &= \frac{1}{n-1} \mathbb{E}\left(\sum_{i=1}^n (X_i - \bar{X})^2\right) \\ &= \frac{1}{n-1} \mathbb{E}\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right) \\ &= \frac{1}{n-1} \sum_{i=1}^n \mathbb{E}(X_i^2) - n\mathbb{E}(\bar{X}^2) \quad \text{由 } \sigma^2 = \mathbb{E}(X^2) - \mu^2 \\ &= \frac{1}{n-1} n(\sigma^2 + \mu^2) - n\left(\frac{\sigma^2}{n} + \mu^2\right) \quad \text{由 } \mathbb{D}(\bar{X}) = \frac{\sigma^2}{n} = \mathbb{E}(\bar{X}^2) - \mu^2 \\ &= \sigma^2 = \mathbb{D}(X) \end{aligned}$$

5.3.2 矩估计

设 X 为随机变量, 概率密度为 $f(x; \theta_1, \theta_2, \dots, \theta_n)$, 则 X 的前 k 阶矩

$$\mu_l(\theta_1, \theta_2, \dots, \theta_k) = \int_{-\infty}^{\infty} x^l f(x; \theta_1, \theta_2, \dots, \theta_k) dx, l = 1, 2, \dots, k$$

k 个方程组便可解得 k 个估计量 $\hat{\theta}_l$

5.3.3 最大似然估计法

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta), \theta \in \Theta$$

5.3.4 区间估计

定义 22 (置信区间).

$$\mathbb{P}(\underline{\theta} < \theta < \bar{\theta}) \geq 1 - \alpha$$

正态总体的区间估计

待估参数	其他参数	枢轴量	置信区间
μ	σ^2 已知	$Z = \frac{X - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$	$\left(\bar{X} \pm \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right)$
μ	σ^2 未知	$t = \frac{X - \mu}{S/\sqrt{n}} \sim t(n-1)$	$\left(\bar{X} \pm \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right)$
σ^2	μ 未知	$\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$	$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right)$
$\mu_1 - \mu_2$	σ_1^2, σ_2^2 已知	$Z = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \sim N(0, 1)$	$\left(\bar{X} - \bar{Y} \pm z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right)$
$\mu_1 - \mu_2$	$\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知	$t = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_w \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2)$	$\left(\bar{X} - \bar{Y} \pm t_{\alpha/2}(n_1 + n_2 - 2) S_w \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right)$
$\frac{\sigma_1^2}{\sigma_2^2}$	μ_1, μ_2 未知	$F = \frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$	$\left(\frac{S_1^2}{S_2^2} \frac{1}{F_{\alpha/2}(n_1 - 1, n_2 - 1)}, \frac{S_1^2}{S_2^2} \frac{1}{F_{1-\alpha/2}(n_1 - 1, n_2 - 1)} \right)$

5.4 可视化

1. 直方图: 矩形宽度 $\frac{f_i}{n} / \Delta$, Δ 为组距
2. 箱线图: 最小值min, 第一四分位数 Q_1 , 中位数 M , 第三四分位数 Q_2 , 最大值max

$$q \text{分位数} \quad x_p = \begin{cases} x_{[np]+1} & np \notin \mathbb{Z} \\ \frac{1}{2}[x_{np} + x_{np+1}] & np \in \mathbb{Z} \end{cases}$$

6 假设检验

6.1 假设检验

定义 23 (显著性检验). 在显著性水平 α 下, 检验假设

$$H_0 : \mu = \mu_0, H_1 : \mu \neq \mu_0$$

其中 H_0 称为原假设或零假设, H_1 称为备择假设

正态总体的假设检验与区间估计类似

原假设 H_0	检验统计量	拒绝域
$\mu \leq \mu_0$ $\mu \geq \mu_0$ $\mu = \mu_0$ $(\sigma^2 \text{已知})$	$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}}$	$z \geq z_\alpha$ $z \leq -z_\alpha$ $ z \geq z_{\alpha/2}$
$\mu \leq \mu_0$ $\mu \geq \mu_0$ $\mu = \mu_0$ $(\sigma^2 \text{未知})$	$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}}$	$t \geq t_\alpha(n-1)$ $t \leq -t_\alpha(n-1)$ $ t \geq t_{\alpha/2}(n-1)$

成对数据的假设检验即作差，检验均值是否为0

定义 24 (p值). 假设检验问题的p值(probability value)是由检验统计量的样本观察值得出的原假设可被拒绝的最小显著性水平

6.2 分布拟合检验

定理 15 (分布拟合检验). 设总体 X 分布未知，假设检验

H_0 : 总体 X 的分布函数为 $F(x)$

H_1 : 总体 X 的分布函数不是 $F(x)$

$$\chi^2 = \sum_{i=1}^k \frac{n}{p_i} \left(\frac{f_i}{n} - p_i \right)^2 = \sum_{i=1}^k \frac{f_i^2}{np_i} - n \sim \chi^2(k-1)$$

需满足 H_0 为真， $n \geq 50$ ， $np_i \geq 5$ ，否则进行并组

定理 16 (分布族的拟合检验).

H_0 : 总体 X 的分布函数为 $F(x; \theta_1, \dots, \theta_r)$

$$\chi^2 = \sum_{i=1}^k \frac{f_i^2}{n\hat{p}_i} - n \sim \chi^2(k-r-1)$$

7 方差分析及回归分析

7.1 单因素方差分析

方差来源	平方和	自由度	均方	F比
因素A	$S_A = \sum_{j=1}^s \sum_{i=1}^{n_j} (\bar{X}_{.j} - \bar{X})^2$	$s-1$	$\bar{S}_A = \frac{S_A}{s-1}$	$F = \frac{\bar{S}_A}{\bar{S}_B}$
误差	$S_E = \sum_{j=1}^s \sum_{i=1}^{n_j} (X_{ij} - \bar{X}_{.j})^2$	$n-s$	$\bar{S}_E = \frac{S_E}{n-s}$	
总和	$S_T = S_E + S_A = \sum_{j=1}^s \sum_{i=1}^{n_j} (X_{.j} - \bar{X})^2$	$n-1$		

7.2 一元线性回归

$$\hat{y} = \hat{b}x + \hat{a}$$

$$S_{xx} = \sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - \frac{1}{n} \left(\sum_{i=1}^n x_i \right)^2$$

$$S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n y_i^2 - \frac{1}{n} \left(\sum_{i=1}^n y_i \right)^2$$

$$S_{xy} = \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - \frac{1}{n} \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right)$$

$$1. \hat{b} = \frac{n \sum_{i=1}^n x_i y_i - \left(\sum_{i=1}^n x_i \right) \left(\sum_{i=1}^n y_i \right)}{n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2} = \frac{S_{xy}}{S_{xx}} \quad \hat{a} = \bar{y} - \hat{b}\bar{x}$$

2. 误差 ε 的方差 $D(\varepsilon) = \sigma^2$ 的无偏估计

$$\widehat{\sigma^2} = \frac{Q_e}{n-2} = \frac{\sum_{i=1}^n (y_i - \hat{a} - \hat{b}x_i)^2}{n-2} = \frac{S_{yy} - \hat{b}S_{xy}}{n-2}$$

3. 线性假设: $H_0: b = 0, H_1: b \neq 0$ 的显著性检验, H_0 的拒绝域为

$$|t| = \frac{|\hat{b}|}{\hat{\sigma}} \sqrt{S_{xx}} \geq t_{\alpha/2}(n-2)$$

若拒绝 H_0 则回归效果显著

4. 回归系数 b 的置信水平为 $1 - \alpha$ 的置信区间

$$\left(\hat{b} \pm t_{\alpha/2}(n-2) \frac{\hat{\sigma}}{\sqrt{S_{xx}}} \right)$$

5. 回归函数 $\mu(x)$ 在点 $x = x_0$ 处函数值置信水平为 $1 - \alpha$ 的置信区间

$$(\hat{a} + \hat{b}x_0 \pm t_{\alpha/2}(n-2) \hat{\sigma} \sqrt{1/n + (x_0 - \bar{x})^2/S_{xx}})$$

6. 以 x_0 处的回归值 $\hat{y}_0 = \hat{a} + \hat{b}x_0$ 作为 Y 在 x_0 处观察值 $Y_0 = a + bx_0 + \varepsilon_0$ 的预测值, 则 Y_0 的置信水平为 $1 - \alpha$ 的预测区间为

$$(\hat{a} + \hat{b}x_0 \pm t_{\alpha/2}(n-2) \hat{\sigma} \sqrt{1 + 1/n + (x_0 - \bar{x})^2/S_{xx}})$$